3과목. 빅데이터 모델링. 핵심노트. 노빌쌤.

Copyright 2026. 데이터서핑앤노트. All rights reserved

*빅데이터 분석기사 필기시험. 4과목. 총 80문항 100점 만점 기준, 합격기준:60점 이상. 1과목별 최소 15점 이상 필요!
3과목은 20문항 25점 기준, 1과목별 최소 15점 이상 되어야함. 총 20문항 중 60%로 12개 이상 맞추어야함.

***변수선택** : 필터방법(독립변수와 종속변수간의 관계를 통계적으로 선택 ex)카이제곱.상관계수,ANOVA 등) 래퍼방법 (모델을 학습시키고 성능을 기준으로 선택. ex)전진선택법.후진제거법.단계적선택법). 임베디드방법(학습과정=동시선택 ex회귀_랏소.의사결정나무등) *하이퍼 파라미터 튜닝방법 : 매뉴얼서치(사람이직접). 그리드서치(모든 가능한 조합시도). 랜덤서치 ***분석도구** : R(S언어기반.무료). Python(C언어기반.무료). SAS.SPSS(유로)

***데이터분할** : 데이터를 학습/검증(평가)나누는것.일반화 성능확보 목적(훈련데이터,새로운 데이터에서도 모형 성능이 좋다) 홀드아웃(7:3). K폴드교차검증 (데이터를 K개 폴드로 나누고.K번 반복. 각 폴드를 검증데이터로 사용. K-1개 훈련데이터로 사용). 층화K폴드(클래스비율유지).LPO.LOO

방법	분할 방식	반복 횟수	계산 복잡도
LOO	1개를 검증 셋 (테스트 셋)	N 번	중간
LPO	P개를 검증 셋 (테스트 셋)	nCp 번	매우 높음
K-Fold	K개 폴드로 나눔 (N/K)	K 번	낮음

***회귀분석** : 지도학습.수치예측. 가정은 선형성. 독립성. 등분산성. 정규성임.

***선형성** : 독립변수,종속변수는 선형적인관계. 잔차산점도에서 평균0.분산일정. ***독립성** : 단순(잔차와 독립변수값이 서로 독립). 잔차산점도에서 경향이 없어야함. ***등분산성** : 잔차의 분산이 독립변수와 무관. 잔차산점도에서 고르게 분포해야함. ***정규성** : 잔차가 정규분포에따라야함. QQ플랏에서 우상향 형태임. * **종류** : 단순선형회귀(독립변수1개).다항선형회귀(독립변수1개.거듭제곱항). 다중선형회귀(독리변수2개이상.다차원직선). 정규화 모델인 릿지.라쏘.엘라스티넷회귀

***로지스틱 회귀분석** : 지도학습.분류예측. 유도과정 : 오즈(승산. p/1-p) > 로짓(log(p/1-p)) 왜 하는가? 좌변 실수 전체 범위. 우변 선형회귀처럼 독립 변수들의 결합으로 표현)>스그모이드(로짓함수에 지수함수의 곱)

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n \qquad \frac{p}{1-p} = e^{\beta_0 + \beta_1 X_1 + \ldots + \beta_n X_n} \qquad p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n)}}$$

오즈를 사용해 확률변환>로짓변환으로 선형방정식으로 표현>시그모이드 함수로 최종확률예측이 가능함. * **종류** : 이진 로지스틱회귀 : 종속변수 범주가 2개. 다항 로지스틱회귀 : 종속변수 범주가 3개이상. 다중 로지스틱회귀 : 종속변수가 2개이상.

***의사결정나무** : 지도학습.수치&분류예측. 트리구조로 사각화가능.변수선택 자동.비선형 관계학습.전처리 과정이 간단. 과적합가능성이 높음>정지기준 설정함. 일반화성능이 낮을수있음>랜덤포레스트기법활용. ***분리기준** : 불순도 지표

불순도 지표

종속 변수	알고리즘	분류 기준	사용되는 불순도 지표
이산형	CHAID	카이제곱 통계량	P-value (유의수준)
	CART	**지니 계수 최소화**	**지니 계수**
	C4.5	**엔트로피 최소화** **정도이득 최대화**	**엔트로피 & 정보이득**
	랜덤포레스트, XGBoost, LightGBM		**지니 계수,엔트로피**
연속형	CHAID	**F-검정 (ANOVA) 최소화**	F-통계량 (P-value)
	CART	분산 감소 **부모노드와 자식노드의 MSE 차이 최대화**	MSE (평균제곱오차)
	랜덤포레스트, XGBoost, LightGBM		**MSE, MAE**

정지기준 : 과적합방지목적. 하이퍼파라미터임 최대깊이제한. 최소샘플수. 최소 리프노트샘플수 가지치기(불필요한가지를제거)

***인공신경망** : 지도학습(수치예측.분류예측) .비지도학습(차원축소.군집분석등)

*뉴런 : 입력변수와 가중치를 선형결합을 만들고 활성화함수로 비선형적 값 출력 $y = w_1x_1 + w_2x_2 + \ldots + w_nx_n + b$ 단층퍼셉트론>다층퍼셉트론=딥러닝의 출발>DNN. *단층퍼셉트론 한계 : AND,OR (선형분리)만 가능. XOR(비선형분리)불가

***단층퍼셉트론** : 뉴런1개(입력층->출력층). ***다층퍼셉트론** : 입력층>은닉층(1개이상.N개의뉴런.활성화함수Relu계열)>출력층(이진분류 시그모이드,다중분류 소프트맥스. 회귀문제 활성화x) ***SVM** : 지도학습.수치&분류예측. 데이터를 잘 구분할 수 있는 마진을 최대화하는 최적의 경계선(초평면)을 찾음. 장점은 결정경계의 유연성(커널트릭을 사용하면 비선형문제도 해결 가능함).과적합방지(마진최대화로 일반화성능이 뛰어남).단점은 매개변수 선택의 어려움이 있음. 마진에는 하드,소프트마진

***연관성분석** : 비지도학습.데이터 내 변수간의 관계나 규칙을 발견하는 기법임. 장바구니분석이라 함. 만약A가 발생하면 B가 발생한다.조건부확률기반임. 지지도:특정 항목 집합이 전체 거래에서 얼마나자주 발생했는지. 신뢰도 : A를 구매한 고객 중 B도 함께 구매한 비율(조건부확률). 향상도:A와B의관계가 우연인지 실제인지 측정하는 지표임.(Lift =1 독립. Lift>1 연관)

***군집분석** : 비지도학습. 데이터의 유사성을 기준으로 그룹으로 나누는 기법. ***거리측정방법** : 유클리드거리(피타고라스정리) 맨허튼거리(축을따라이동하는거리측정). 코사인유사도(벡터 각도차이를이용한유사도측정).자카드유사도(집한간유사성평가)

***계층적 군집분석** : 트리구조.병합적방법(점점병합함).분할적방법(점점분리함).군집개수 사전설정이 필요 없음.대규모에선 비효율. 군집간거리 : 최단연결법.최장연결법.평균연결법.중심연결법(각군집의 중심간 연결).ward연결법(군집내 분산이 최소화 되도록**) *비계층적 군집분석 :** 사전에 정의된 군집 개수만큼 반복적인 조정을 통해 군집을 형성함 대규모 데이터에도 적합.(KMEANS. GMM(확률 기반). DBSCAN(밀도 기반). SOM{신경망기반. 차원축소 및 데이터 시각화 가능}).

***t 검정** : 양측검정,단측검정 가능. 정규성,등분산성확인. 단일표본,대응표본,독립표본t검정. ***ANOVA** : 양측검정만 가능.

정규성,등분산성확인. Oneway,TwowayANOVA. 사후분석(어떤 집단이 다른지 확인하기위해) ***카이제곱검정** : 독립성(H0:서로독립이다), 적합성(독립변수x.H0:관측된분포가 기대 분포와차이가 없다), 동질성(독립성검정과 유사하지만 독립변수의 집단간 분포를 비교함. ***교차표** : 분할표. 두개 이상의 범부형 변수간의 관계를 분석. 카이제곱검증.RR.OR에 활용

***상대 위험도(RR)** ***승산비(OR)** : 두집단의 승산(오즈)비

$$RR = \frac{(A/(A+B))}{(C/(C+D))} \quad OddsA = \frac{A}{B} = OddsB = \frac{C}{D} \quad OR = \frac{(A \times D)}{(B \times C)}$$

	질병 발생(+)	질병 미발생(-)	합계
흡연(노출군)	40	60	100
비흡연(비노출군)	20	80	100

상대 위험도는 전향적 코호트연구(연구시작할때 연구 대상자 모집.추적). 승산비는 후향적 코호트연구(과거 데이터 사용) ***단변량 분석**(하나의 변수분석ex기초통계량).**이변량 분석**(두 변수간 관계를 분석ex단순선형회귀).**다변량 분석**(3개이상의 변수간 분석ex다중회귀분석) ***다차원 척도법 :** 계량적MDS(데이터가 등간척도,비율척도),비계량적MDS(데이터가 순서척도임 스트레스값 : MDS에서 저차원으로 축소할때 원본 데이터에서의 거리와 저차원에서의 거리간차이를측정하는지표. 스트레스값이 낮을수록 모델의 정확도와 적합도가 상승함. ***MANOVA :** 3개이상의 집단을 가진 범주형독립변수와 2개이상의 연속형 종속변수로 구성된 검정기법.양측검정.사후분석.정규성,등분산성확인. ***시계열분석** : 데이터간 시간적 의존성을가지며, 시점간 관측값은 독립적이지 않음. ***특징** : 시간순서가 중요. 자기상관이 존재함(자기상관: 이전시점의 값이 현재 시점의 값에 영향을 준다. 자기상관=0, 서로 다른 시점간 공분산0. 서로 독립). **시계열 성분** : 추세.계절성.순환성분.불규칙성분으로 구성됨

***분해모형** : 가법모형.(변동폭이 일정한 시계열에 적합) 승법모형(변동폭이 추세에 따라 커지거나,작아지는시계열에적합)

구분	평균(Mean)	분산(Variance)	공분산(Covariance) / 자기상관(Autocorrelation)
자기상관	제한 없음	제한 없음	* 특정 시차에서 공분산 ≠ 0 → 자기상관 존재 * 특정 시차에서 공분산 = 0 → 자기상관 없음
백색잡음	0 또는 일정함	일정함	* 모든 시차에서 공분산 = 0 → 자기상관 없음
정상성	일정 (모든 시점에서)	일정 (모든 시점에서)	* 공분산은 시차(lag)에만 의존함 (0 또는 ≠ 0) (시점(time point) 에는 의존하지 않음)
비정상성	시간에 따라 변할 수 있음	시간에 따라 변할 수 있음	공분산이 시차 뿐만 아니라 시점에도 의존할 수 있음

***계산기법,예측방법론** : 이동평균법(일정기간평균을통해 추세성분을 추출). 지수평활법(과거시점으로 갈수록 가중치를 지수적으로줄임) ***시계열 모형 식별방법** : AR은 PACF 시차P이후로 0으로절단. MA는 ACF가 q이후로0으로절단.

***베이지안 기법** : 기존의 알고있는 정보를 바탕으로 새로운 정보가 왔을때 확률을 갱신하는방법임. 베이즈 정리 (사전확률에 새로운정보(증거)를 반영하여 사후확률을 계산함. 나이브베이즈분류기 : 조건부 확률과 베이즈 정리기반 지도학습분류기.

***딥러닝** : 인공신경망을 다층으로 구성하여 고차원특성을 자동으로학습하는 기계학습 기법. 주요 하이터파리미터 **학습률 :** 가중치의업데이트 정도. **에포크** :전체 학습 데이터를 반복 수. **반복횟수** : 한에포크 내에서 배치단위 학습 수행 횟수 **배치사이즈** : 1반복횟수를 진행할때 데이터수. ***CNN** : **합성곱층**(필터를 사용하여 이미지특징추출.선형적인 특성맵 생성됨. **필터**(총필터수가 특징맵의 수). **패딩**(데이터주변에 0을추가하여 테두리생성.정보유실방지)과 **풀링계층**(특징맵의 크기를 줄여 연산량이감소.위치변화에 강건함)으로구성. **펼치기**(3D(텐서)>1D벡터로 변환). **완전 연결층**(출력 클래스수만큼의 뉴런으로 연결). 출력층:softmax함수는 다중클래스분류. sigmoid함수는 이진분류 ***순환신경망.장단기메모리.적대적신경망**

***비정형분석** : **텍스트마이닝**(정제,토큰화,불용어제거,어간추출,표제어추출,형태소분석). **SNA**(노드와엣지로구성.행위자간관계 그래프로표현. 연결정도중심성(직접연결). 근접중심성(최소거리). 매개중심성(노드들사이에위치하는정도). 위세중심성(노드의 영향력에 가중치) ***앙상블** : 동일 알고리즘(부스팅{순차적 학습. 오차에 가중치}.배깅{병력적 학습.부트스트랩}). 서로다른 알고리즘(보팅.스태킹)

데이터 유형	연속형 종속변수	범주형 종속변수	종속변수 없음
▪ 연속형 독립변수	회귀분석. 트리나무. 인공신경망. SVR.KNN	로지스틱회귀분석. 트리나무.인공신경망. SVM. KNN. 판별분석	주성분 분석 군집분석
▪ 범주형 독립변수	회귀분석.트리나무. 인공신경망. T-test. ANOVA. MNOVA.	로지스틱회귀분석. 트리나무.인공신경망. 카이제곱 검증.피셔의 정확도.교차표. 나이브베이즈	연관분석
▪ 연속형 + 범주형 독립변수	회귀분석.트리나무. 인공신경망.	트리나무.인공신경망.	상관분석

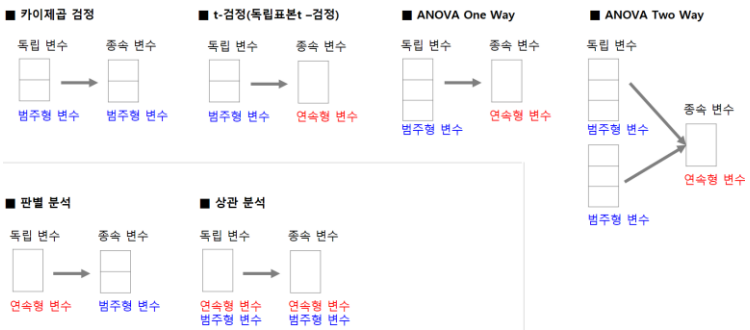

구분	모수 통계	비모수 통계
범주형 변수들간 검정		카이제곱 검정 (표본 수 多) 피셔의 정확 검정 (표본 수 小)
한 그룹 비교	단일 표본 t 검정	부호 검정
한 그룹의 비교 (전후)	대응 표본 t 검정	윌콕슨 부호 순위 검정
두 그룹 비교	독립 표본 t 검정	만 위트니 U 검정
주로 세 그룹 이상	One Way ANOVA	크루스칼 왈리스 검정
변수간 상관 비교	피어슨 상관 계수	스피어만 상관 계수