4과목. 빅데이터 결과해석. 핵심노트. 노빌쌤.

Copyright 2026. 데이터서핑앤노트. All rights reserved

*빅데이터 분석기사 필기시험. 4과목. 총 80문항 100점 만점 기준, 합격기준:60점 이상. 1과목별 최소 15점 이상 필요! 4과목은 20문항 25점 기준, 1과목별 최소 15점 이상 되어야함. 총 20문항 중 60%로 12개 이상 맞추어야함.

***평가지표** : 과적합.과소적합을 방지,예측력과 일반화 성능을 확보하기위해 수행함. ***회귀모형 평가지표**: 실제값-예측값 : ↓ 모형성능↑. **MSE:** 에러 크기를 그대로 반영(단위의존성) 이상치에 민감. **RMSE**: MSE보다 직관적임. 단위의존성. 이상치 민감 **MAE** : 직관적임.단위 의존성.이상치 강건. **MAPE** : 백분율값 (비율값. 단위의존성X) 모형간 비교에 용이. 실제값 0이면 왜곡 심함. 따라서, 실제값이 0과 작은 값 에서는 사용X. **R^2(결정계수):** 설명력 지표. 1- SSE/SST = SSR/SST 1 완벽하게 설명.0 평균값 만큼 설명.설명력이 없음. <0 평균값 예측보다 못한 경우.잘못된 모형

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \quad MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \quad MAPE = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right|$$

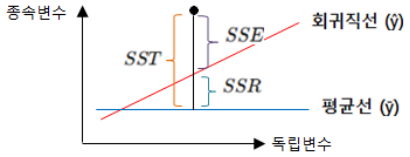

Adjusted R^2(수정된 결정계수): 다중선형회귀에서는 R^2와 Adjusted R2를 함께 확인이 필요. 변수를 추가할때 R^2값은 증가, 유지됨.변수의 개수,데이터 수를 반영한 수정된 결정계수확인이 필요. 불필요한 변수가 추가되면 수정된 결정계수는 감소함. ***분류모형 평가지표**: 혼돈행렬을 바탕으로 지표를 도출함.

실제 값 ₩ 예측 값	Positive (예측 Positive)	Negative (예측 Negative)
Positive (실제 Positive)	True Positive (TP)	False Negative (FN)
Negative (실제 Negative)	False Positive (FP)	True Negative (TN)

정확도:TP+TN/전체. **정밀도(precision)**: TP/TP+FP. FP↓중요.금융분야

재현율(recall)=민감도(sensitivity) TP/TP+FN. FN ↓중요. 의료분야

특이도(specificity) TN/TN+FP. 의료분야. **f1-scroce** 정밀도,재현율의 조화평균

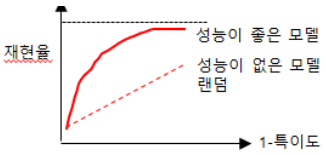

데이터 불균형 심한경우 정밀도,재현율, f1-scroce. 전체적 성능평가 경우 정확도, ROC-AUC

***선형회귀모형 가정 진단: 잔차산점도 기준**, 선형성 0 중심으로 랜덤 (패턴x). 등분산성 폭이 일정하게 랜덤 (깔때기모양x). 정규성 QQPlot. 우상향. 독립성 더빈왓슨검정

***교차검증 *과대적합:** 훈련 데이터 성능↑,새로운 데이터 성능↓. **과소적합:** 훈련,새로운 데이터 성능↓. ***편향오차**: 학습오차.모델이 단순해서 발생. 과소적합의 원인. **분산오차**: 일반화오차. 모델이 복잡해서 발생. 과대적합의 원인. 모델 복잡도 ↑>훈련오차↓,일반화오차↑>과대적합 위험. 편향오차와 분산오차의 균형지점이 일반화성능이 좋은 모형임. *과대적합 방지: 학습 데이터 확보, 교차검증 활용, 단순화 모델, 가중치 규제 (L1규제 (절대값,0,변수가 많을때, 줄어듬), L2규제(제곱,0에 근접,모든 변수가 중요),ElasticNet) ***매개변수,초매개변수,매개변수 최적화.** 학습데이터로부터, 손실함수(비용함수)의 값이 최소가 되는 최적값을 찾는 과정임. **경사하강법**: 손실함수기울기, 가중치를 반복, 업데이트. 배치 경사하강법(한번 업데이트,전체 데이터, 느림, 안정적), 확률적 경사하강법(데이터 1개씩, 빠름, 불안정), 미니배치 경사하강법(일부 데이터 묶음.중간,균형). **경사하강법을 개선** (모멘텀:관성, adagrad:적응형 학습률, 많이 학습된 변수,학습률↓, rmsprob: adgrad개선, **adam:모멘텀+rmsprob**) **모아알아, 밀고 줄이고 유지하고 다한다. *앙상블 기법**

***분석결과 해석의 전제조건**: 데이터신뢰성, 분석목적명확, 모형적합성, 통계적유의성확보. ***비즈니스 기여도 평가**: 재무 분석 지표 **ROI**(투자수익률 투자해서 얼마벌었냐?), **NPV**(순현재가치,현 가치기준 총 기간 경제적이익), **IRR**(내부수익률, NPV=0 만드는 수익률),**TCO**(숨은 비용 포함 총소유비용), **PP**(투자회수기간, 원금회수기간) **시간가치 반영된 건, NPV,IRR**

***시간 시각화** : 막대그래프,산점도, 선그래프,계단식그래프, 영역차트. ***공간 시각화** : 등치지역도(색상,음영),도트플롯맵(점), 버블플롯맵(원크기), 등치선도 (등고선) ,카토그램 (크기 왜곡)

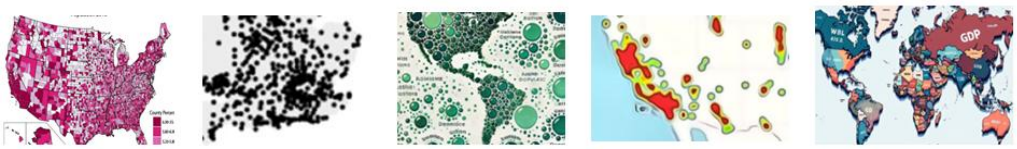

***관계 시각화** : 산점도, 산점도행렬 버블차트, 히스토그램, 플로우차트 ***비교 시각화 :** 박스플롯 (여러 그룹간 비교), 히트맵(상관구조, 대용량 데이터), 스타차트 (여러 속성 비교), 체르노프페이스 (시각적 해석 오류) 평행좌표 그래프 (변수 많아지면 해석 어려움)

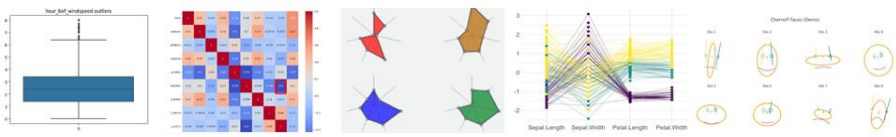

***인포그래픽 :** 인포메이션+그래픽 (정보형,리스트형, 차트/통계형,비교형)

*분석결과를 실무에 활용하기위해서는 **분석모형전개>분석결과활용시나리오개발>분석모형모니터링>분석모형리모델링**

* 분석모형모니터링:운형환경에서 분석모형의 성능을 지속적으로 추적,평가하는과정. ***분석모형리모델링: 기존 분석모형 분석(새로운 데이터 적용)>데이터수집,전처리>분석모형구축>최종분석모형선정및반영**