합격 알고리즘 노트

제1과목 ▶ 빅데이터 분석 기획

제2과목 ▶ 빅데이터 탐색

제3과목 ▶ 빅데이터 모델링

제4과목 ▶ 빅데이터 결과 해석

합격
알고리즘
노트

제 1 과목 빅데이터 분석 기획

제 1 장 빅데이터의 이해

빅데이터(Big Data)

기존 데이터베이스 관리 도구의 능력을 넘어서는 대량의 정형 또는 심지어 데이터베이스 형태가 아닌 비정형의 데이터 집합까지 포함한 데이터로부터 가치를 추출하고 결과를 분석하는 기술(빅데이터 분석 및 시각화 기술도 포함한 개념으로 이해)

빅데이터의 주요 특징

Volume(규모), Variety(다양성), Velocity(처리속도), Value(가치), Veracity(정확성), Validity(유효성), Volatility(휘발성)

(주)시대고시기획

빅데이터의 유형

- 정형(Structured) : 정해진 규칙에 맞게 저장된 데이터, 구조화되어 있음
- 반정형(Semi-structured) : 어의적 요소(단어, 말)를 분리시키고 태그나 다른 마커를 포함
- 비정형(Unstructured) : 데이터의 구조와 형태가 데이터마다 다르고 정형화되지 않음

빅데이터의 가치

사회경제적 가치, 비즈니스 모델 혁신, 비용 절감, 수익 증대, 사회적 비용 감소(의료 및 보건 분야 등), 산업 생산성 및 효율성 향상

빅데이터 산업

인프라(단말, 장비, 소프트웨어 공급자) 및 서비스(빅데이터 서비스 공급업자, 유 · 무선 통신 서비스 업자)

빅데이터 비즈니스 모델

빅데이터 서비스 제공자가 단말, 장비, 소프트웨어 공급자로부터 구매한 인프라를 이용하여 고객에게 데이터 처리, 정보 제공, 솔루션 제공, 교육 및 컨설팅 제공 등의 서비스를 제공하는 방법

빅데이터 조직

시스템 엔지니어, 데이터베이스 엔지니어, 소프트웨어 엔지니어 등으로 데이터 분석팀 및 시스템 운영팀 구성

빅데이터 분석 직무(NCS의 정의)

대용량의 데이터 집합으로부터 유용한 정보를 찾고 결과를 예측하기 위해 목적에 따라 분석기술과 방법론을 기반으로 정형, 비정형 대용량 데이터를 구축, 탐색, 분석하고 시각화를 수행하는 업무

빅데이터 요소 기술

데이터 수집, 저장, 공유, 처리, 분석 및 시각화

빅데이터 플랫폼

다양한 데이터 소스에서 수집된 데이터를 처리하고 분석해서 지식을 추출하고 지능화된 서비스를 제공하는 데 필요한 IT환경

데이터베이스(Database)

여러 사람에 의해 공유되어 사용될 목적으로 통합하여 관리되는 데이터의 집합(Stored, Integrated, Shared)

데이터베이스 관리 시스템(DBMS ; Database Management System)

다수의 컴퓨터 사용자들이 컴퓨터에 수록된 많은 자료들을 쉽고 빠르게 조회, 추가, 수정, 삭제할 수 있도록 해주는 소프트웨어

인공지능(AI ; Artificial Intelligence)

- 컴퓨터를 사용하여 인간의 지능을 모델링하는 기술
- 핵심요소 : 하드웨어, 소프트웨어, 프로그래밍 언어, 모델 형태, 응용 분야

(주)시대고시기획

데이터 마이닝(Data Mining)

대규모로 저장된 데이터 안에서 체계적이고 자동적으로 통계적 규칙이나 패턴을 찾아내는 기법으로 분류, 군집화, 연관성 분석, 연속성 분석 및 예측 분야에 활용

머신러닝(기계학습, Machine Learning)

- 인공지능의 한 분야로서 컴퓨터가 학습할 수 있도록 하는 알고리즘과 기술 개발
- 지도 학습 : 입력과 출력을 연관시키는 관계 학습(분류, 회귀 분석)
- 비지도 학습 : 출력값 없이 입력값만으로 스스로 규칙성을 찾아냄(클러스터링, 차원축소)
- 강화 학습 : 보상을 이용하여 학습(실시간 의사결정, 인공지능 게임)

딥러닝(Deep Learning)

머신러닝과 신경망의 한 분야로서 여러 개의 은닉층을 가진 심층 신경망을 기반으로 하는 학습 방법

개인정보

- 이름, 주민등록번호에서 DNA에 이르기까지 그것을 이용해 특정 개인을 식별할 가능성을 내포한 데이터
- 관련 법령 : 정보통신망 이용촉진 및 정보보호 등에 관한 법률, 위치정보의 보호 및 이용 등에 관한 법률, 정보통신기반 보호법, 국가정보화 기본법, 전자정부법, 개인정보보호법 등

개인정보 활용을 위한 비식별조치 가이드라인

- 비식별 조치 : 데이터 내에 포함된 개인정보에 대한 활용 및 비식별 조치 후 활용 가능 여부에 대한 부분이 국내 관계부처에서 제정한 '개인정보 비식별조치 가이드라인'을 준수하고 있는지 확인
- 가이드라인 : 공공정보 개방 · 공유에 따른 개인정보보호지침, 개인정보 비식별화에 대한 적정성 자율평가 안내서, 빅데이터 개인정보보호 가이드라인, 빅데이터 활용을 위한 개인정보 비식별화 기술 활용 안내서 준수

제 2 장 데이터 분석 계획

작업분할구조도(WBS ; Work Breakdown Structure)

- 프로젝트 관리와 시스템 공학 분야에서 프로젝트의 더 작은 요소로 분해시킨 Deliverable 지향 분업 구조
- 프로젝트 팀이 프로젝트 목표를 달성하고 필요한 인도물을 산출하기 위해 실행하는 작업을 인도물 중심의 계층 구조로 세분해 놓은 것
- 작성 절차 : 프로젝트 소요 비용 배분 → 프로젝트 WBS 수립 → 프로젝트 업무분장 계획 및 배분

(주)시대고시기획

빅데이터 분석 프로세스

- 5단계(NCS) : 도메인 이슈 도출 → 분석목표 수립 → 프로젝트 계획 수립 → 보유 데이터자산 확인 → 빅데이터 분석결과 시각화
- 6단계 : 문제인식 → 관련 연구조사 → 모형화(변수선정) → 자료수집(변수측정) → 자료분석 → 분석결과 제시

데이터 수집 시 고려사항

분석대상 비즈니스 이해, 데이터 수집 대상 및 유형, 데이터 위치, 수집 방법, 획득 비용 등

데이터 분석 관련 문서화

빅데이터 요건 정의서, 분석목표정의서, WBS, 데이터품질보고서, 데이터 분석 보고서 등

빅데이터 분석목표정의서

데이터 원천 파악(데이터 정보, 입수 난이도), 분석접근 방안, 데이터 분석모형 적용 가능성 판단, 성과평가 기준(정성 및 정량적 평가기준) 마련 등

빅데이터 주요 분석 기술

회귀, 분류, 연관성, 머신러닝, 감정, 소셜 네트워크, 유전 알고리즘 등

빅데이터 분석 도구

Hadoop, MapReduce, R, Presto, BigQuery, Summingbird, Esper 등

빅데이터 처리 시스템

- 데이터 처리를 통하여 유용한 정보를 찾고 데이터가 포함하고 있는 지식을 찾아내며, 이러한 정보를 찾기 위한 데이터 가공 및 분석과정 전반을 지원하는 시스템
- 주요 고려사항 : 데이터 양, 데이터 발생속도, 데이터 형태, 새로운 처리 기술 등
- 요구사항 : 결함허용, 저비용, 기존 시스템 연계성 등

데이터 확보 계획 수립 절차

목표 정의 → 요구사항 도출 → 예산안 수립 → 계획 수립

WBS(Work Breakdown Structure, 작업분할구조도) 작성 절차

데이터 분석과제 정의 → 데이터 준비 및 탐색 → 데이터분석 모델링 및 검증 → 산출물 정리

데이터 수집 및 점검 프로세스

데이터 상황 점검 → 데이터 수집경로 및 데이터 유형 파악 → 데이터별 활용정보 점검

데이터 적절성 점검 항목

데이터 누락, 소스 데이터와의 비교, 데이터 정확성, 보안 점검, 저작권 점검, 대량 트래픽 발생 점검 등

(주)시대고시기획

데이터 저장 시스템 설계를 위한 요구사항

요구사항 수집, 요구사항 분석(데이터 및 인터페이스 등), 요구사항 명세(데이터 요구사항 명세서 작성), 요구사항 검증 등

제3장 데이터 수집 및 저장 계획

데이터 수집 시 고려사항

데이터 분석의 목적, 데이터 수집 가능성, 데이터 보안, 데이터 정확성, 수집 난이도 및 비용 고려

데이터 위치

- 내부 데이터 : 대부분 정형 데이터로 존재, 조직 내부의 데이터 담당자와 수집 주기 및 방법 협의, 수집 난도가 낮음
- 외부 데이터 : 대부분 반정형 및 비정형 형태로 존재, 특정 기관의 담당자와 협의, 전문업체를 통해 수집, 수집 인터페이스 협의, 수집 난도가 높음

데이터 수집 절차

데이터 유형 파악 → 수집기술 검토 → 수집 솔루션 확인 → 하드웨어 구축 → 실행환경 검토

데이터 수집 기술

- 정형 데이터 : 대용량 데이터 전송 솔루션 이용(Sqoop, Hiho 등)
- 반정형 데이터(로그 데이터 등) : 로그 파일 수집기 이용(Flume, Scribe, Chukwa 등)
- 비정형 데이터 : 크롤링, Open API, RSS 이용

(주)시대고시기획

웹에서의 데이터 수집 방법 : HTML, XML, JSON 등 이용

- Web Crawling : 자동화 Bot인 Web Crawler가 정해진 규칙에 따라 복수의 웹페이지 자료수집
- Web Scraping : 웹사이트의 원하는 부분에 위치한 정보를 자동 추출 및 수집
- Web Mining : 인터넷을 이용한 웹서비스의 다양한 패턴을 발견하기 위해 사용되는 기술

스크립트 언어를 이용한 데이터 수집

Python, Ruby 등 이용

데이터 수집 시 관련 내규 검토

개인정보보호 업무처리 지침서, 보안 약점 및 개인정보 사전 제거, 보안 가이드 검토

데이터 적절성 검증

데이터 누락 및 결측(데이터 재수집), 데이터 정확성, 개인정보 유무 파악, 데이터 저작권 및 법률적 문제 검토

빅데이터 시스템 운영 업무

시스템 구성 및 변경 관리, 운영 상태 관리, 성능 관리, 보안 관리

데이터 수집 불가의 원인 및 대처 방안

- 시스템 오류 : 시스템 구성 및 프로그램 수정, 네트워크 확인
- 보안 : 암호화된 데이터의 경우 인증서 이용, 폐쇄망 데이터의 경우 사전 관리자 승인
- 저장 용량 : 시스템 용량 산정 재검토, 저장 공간 확보

데이터 수집 보고서의 주요 내용

데이터 유형, 데이터 위치, 데이터 저장 시스템, 수집 기술, 수집 비용

데이터 유형

- 정형 데이터 : 정형화된 스키마 구조를 갖고 있으며 스프레드 시트, csv 형태의 데이터
- 반정형 데이터 : 내부에 데이터 구조에 대한 메타 정보를 갖고 있으며 HTML, XML, JSON, 로그 형태의 데이터
- 비정형 데이터 : 구조가 일정하지 않은 데이터로서 텍스트, 영상, 이미지, 음성 등의 데이터

데이터 측정

일정한 규칙에 따라서 사물 또는 현상에 숫자를 부여하는 행위로서 추상적 개념을 경험적으로 관찰 가능한 것으로 바꾸는 과정

데이터 속성

- 측정을 통해서 대상의 특정 속성과 연관된 값을 데이터의 속성값이라고 정의함
- 계량적 변수 : 정량 데이터, 수치로 측정할 수 있는 데이터 저장, 연속적인 모든 값을 가짐, 연속형 변수, 비율 및 등간 척도
- 비계량적 변수 : 정성 데이터, 수치로 측정할 수 없는 데이터 저장, 정숫값만을 가짐, 이산형 변수, 명목, 서열 및 등간 척도

(주)시대고시기획

데이터 측정 척도

- 명목 척도(범주형) : 측정대상이 어느 집단에 속하는지 분류 예 성별, 이메일 주소, 인터넷 계정, 옷 색깔 등
- 서열 척도(순서형) : 측정대상이 서열관계를 갖는 척도 예 고객등급, 순위, 직급, 평점, 선호도 등
- 등간 척도(상대적 크기) : 측정대상이 갖고 있는 속성의 양 측정. 또는 (구간 척도) 서열과 의미 있는 차이를 가지는 척도, 결과는 숫자로 표현 예 온도, 지능 지수 등
- 비율 척도(절대영점 존재) : 절대적인 영점 존재. 두 측정값의 비율이 의미가 있음 예 몸무게, 매출액, 질량, 나이, 길이 등

데이터 변환

데이터의 특정 변수를 정해진 법칙에 따라 바꿔주는 것

데이터 변환 방법

- 표준화(변수변환) : 집단 간의 측정 변수들에 대한 값의 차이를 서로 비교할 때 용이, 표준 정규 분포 등을 이용
- 총계(개수 축소) : 두 개 이상의 샘플을 하나의 샘플로 합산하여 데이터 변환
- 평활(범주화) : 데이터 집합에 존재하는 잡음으로 인해 거칠게 분포된 데이터를 매끄럽게 만드는 기법(구간화, 군집화 등)
- 비정형 데이터 변환 : 가능한 정형 데이터로 변환하여 분석, 텍스트의 경우 단어들의 빈도 표현

데이터 비식별화

- 개인을 식별할 수 있는 잠재성을 가진 데이터를 식별할 수 없거나 식별하기 어려운 데이터로 가공하는 일련의 과정
- 절차 : 사전검토 → 비식별조치 → 적정성 평가 → 사후관리

데이터 비식별화 방법

가명처리, 총계처리, 데이터값 제거, 범주화, 데이터 마스킹

데이터 품질

데이터 분석의 목적을 달성하고 최종 사용자의 기대를 만족시키기 위해 데이터가 확보하고 있어야 하는 성질

데이터 품질 검증 절차

- 데이터 품질 : 데이터 정확성, 완전성, 적시성, 일관성
- 데이터 무결성 : 개체, 참조, 속성, 키, 도메인, 사용자 정의 무결성
- 데이터 비식별화 : 가명 처리, 총계처리, 데이터값 제거, 범주화, 데이터 마스킹

(주)시대고시기획

데이터 품질검증 및 진단계획 수립 절차

프로젝트 정의 → 조직 정의 및 편성 → 품질진단 절차 정의 → 세부 시행계획 확정 → 품질기준 및 진단대상 정의

데이터 품질관리

비즈니스 목표에 부합한 데이터 분석을 위해 가치성, 유용성 있는 데이터를 확보하고 신뢰성 있는 데이터를 유지하는 데 필요한 관리 활동, 분석결과의 신뢰성 확보를 위해 중요

데이터 품질관리 모형의 3가지 관점

- 미시적 관점 : 데이터 품질관리의 요소 확인, 요소별 데이터 품질 향상 방안 도출
- 거시적 관점 : 전사적 조직 측면에서 데이터 관리의 성숙도 단계 정의
- 부가가치적 관점 : 데이터 품질관리의 비용 · 효과 · 위험 모형 개발

데이터 품질검증 결과 보고서 주요 내용

품질기준에 따른 테스트 결과, 수집 데이터 오류 및 수정 방안, 데이터 변경 및 보완 등의 데이터 품질개선 방안

데이터 품질검증 자동화 도구의 이용

진단 대상 데이터베이스 관리, 테이블 관리, 진단 유형 관리, 품질진단, 진단 모니터링, 진단 결과관리, 오류원인 관리, 보고서 작성 등의 업무 수행이 가능

빅데이터 품질관리 시스템 운영 및 관리 기능

장애관리, 용량관리, 성능관리, 보안관리, 사용자 지원 서비스 제공 등

데이터 적재

수집된 데이터를 저장소에 적재하기 위한 작업, 데이터 필터링, 유형변환, 정제 등의 기술 활용

데이터 전처리

- 데이터 필터링 : 데이터 분석 목적에 맞는 데이터 추출, 비정형 데이터의 경우 데이터 오류나 중복 제거, 저품질 데이터의 경우 품질개선
- 데이터 유형 변환 : 데이터 분석이 용이한 형태 또는 분석 목적에 맞는 데이터로 변환
- 데이터 정제 : 데이터 결측치, 노이즈, 이상값 식별 및 처리

데이터 후처리

- 데이터 변환 : 수집 데이터를 일관성 있는 형식으로 변환
- 데이터 통합 : 연관성 있는 데이터 결합, 데이터 단위 일치
- 데이터 축소 : 불필요한 데이터 축소, 분석시간 단축 등 분석의 효율성 제고

(주)시대고시기획

데이터 저장 시스템 계획 수립 시 고려사항

- 시스템 구축 : 데이터(양, 유형, 크기, 저장 방식, 기간 등), 디스크 용량, 클라우드 서비스 등
- 사전 계획 수립 : 안정성, 신뢰성, 접근성, 관리자, 사용자, 세부 계획 수립(시스템 도입, 구축 일정, 연계방안, 검증 및 운영 방안 등)

데이터 저장 시스템 점검 리스트

- 저장 시스템 및 환경설정, 구축 일정 및 역할, 데이터 수집 및 처리 시스템 연계 방안, 시스템 검증 및 운영 방안
- 정형 데이터 : RDB
- 반정형 데이터 : RDB 또는 NoSQL
- 비정형 데이터 : NoSQL 또는 HDFS

데이터 저장 시스템 기능성 점검 항목

데이터 모델, 확장성, 트랜잭션의 일관성, 질의 지원, 접근성 등

데이터 저장 방법

분산 파일 시스템, 데이터베이스, NoSQL, MongoDB 등

하드웨어 구성 방법

분산 컴퓨팅(Grid, GPGPU, FPGA 등), 병렬 컴퓨팅, 클라우드 컴퓨팅(SaaS, IaaS, PaaS) 등

소프트웨어 환경

멀티 프로세스, 멀티 스레드, 아파치 하둡, HDFS 이용, MapReduce, YARN, Spark, RDD 등

데이터 저장 시스템 선정 결과 보고서 주요 내용

저장 기술의 기능성, 분석 방식 및 환경, 데이터 유형, 기존 시스템 연계 방법, 최종 검토결과 등

(주)시대고시기획

제 2 과목 빅데이터 탐색

제 1 장 데이터 전처리

데이터 오류

- 결측치(Missing Value) : 측정된 데이터 샘플에서 누락된 변숫값, 샘플 제거, 해당 변수 제거, 결측치 무시, 결측치 추정 등의 방법 사용
- 잡음(Noise) : 데이터 측정 시 개입되는 임의적 요소, 본래의 참값에서 벗어나게 하는 오류, 구간화, 군집화, 회귀모형 변환 등을 이용한 잡음 제거
- 이상치(Outlier) : 대부분의 다른 측정값들과 현저한 차이를 보이는 샘플 혹은 변숫값, 오류인 경우 이상치 제거 또는 무시, 특이값인 경우 관심을 두고 분석 수행

(주)시대고시기획

빅데이터 정제

데이터를 불완전하게 만드는 요소를 제거하기 위한 업무, 데이터 변환, 교정 및 통합

ETL(Extract, Transforam, Load) 주요 기능

논리적 데이터 변환, 도메인 검증, DBMS 간 데이터 변환, 기본값 생성, 데이터 요약, 불필요한 데이터 또는 중복 데이터 삭제, 레코드 통합 등

데이터 정제 및 처리 솔루션

대화형 처리, 배치 처리, 실시간 처리 등을 위한 Cloudera, Hortonworks, Azure, MapReduce, Pig, AWS 등

데이터 세분화(Segmentation)

데이터를 유의미한 기준에 따라 나누는 작업으로서 정형 데이터의 경우 큰 문제가 없으나 비정형 및 반정형 데이터의 경우 데이터 형식 변환 기준에 따른 세분화 작업이 요구됨

데이터 결측값 종류

- 완전 무작위 결측(MCAR ; Missing Completely At Random) : 어떤 변수 상에 결측 데이터가 관측된 혹은 관측되지 않은 변수와 아무 연관이 없음
- 무작위 결측(MAR ; Missing At Random) : 어떤 변수 상에 결측 데이터가 관측된 다른 변수와 연관되어 있지만, 그 자체의 비관측된 값들과는 연관되어 있지 않음
- 비무작위 결측(NMAR ; Not Missing At Random) : 어떤 변수의 결측 데이터가 완전 무작위 또는 무작위 결측이 아닌 경우로 소득, 성별, 나이 데이터 등

결측값 대체 방법

결측치가 있는 경우 제거하거나 시계열 자료인 경우 같은 시기의 데이터로 대체, 평균값, 최빈값 등으로 대체 사용(평균치 삽입법, 보삽법, 평가치 추정법 등 사용)

데이터 이상값

- 입력 오류, 데이터 처리 오류 등의 이유로 특정 범위에서 벗어난 데이터 값, 속성의 값이 일반적인 값보다 편차가 큰 값, 특정 범위를 벗어난 자료
- 주어진 자료에 대해서 데이터의 분포나 자료의 형태를 보고 이상치 판정

이상값 검출 방법

Variance, Likelihood, Nearest-neighbor, Density, Clustering, Box-plot 등

(주)시대고시기획

이상값 처리 방법

하한 및 상한값, 평균의 표준편차, 평균의 절대편차, 극 백분위수 등으로 대체

변수(Variable)

- 관심의 대상이 되는 사물이나 사건의 속성으로 보통 서로 다른 두 개 이상의 값을 가짐
- 컴퓨터 프로그래밍에서의 변수 : 아직 알려지지 않거나 어느 정도까지만 알려져 있는 양이나 정보에 대한 상징적 이름

속성에 따른 변수

이산, 연속, 더미 변수 등

기능에 따른 변수

독립, 종속, 통제, 매개, 외생, 억압 변수 등

차원축소(Dimensionality Reduction)

- 분석대상이 되는 여러 변수들의 주요 정보는 최대한 유지하면서 데이터세트 변수의 개수를 줄이는 일련의 탐색적 데이터분석기법
- 주요 알고리즘 : 주성분, 독립성, 특이값 분해, 요인, 다차원 척도법 등

파생변수(유도변수, Derived Variable)

- 기존 변수에 특정 조건 또는 함수 등을 이용하여 새롭게 재정의한 변수
- 생성 방법 : 단위 및 척도 변환, 표현 형식, 요약 통계량 이용, 변수 결합 등

변수변환

- 수학적 의미에서 보면, 어떤 변수(들)로 나타낸 식을 다른 변수(들)로 바꿔 나타내는 기법
- 구간화, 평활화, 클러스터링, 타깃변수 예측을 위한 의사결정나무 등 이용

불균형 데이터

어떤 데이터에서 각 클래스(주로 범주형 변수)가 갖고 있는 데이터의 양에 차이가 큰 경우 발생

불균형 데이터 처리방법

- Undersampling : 다수 클래스 데이터에서 일부만 사용, 무작위로 정상 데이터 일부 선택
- Oversampling : 소수 클래스 데이터를 증가시키는 방법, 무작위로 소수 데이터 복제

제 2 장 데이터 탐색

(주)시대고시기획

데이터 탐색(EDA ; Exploratory Data Analysis)

- 쌓여 있는 데이터를 기반으로 연구 목적에 맞는 가설을 세우고 데이터를 분석하는 작업으로 데이터의 구조와 특징을 파악하고 분석을 통해 얻은 정보를 토대로 통계적 분석모형을 만듦
- 목적 : 데이터 이해, 연구목적에 맞는 데이터 탐색, 시각화를 통해 다음 단계 필요한 데이터 생성, 데이터에 포함된 변동성 유형 파악, 변수들 사이 공통 변동 파악, 이상점 파악 및 분석

EDA 절차

데이터 속성 파악 → 데이터 결측치 확인 → 데이터 이상치 확인

상관관계 분석

두 변수 사이에 얼마나 선형적인 관계가 있는지를 파악하기 위해서 사용되는 통계적 방법

산점도(산포도)

두 개의 변수가 짝을 이루는 경우 두 변수 사이의 관계를 그림으로 표현한 것

상관계수

- 두 변수의 직선화 정도를 파악할 수 있는 통계량
- 피어슨 상관계수 : 두 변수가 연속형 자료인 경우 두 변수 사이의 연관성 정도 파악
- 스피어만 상관계수 : 분석하려는 데이터가 순위를 나타내는 순위형 자료(서열 척도)인 경우

통계학

- 기술 통계학 : 자료의 특성을 쉽게 파악할 수 있도록 자료의 대푯값을 구하고 자료를 간단히 그래프로 표현하여 분석
- 추측 통계학 : 자료에 있는 불확실한 사실에 대한 추론을 하는 것으로 모집단에서 표본을 추출해서 선출된 표본으로 모집단의 특성 파악
- 모집단 : 관심의 대상이 되는 전체 집합
- 표본집단 : 모집단에서 추출된 일부
- 모수 : 모집단의 특성을 수치로 나타낸 것
- 통계량 : 표본집단의 특성을 수치로 나타낸 것

중심위치의 기초 통계량

산술평균, 가중 산술평균, 기하평균, 조화평균, 중위수, 최빈값, 사분위수 등

흩어짐(퍼짐) 정도를 나타내는 기초 통계량

범위, 분산, 표준편차, 변동계수(표본평균/표본편차), 사분위 범위 등

(주)시대고시기획

분포의 모양을 나타내는 척도

- 왜도(Skewness) : 자료 분포의 비대칭도 파악. 왜도 = 0이면 대칭 분포, 왜도가 +이면 왼쪽으로 기울고, −이면 오른쪽으로 기울어진 분포 모양
- 첨도(Kurtosis) : 분포가 중심에서 얼마나 뾰족한지를 나타내는 통계량. 3보다 작으면 정규 분포보다 뾰족한 모양, 3보다 크면 정규 분포보다 완만한 모양을 나타냄

시각적 데이터 탐색

- 시각 이해의 계층도를 통해 데이터, 정보, 지식, 지혜 사이의 계층적 관계 설명
- 데이터 사이의 관계 등을 찾아 정보를 발견하고 정보가 좀 더 조직화되었을 때 지식이 되며, 정보가 구조화되어 적용되었을 때 지혜가 됨

시공간 데이터

- 공간적 객체에 시간의 개념이 추가된 것, 시간에 따라 위치나 형상이 변하는 데이터
- 데이터를 공간과 시간의 흐름상에 위치시킬 수 있는 거리 및 시간 속성을 가짐
- 시공간 데이터를 저장하기 위한 공간 데이터 타입은 객체의 기하학적인 특성을 기준으로 저장됨(포인트, 라인, 폴리곤, 폴리라인 등)
- 이산적 변화 : 시간의 흐름에 따라 시와 군의 통합으로 인해 상호간의 행정경계가 변화
- 연속적 변화 : 일정한 주기로 수집된 기상정보를 이용하여 기상전선의 변화를 나타냄

다변량 데이터 분석

- 많은 수의 케이스를 특성이 비슷한 몇 가지 집단으로 분류하여 전체 케이스가 가지고 있는 의미를 분류된 몇 개의 집단으로 설명
- 변수의 차원을 줄이는 방법 : 다변량 회귀 분석, 다변량 분산 분석, 주성분 분석, 요인 분석, 정준상관 분석
- 케이스의 차원을 줄이는 방법 : 군집 분석, 판별 분석, 다차원 척도법

비정형 데이터 탐색

일반적으로 비정형 데이터 탐색 및 정련 과정을 통해 정형 데이터로 만든 후 분류, 군집화, 회귀 분석, 요약, 이상감지 분석 등의 데이터 마이닝을 통해 의미 있는 정보를 발굴

비정형 데이터 탐색 및 분석 방법

- 통계기반의 데이터 분석 도구 사용
- OLAP(Online Analytical Processing) 분석
- 데이터 내에 숨겨진 관계, 패턴, 경향 등을 추출
- 텍스트 마이닝, 오피니언 마이닝, 웹 마이닝, 소셜 네트워크 마이닝 기법 등 활용

제3장 통계기법 이해

(주)시대고시기획

데이터 요약값

데이터 분석을 위해 간단한 기초통계량을 중심으로 제시된 값

표본 추출

- 모집단의 부분 집합을 추출한 것
- 추출된 표본(Sample)은 모집단과 같은 대표성을 가진다고 가정
- 모집단 전체에 대한 분석이 사실상 불가능한 제약으로 표본 이용
- 전체 대상의 특성을 대표할 수 있는지의 여부 확인
- 표본의 대표성이 중요

확률적 표본 추출 방법

- 단순 무작위 추출 : 표본이 추출될 확률이 동일한 경우
- 층화표본 추출 : 두 개 이상의 층으로 나누고 각 층마다 독립적으로 단순 임의 추출
- 집락(군집)표본 추출 : 이질적인 군집으로 구분, 무작위로 몇 개의 군집을 표본 추출
- 계통표본 추출 : 모집단 목록에서 일정한 순서에 따라 요소 추출

비확률적 표본추출 방법

- 할당표본 추출 : 모집단을 일정한 카테고리로 나눈 후 각 카테고리에서 정해진 표본 수만큼 작위적으로 추출
- 유의표본 추출 : 연구자가 연구목적의 달성에 도움이 되는 구성요소를 의도적으로 추출
- 임의표본 추출 : 정해진 표본 선출 시까지 모집단의 일정 단위 또는 사례 표집
- 누적표본 추출 : 소수 인원을 조사원으로 활용하여 주위 사람들을 조사

확률 변수와 확률 분포

- 확률 변수(Random Variable) : 표본공간의 근원 사상을 정수나 실수로 표현하여 나타낸 변수
- 확률 분포(Probability Distribution) : 확률 변수를 중심으로 확률 변수의 특성에 따라 확률로 표현한 분포

이산 확률 분포

- 확률 변수가 일정한 수로 나타나는 경우
- 베르누이 시행 : 확률 변수가 성공 아니면 실패로 표본공간이 이루어진 경우
- 이항 분포 : 성공확률이 p인 베르누이 시행을 n번 독립적으로 반복할 때의 성공 횟수
- 포아송 분포 : 단위시간당 또는 단위면적당 사건의 평균 횟수가 몇 번인지를 확률 변수로 정의
- 초기하 분포 : 유한 모집단에서 비복원 추출의 경우 성공의 수를 확률 변수로 정의
- 기하분포 : 첫 번째 성공이 일어날 때까지의 베르누이 시행 횟수
- 음이항 분포 : 성공확률이 p인 베르누이 시행을 n번 독립적으로 반복할 때 K번 성공하기까지의 시행 횟수
- 다항 분포 : 여러 번의 독립시행에서 각각의 값이 특정 횟수가 나타날 횟수

(주)시대고시기획

연속 확률 분포

- 확률 변수가 연속적인 수로 나타나는 경우
- 정규 분포 : 모수인 평균과 표준편차에 의해 모양 결정. 평균을 중심으로 종모양의 분포
- 표준 정규 분포 : 평균 = 0, 표준편차 = 1인 정규 분포
- t분포 : 표준 정규 분포를 따르는 확률 변수가 표준편차를 알 수 없어 추정값을 사용하거나 표본의 크기가 작을 때 이용. 자유도에 따라 모양이 변함
- 카이제곱 분포 : 확률 변수들이 각각 표준 정규 분포를 따르고 서로 독립일 때 확률 변수의 제곱의 합의 분포
- F 분포 : 두 정규 모집단에서 추출된 표본으로부터 두 모집단의 분산에 대한 검정 시 사용

표본 분포와 통계량

- 표본 분포 : 추출된 표본(통계량)의 확률 분포. 모집단에서 일부분을 추출하여 표본을 만들고 추출된 표본을 이용하여 분포에 대한 추론을 수행함
- 통계량 : 표본집단의 특성값. 모평균을 추론하기 위해 표본평균을 활용함

중심극한정리

표본의 크기가 큰 경우에 표본평균의 분포는 모집단의 분포와 무관하게 정규 분포를 따름

점추정

- 모수를 하나의 값으로 추정하여 나타냄
- 모평균 추정을 위한 표본평균 값
- 모분산 추정을 위한 표본분산
- 모비율 추정을 위한 표본집단의 비율 등
- 추정량(Estimator) : 모수를 추정하기 위해 만들어진 표본 통계량
- 추정치(Estimate) : 주어진 관측값으로부터 계산된 통계량 값
- 표준오차 : 추정량의 정확도를 측정하는 도구. 추정량의 표준편차 이용

구간추정

- 신뢰구간 : 추정량의 분포를 이용해서 표본으로부터 모수값을 포함할 것으로 예상되는 구간
- 신뢰수준 : 신뢰구간이 모수를 포함할 확률

표본의 최소 크기

적정한 신뢰구간을 이용하여 표본의 크기를 구함. 일반적으로 모집단에 대한 분포의 가정이 없을 때 중심극한정리를 만족하도록 하기 위해서 표본의 크기는 30 이상이 되도록 함

추정량의 성질

- 불편성(비편향성) : 추정량의 기댓값과 모수의 실젯값이 같아야 함
- 효율성(유효성) : 추정량의 분산이 작아야 함
- 일치성 : 표본의 크기가 커질수록 추정량이 모수에 일치해야 함
- 충분성 : 동일한 표본으로부터 얻은 추정량이 모집단의 모수에 대한 정보를 더 많이 제공해야 함

(주)시대고시기획

가설 검정

- 모집단의 모수에 대한 추정값에 대한 검정
- 통계적 가설 : 표본의 특성을 나타내는 모수에 대한 주장
- 귀무가설 : 모집단의 모수에 대해 어떤 조건을 가정하여 설정된 가설(거짓이 명확히 규명될 때까지 참인 것으로 인정되는 주장)
- 대립가설 : 귀무가설의 반대되는 가설(모수에 차이가 있다는 것을 나타냄, 효과가 있다는 주장)

유의수준

- 유의수준(α) : 귀무가설이 참인데 참인 귀무가설을 기각하면서 생기는 오류(제1종 오류)
- 유의수준을 기준으로 기각과 채택을 결정함
- 유의확률(p) : 주어진 통계량에서 귀무가설을 기각할 수 있는 최소의 유의수준 값
- 검정 통계량 : 모집단의 부분집합인 표본으로부터 검정에 대한 결론을 내리고 귀무가설을 기각하거나 채택하는 결정을 내리는 데 활용되는 표본의 함수
- 채택역 : 귀무가설을 채택하는 검정 통계량의 영역
- 기각역 : 귀무가설을 기각하는 검정 통계량의 영역

가설 검정 절차

가설수립 → 유의수준 결정 → 검정 통계량 계산 → 기각역 설정 → $p \leq \alpha$이면 귀무가설 기각

제 3 과목 빅데이터 모델링

제 1 장 분석모형 설계

분석모형 선정

- 통계 분석 : 객관적인 근거에 기반을 두고 데이터 수집, 처리, 분류, 분석하여 의사결정 지원. 모집단에서 표본을 추출하고 추론 및 가설 검정 실시
- 데이터 마이닝 : 수학이나 통계적 기술을 활용하여 데이터 분석, 새로운 상관관계나 추세를 파악하고 예측 및 분류 등에 활용
- 데이터 유형, 변수, 속성을 파악하고 연구 목적에 맞게 데이터 분석모형 선정

(주)시대고시기획

빅데이터 분석 프로세스의 핵심 업무

적합한 분석모형 선정, 분석모형 적용, 성능 및 적합성 평가, 안정성 평가

빅데이터 분석 방법(분석대상과 분석방법의 유무에 따른 분류)

- 최적화(Optimization) : 목적함수, 제약조건 정의 후 문제해결
- 솔루션(Solution) : 분석대상은 알면서 분석방법을 모르는 경우 적용
- 통찰(Insights) : 분석대상이 명확하지 않은 경우 기존 분석 방식 활용
- 발견(Discovery) : 새로운 분석대상 도출, 정확도가 중요함

데이터 분석모형 구축 절차

요건정의 → 모델링 → 검증 및 테스트 → 적용 → 주기적 검토

데이터 분석모형 구축 시 고려사항

데이터 처리, 시각화, 공간분석, 탐색적 자료분석, 통계 분석, 데이터 마이닝, WBS수립, 결측치 및 이상치 처리 방법

소프트웨어 분석 방법론

- 폭포수 모델 : 체계적이고 순차적인 개발 접근 방법
- 나선형 모델 : 반복을 통한 점증적 개발 방법
- 프로토타입 모델 : 시스템 일부분을 구현한 후 다음 요구사항을 반영, 점진적 개발 방법

빅데이터 처리 시스템

- 대용량 데이터를 분산 병렬 처리하고 관리하는 시스템
- 빅데이터 수집 · 관리 · 유통 · 분석 과정 수행
- 주요 기능 : 데이터 검증, 실시간 배치 처리를 위한 프레임워크 제공, 데이터 품질관리 등
- 구축 절차 : 빅데이터 처리 환경 분석 → 빅데이터 처리 시스템 세부 계획 수립 → 기존 시스템 연계 고려 → 빅데이터 처리 환경 구축

빅데이터 저장 시스템

- 관계형 데이터베이스(Relational DBMS) : 주로 정형 데이터 유형의 데이터 저장
- NoSQL : 기존 RDBMS와 비교하여 상대적으로 제한이 덜한 데이터 모델 적용
- 하드웨어 : 마스터 노드(메모리 상에서 처리해야 할 작업이 많은 경우 고용량 메모리 요구)와 슬레이브 노드(파일 블록 저장, 작업 수행 노드)로 구분
- 소프트웨어 : 데이터 수집, 변환, 적재, 데이터 관리 및 분석용 소프트웨어로 구분

데이터 분석 도구

- 하둡(Hadoop) : 대용량의 데이터 분산 처리. 자바기반의 오픈소스 프레임워크, 아파치 재단 관리
- R : 오픈소스 프로그램. 통계 계산 및 데이터 마이닝, 시각화 지원
- MapReduce : 분산 병렬 컴퓨팅 환경에서 데이터 처리. 맵함수와 리듀스 함수 기반 데이터 병렬 처리, 구글 개발
- SPSS : 사회과학 자료 분석용으로 고안. 사용의 편리, 보편적으로 많이 사용
- SAS : 통계 전문가들이 주로 사용. 보고서 작성 기능 제공, 그래픽 기능 제공

(주)시대고시기획

텍스트 마이닝을 위한 텍스트 수집 도구

- Scraping : 크롤러와 달리 하나의 웹문서(웹사이트)에 대한 정보 수집
- Crawling : SNS, 뉴스, 웹정보 등 인터넷에서 제공되는 웹문서 정보 수집
- RSS : 웹기반 최신 정보 공유, XML 기반의 콘텐츠 배급 프로토콜 이용
- Open API : 데이터, 정보, 각종 서비스 등을 어디서나 쉽게 이용할 수 있는 개방형 API로 데이터 수집

데이터 분할

- 데이터 분석목적에 부합하는 데이터 분석모형과 모형 구축을 위한 데이터의 질이 중요하며, 분석모형의 성능을 개선하기 위하여 데이터를 훈련, 검증 및 평가검증 데이터세트로 분할함
- 훈련 데이터세트 : 가장 큰 데이터세트로 빅데이터 통계 모듈 구축을 위해 사용. 데이터 분석모형 개발을 위한 학습(훈련) 데이터
- 검증 데이터세트 : 모형을 비교하여 좋은 모형을 선택하기 위해 사용. 각 모형의 성과를 평가하기 위해 사용
- 평가검증 데이터세트 : 새로운 데이터를 이용하여 선택된 모형의 성능을 평가하기 위한 용도로 사용
- 과적합 : 제한된 훈련 데이터세트에 너무 과하게 특화되어 새로운 데이터에 대한 오차가 매우 커지는 현상

회귀 분석(Regression Analysis)

- 변수들 사이에 함수적인 관계를 알아보기 위해서 수행하는 통계적 기법으로 독립변수와 종속변수 사이의 함수식 유도. 독립변수들의 값을 이용해서 종속변수의 값을 예측
- 단순회귀 분석 : 독립변수와 종속변수가 각각 1개인 경우
- 다중회귀 분석 : 독립변수의 수가 2개 이상, 종속변수가 1개인 경우
- 결정계수(Coefficient of Determination) : 총변동 중에서 회귀식에 의하여 설명되는 변동의 비율로 회귀모형의 설명력 나타냄. 단순회귀 분석모형의 경우 결정계수의 값이 1에 가까울수록 점들이 직선 주위에 밀집되어 나타나게 되어 회귀에 의한 설명이 잘 됨을 뜻함
- 단순회귀 분석모형의 가정 : 선형성, 등분산성, 독립성, 정규성
- 독립변수 선택 방법 : 전진선택, 후진제거, 단계별선택, 일반적 회귀식 이용
- 절차 : 독립 및 종속변수 결정 → 선형 관계 확인 → 회귀계수 추정(최소제곱법) → 유의성 검정 → 독립변수별 회귀계수의 유의성 검정(분산 분석표 활용)
- 회귀 분석의 종류 : 단순, 다중, 다항, 비선형 회귀 분석 등

다중공선성(多重共線性, Multicollinearity)

회귀 분석을 실시할 경우 독립변수들 사이에 강한 상관관계가 나타나는 문제. 분산팽창지수를 구하여 독립변수들 사이의 상관관계 판정(분산팽창지수가 10 이상이면 독립변수 간에 상관관계 존재)

(주)시대고시기획

분산 분석(ANOVA ; Analysis of Variance)

세 개 이상의 집단 간 평균에 대한 검정을 위해 사용하는 기법으로 분산을 기반으로 하여 통계적인 평균을 비교. 집단 내 분산과 집단 간 분산비(F검정통계량)를 구하여 통계적인 차이가 있는지를 검정. 종속변수의 수가 1개인 경우 단일변량 분산 분석(독립변수가 1개인 경우 일원 분산 분석 2개인 경우 이원 분산 분석), 2개 이상인 경우 다변량 분산 분석 이용

로지스틱 회귀 분석(Logistic Regression)

- 독립변수와 종속변수 사이의 관계를 함수로 나타낼 때, 종속변수가 범주형으로 주어진 자료의 경우 새로운 자료가 어느 범주에 속하게 될지를 예측
- 로지스틱 회귀모형식 : 이항형 로지스틱 회귀모형을 위해 주로 시그모이드(Sigmoid) 함수 이용. 독립변수는 연속형 형태의 자료 종속변수는 (성공, 실패), (가능, 불가능), (합격, 불합격) 등의 범주(이항)형
- 의료, 통신, 데이터 마이닝 등의 분야에서 분류와 예측에 활용

의사결정나무(Decision Tree)

- 의사결정 구조를 나무 모형으로 나타내는 것으로 과거에 수집된 자료를 분석해서 이들 사이에 존재하는 패턴을 나타내며, 분류 모형에 주로 사용. 전체 자료를 몇 개의 소집단으로 분류하거나 예측을 수행하는 데 활용
- 트리 구조 형성 알고리즘 : CHAID(Chi-squared Automatic Interaction Detection, 이산형 목표변수의 경우 카이제곱, 연속형인 경우 F검정통계량을 이용하여 분리 구조 생성), CART(Classification and Regresstion Tree, Gini Index 이용), C4.5(Entropy Index 이용) 등 기업 부도 예측, 주가 상한가 종목 예측, 환율 예측, 경제 전망 등에 활용

인공신경망(Artificial Neural Network)

- 사람의 뇌 구조(Neuron)에 모티브를 얻어 인공 뉴런(노드)의 네트워크 구성, 다층 신경망 생성
- 초기 인공지능은 전문가시스템, 사례기반추론(과거 사례를 기반으로 새로운 사례의 결과 예측), 퍼지 이론 등을 이용한 문제해결에 초점
- 최근 컴퓨팅 속도가 빨라지고 빅데이터 분석 기술이 발전하면서 인공신경망을 이용한 문제해결(딥러닝 알고리즘 등)이 가능하게 됨
- 복잡한 분류, 비선형 및 수치예측 등에 활용

서포트벡터머신(Support Vector Machine)

- 서로 다른 분류에 속한 데이터들 사이의 간격(Margin)이 최대화되는 평면을 찾아 이를 기준으로 분류 결과를 찾아냄
- 텍스트 분류, 패턴인식, 다양한 분류 및 회귀에 주로 사용
- 선형분류뿐만 아니라 Kernel Trick(커널 트릭)이라 불리는 입력자료의 다차원 공간상으로의 Mapping 기법을 사용하여 비선형 분류에도 효율적으로 사용

(주)시대고시기획

연관성 분석(Association Analysis)

- 군집 분석을 통해 나누어진 클러스터를 대상으로 각 그룹에 대한 특성을 분석
- 연관관계 규칙의 측정지표 : 지지도(Support, 전체 거래 중에서 상품 A, B를 동시에 구매하는 거래 비율), 신뢰도(Confidence, 품목 A가 포함된 거래 중에서 품목 B를 포함하는 거래의 비율), 향상도(Lift, 품목 B를 구매한 고객 대비 품목 A를 구매한 후, 품목 B를 구매한 고객에 대한 비율)

군집 분석(Clustering Analysis)

- 개체들에 대한 사전 지식없이 유사도에 근거하여 군집을 구분함. 새로운 개체를 독립변수의 값을 가지고 예측(분류)
- 분류 방법 : 계층적 군집(가장 유사한 개체를 묶어 나가는 과정을 반복하여 원하는 개수의 군집 형성), K-평균 군집(군집안의 중심과 해당 군집의 각 객체 간 거리의 합이 최소화, 군집 간 분리는 각 군집의 중심 간의 거리 합이 최대화), 혼합분포 군집(군집을 몇 개의 보수로 표현하고 확률 분포를 도입하여 군집 수행), 자기조직화 지도(Self-Organizing Map, 다차원 데이터를 이해하기 쉬운 저차원의 뉴런으로 정렬하고 지도의 형태로 형상화) 등
- Dendrogram : 개체들이 결합되는 순서를 나타내는 Tree 형태의 구조
- Ward : 두 군집 간의 유사성을 두 군집이 합쳐졌을 때의 오차제곱합의 증가분에 기반해서 측정
- 군집 간 거리측정 방법(수치값을 가지는 데이터) : 민코프스키, 유클리디안, 맨해튼, 체비셰프 거리측정 등

범주형 자료분석(Categorical Data Analysis)

관측된 데이터가 몇 개의 범주로 분류되고 각 범주의 도수로 자료가 주어진 경우 적합도 검정, 동질성 검정, 독립성 검정 등의 방법(카이제곱 검정 통계량 이용)을 이용하여 범주형 자료를 분석함

다변량 분석(Multivariate Analysis)

- 일변량 통계 분석 : 단일 독립변수와 단일 종속변수 사이의 관계 파악
- 다변량 통계 분석 : 변수의 변동 요인을 알아보기 위해 많은 수의 요인 중 한 요인을 선택하여 선택된 요인과 변수와의 관계 분석 시 요인들 간의 상호작용이 존재하고 변수 또는 요인들이 서로 영향을 줌. 이 경우 다변량 통계 분석 방법 적용
- 변수의 차원축소 방법 : 다변량 회귀 분석, 분산 분석, 주성분 분석, 요인 분석, 정준상관 분석 등
- 케이스의 차원축소 방법 : 군집 분석, 판별 분석, 다차원 척도법 등
- 요인 분석 : 많은 변수가 상호 연관성을 가지고 소수의 요인으로 분석되는 경우 해당되는 요인을 찾아서 변수를 줄임
- 판별 분석 : 결과가 다르게 나타난 개체들의 집단 간의 유사성과 차이점을 기준으로 아직 결과를 알 수 없는 개체에 대한 결과 예측, 집단을 구별할 수 있는 설명변수(독립변수)를 통해 집단구분 함수식(판별함수)을 도출하고 이를 이용하여 소속 집단을 예측함
- 다차원 척도법 : 개체들의 특성을 측정하고 특성을 이용해 개체들 사이의 유사성과 비유사성을 측정하며 다차원 공간상에 점으로 표현함, 다차원 공간상에 유사성이 큰 대상들은 가깝게 유사성이 작은 대상들은 상대적으로 멀게 위치시킴

(주)시대고시기획

시계열 분석(Time Series Analysis)

- 시간의 경과에 따라 변동하는 변수를 관측하고 예측함. 오랫 동안의 변동을 통해 일정한 추세를 가지며 이를 이용해 미래 현상을 예측함, 과거를 통해 미래의 지속성 확인
- 시계열 자료의 패턴 : 추세, 계절성, 주기성, 자기상관, 백색잡음 등
- 예측기법 : 평균, 단순기법, 계절성 단순 기법, 표류기법, 잔차진단, 회귀모형, 최소제곱추정법, 회귀모형 평가 등
- 자기회귀모형(AR ; Autoregressive Model) : 현 시점의 자료를 p시점 전의 과거 자료로 설명
- 이동평균모형(MA ; Moving Average Model) : 현 시점의 자료를 유한 개의 백색잡음의 선형 결합으로 표현
- 자기회귀 누적이동평균모형 : ARIMA(Autoregressive Integrated Moving Average Model) 모형, 비정상 시계열 모형, 차분 및 변환을 통해 AR, MA, ARMA 모형 정상화

베이지안 기법(Bayesian Method)

- 관측된 데이터 정보에 주관적 확률에 근거한 사전분포를 이용하여 사후분포를 계산하고 사후분포를 통해 모수를 추정함
- 베이지안 이론의 핵심은 베이즈 정리이며 어떤 미지변수의 불확실성은 확률 분포로 표현되고 이는 과거의 경험에 기초한 주관적 사전지식과 현재의 데이터에 기반한 객관적 우도(Likelihood)의 곱으로 주어짐
- 베이지안 네트워크 : Belief Network, 방향성 비순환 그래프(Directed Acyclic Graph)
- 나이브 베이지안 : 측정 자료가 여러 가지 속성을 가지고 있을 때 해당 자료를 어느 속성에 넣어야 할지 결정. 주가 상승(하락) 예상 종목 분류, 문서 내용 분류, 스팸 메일 분류 등에 활용
- 은닉 마르코프 모델(Hidden Markov Model) : 시스템이 은닉된 상태과 관찰 가능한 결과의 두 요소로 이루어진 확률 모형, 음성인식 및 자연어 처리 등에 활용

딥러닝(Deep Learning)

- 머신러닝과 신경망의 한 분야로서 여러 개의 은닉층을 가진 심층 신경망(Deep Neural Network)을 기반으로 하는 학습 방법
- 심층 신경망의 종류 : CNN(Convolutional Neural Network), RNN(Recurrent Neural Network), RBM(Restricted Boltzmann Machine), DBN(Deep Belief Network), GAN(Generative Adversarial Network) 등
- 딥러닝 개발 환경 : Tensorflow, Caffe, Theano, Chainer, MXNet, Keras 등
- 영상인식, 음성인식 등의 패턴인식 분야에 주로 활용

비정형 데이터 분석(Unstructured Data Analysis)

- 유형이 불규칙하고 의미를 파악하기 모호해서 기존 컴퓨터 처리 방식의 적용이 어려운 경우 텍스트 마이닝, 오피니언 마이닝 및 웹 마이닝 등의 기법 활용
- 텍스트 마이닝 : 텍스트 분석 방법(비정형 텍스트로부터 유용한 정보 추출). 텍스트에 대한 형태소 분석, 불용어 처리를 통한 키워드 추출, 단어 및 문서관련 표현 정보 추출 등
- 오피니언 마이닝 : 상품평, 영화 감상평, 정치인에 대한 호감 등 사람들의 주관적, 감정적 의견 분석, 특정 주제에 보인 의견이 긍정, 부정, 중립인지 찾아냄. 선호도 판별 등
- 웹 마이닝 : 노드(웹사이트에서 한 개의 페이지처럼 보이는 정보 단위)와 연결 구조(링크, 서로 연결되어 있는 연결점) 분석, 하이퍼링크로부터 패턴을 찾거나 웹페이지의 구조 분석

앙상블 분석(Ensemble Analysis)

- 여러 분류 모형에 의한 결과를 종합하여 분류의 정확도를 높임. 새로운 자료에 대한 분류 예측값들의 가중 투표(Weighted Vote)를 이용한 분류 방법, 하나의 모델을 사용하는 것보다 여러 개의 모델을 조화롭게 학습시켜 그 모델들의 예측 결과들을 이용하여 더 정확한 예측값을 구할 수 있음
- 앙상블 학습법 : Bagging(Bootstrap Aggregation, 샘플을 여러 번 뽑아 각 모델을 학습하고 결과물을 집계함. 병렬학습), Boosting[모델 예측, 예측 결과에 따라 데이터 가중치 부여, 새로운 분류 규칙 생성(반복 수행)]
- 랜덤 포레스트(Random Forest) : Bagging에 랜덤 과정을 추가, 배깅의 개념과 속성(또는 변수)의 임의 선택(Random Selection)을 결합, 훈련과정에서 구성한 다수의 결정트리로부터 분류 또는 회귀 분석(평균값 예측 등) 결과 출력

비모수 통계

- 정규성 검정에서 정규 분포를 따르지 않거나 표본의 수가 10개 미만인 소규모인 경우 자료를 크기 순으로 배열하여 순위를 매긴 후 다음 순위의 합을 통해 차이를 서로 비교함
- 비모수 검정 : 모집단의 분포가 알려져 있지 않은 경우 관찰값이 실제 자료가 아닌 순위 등의 형태인 경우 수행
- 비모수 검정의 종류 : 부호검정, 윌콕슨 순위합 검정, 크루스칼왈리스 순위검정 등
- 런검정 : 표본의 독립성 검정

※Run : 동일한 관측값이 연속적으로 이어진 것

(주)시대고시기획

제 4 과목 빅데이터 결과 해석

제 1 장 분석모형 평가 및 개선

데이터 분석모형 평가지표

- 데이터 분석모형의 설계와 함께 이를 평가하기 위한 평가지표 수립
- 상관 분석모형의 경우 두 변수 사이의 선형적 관계를 평가하기 위해 상관계수 사용

머신러닝 모형의 평가지표

- 혼동행렬(Confusion Matrix) : 분류 목적의 머신러닝 분석모형 평가지표
- 오차비율, 정확도, 민감도, 특이도, 정밀도, 거짓 긍정률, 카파값, F-Messure 등 사용

(주)시대고시기획

ROC(Receiver Operating Curve) 곡선

- 머신러닝 성능평가 지표들 중 거짓긍정률(FP rate ; False Positive)과 참긍정률(TP rate ; True Positive)을 이용하여 표현한 곡선
- 데이터 분석모형 평가 결과 TP rate 값이 클수록, FP rate 값이 작을수록 성능이 우수함

데이터 분석모형 성능추적

예측신호의 추적신호(TS ; Tracking Signal)를 구하여 예측오차($e_i = y_i - \widehat{y_i}$)를 계속적으로 추적

데이터 분석모형 진단도구

- 데이터 프로파일링, 평가지표 활용 진단, 체크리스트, 오류 데이터 확인 방법 등 이용
- 진단절차 : 품질기준 선정, 품질이슈 조사, 데이터관리 문서 수집, 진단대상 중요도 평가, 진단대상 선정, 핵심 데이터 항목 정의, 데이터 프로파일링, 업무규칙 정의

Data Profiling

데이터 소스에 대해 일련의 데이터 검사 절차를 수행함으로써 데이터에 관한 중요한 정보와 통계치 수집, 데이터베이스에 있는 방대한 정보로부터 숨어있는 지식을 자동적으로 추출

교차검증

- 두 변수들 사이의 선형 정도(교차성)의 교차 타당성 검증, 카이제곱 검정통계량 이용
- 적합도 검정 : 관찰도수와 기대도수 사이의 적합도 여부 검정
- 독립성 검정 : 두 변수 사이에 관련성이 있는지를 알아봄
- 동일성 검정 : 모집단의 표본이 범주로 주어졌을 때 이들 각 모집단의 분포가 서로 동일한지를 검정

학습 데이터 기반 교차검증 방법

- 홀드아웃 교차검증(Hold-out Cross Validation) : 훈련 데이터세트를 이용하여 데이터 분석모형을 구축하고 시험 데이터세트를 이용하여 모형의 성능평가
- 다중 교차검증(k-fold Cross Validation) : 데이터세트를 훈련 데이터와 검증 데이터로 나누어 모델링. 성능평가를 k회 반복하며, 모든 k개 중첩에 대한 성능평가 결과들에 대한 평균치를 통해 최종적인 모델의 성능평가

모수 유의성 검정

- 모수에 대한 가설을 세우고 가설의 옳고 그름을 확률적으로 판정
- 가설 검정 절차 : 가설 설정 → 유의수준 결정 → 검정통계량 계산(유의확률) → 유의확률이 유의수준보다 작으면(또는 같거나) 귀무가설 기각

적합도 검정

- 모집단의 분포에 대한 가정이 옳은지를 실제 관측된 자료를 토대로 검정
- n개의 표본 자료를 K개의 범주로 분류하여 각 범주에 속하는 관찰도수와 귀무가설 하에서 주어진 확률 분포에 대해 각 범주에 속하는 기대도수들 간에 잘 맞는지(적합한지)를 검정, 카이제곱 검정 통계량 이용

(주)시대고시기획

과대적합(Overfitting)

제한된 학습 데이터세트(모델 훈련에 사용한 한정된 데이터)에 너무 과하게 특화되어 새로운 데이터에 대한 오차가 커지는 현상

미적합(Underfitting)

분석의 편의상 단순한 데이터 분석모형을 적용하여 오차가 커지는 현상. 예를 들어 곡선 형태의 학습 데이터를 단순하게 직선으로 예측하는 경우

데이터 준비 및 처리 단계에서의 매개변수 최적화

- 매개변수 : 독립변수와 종속변수 간에 직접적인 관련은 없으나 중간에서 매개자 역할을 하여 두 변수 간에 간접적인 영향을 맺도록 하는 변수
- 매개변수 최적화 : 데이터 준비 및 처리과정에서 데이터 최적화를 위한 구체적인 방법을 설정하고 적용함. 데이터 품질의 기본요소(정확성, 완전성, 적시성, 일시성) 검증, 데이터 품질기준을 상세화하고 하위 품질기준을 정의함

머신러닝에서의 매개변수 최적화

- 학습 데이터세트를 이용하여 최적의 매개변수 도출
- 예측오차 : 평균절대오차, 평균제곱오차, 평균제곱근오차, 표준오차 등 평가

변수 유형에 따른 데이터 분석모형

- 독립변수(연속형)–종속변수(연속형)의 경우 : 회귀 분석, 인공신경망, k–평균 군집화 등
- 독립변수(연속형)–종속변수(범주형)의 경우 : 로지스틱 회귀 분석, 판별 분석, k–평균 군집화 등

데이터 분석모형 선정 시 주요 고려사항

비즈니스 도메인 이슈, 결과물의 활용 형태, 데이터세트의 형태 및 양, 변수의 특성, 데이터 변환 및 전처리 과정에서 얻은 사전 데이터 이해 및 통찰력, 분석가의 경험 및 능숙도 등

머신러닝 기법 선정 시 가이드라인

- 배경이론이나 확률적 접근이 가능 : 로지스틱 회귀모형, 나이브 베이즈 기법
- 분류 결과는 중요하나 분류 확률값 자체는 상대적으로 덜 중요함 : 나이브 베이즈
- 분석 모델링에 엄격한 기준 존재, 결과 계수값 등에 유의성 검정 요구 : 로지스틱 회귀 분석
- 어떤 변수가 목표변수 분류에 중요한지 탐색, 목표변수 분류 규칙 도출 : 의사결정트리
- 결과 분류의 이유나 규칙 등에 대한 설명보다 예측의 정확도가 중요 : 인공신경망, 서포트벡터머신
- 모수적 접근이 아닌 데이터의 유사성 등에 근거한 데이터 분류 : k–최근접 이웃
- 기존에 수행한 분류 모델링의 성능이나 정확도 개선 : 랜덤 포레스트, 앙상블 분석

(주)시대고시기획

제2장 분석결과 해석 및 활용

데이터 시각화(Data Visualization)

- 다양하고 방대한 데이터를 탐색하는 가운데 데이터의 특징을 쉽고 빠르게 알 수 있도록 도와주며, 데이터에 감춰진 의미를 찾아내어 이를 논리적으로 이해하는 데 도움을 줌
- NCS의 정의 : 인간의 시지각 능력을 토대로 데이터에 대한 이해와 설득에 도움을 주기 위해 그림이나 도형 등의 그래픽 요소들을 이용하여 데이터를 묘사하고 표현하는 것
- 목적 : 정보전달 및 설득

데이터 분석결과 해석 방법

- 설명 : 전달하려는 메시지와 주요 분석결과 설명
- 탐색 : 데이터에 숨겨져 있는 관계와 패턴을 찾음
- 표현 : 데이터 분석결과에 대한 공감을 불러일으키기 위한 기능 제공

데이터 분석 및 결과 해석 과정(Colin)

데이터 수집 및 저장 → 데이터 예비처리 및 변형 → 그래픽 엔진을 이용한 시각화 → 시각 및 인지 프로세싱

(주)시대고시기획

분석결과의 스토리텔링

- 컴퓨터로 작업하기 전 대충의 아이디어를 종이나 보드에 그리는 스케치 작업
- 절차 : 사용자별 데이터세트 및 정보 정의 → 사용자 시나리오 작성 → 스토리보드 기획

스토리텔링 시각화 원칙(Edward Thufte)

시각적 비교 강화, 인과관계의 제시, 다차원 변수의 표시, 효과적 정보전달을 위한 범례 및 레이블 사용, 명확한 콘텐츠 전달, 공간적 순서 배치, 정량적 자료에 대한 양적 정보의 표현

데이터 분석결과의 이해

시간, 공간, 분포, 관계 및 비교 시각화 등

기업의 비즈니스 기여도 평가

- 데이터 분석결과가 비즈니스의 효율성(매출 증대, 비용 감소, 고객 증가 등) 향상에 어느 정도 기여했는지를 판단
- 분석결과 적용(기업) : 재무분석, 산업 분석, 프로세스 분석, 시스템 개발 분석, 신규 상품 및 서비스 개발, 스타트업 기업의 신규 사업 경제성 분석, 가치창출, 의사결정 등에 활용

데이터 시각화 프로세스

- 3단계 : 구조화 → 시각화 → 시각표현
- 7단계 : 획득 → 구조화 → 추출 → 마이닝 → 시각화 → 재정의 → 상호작용

데이터 시각화 기술

- 기하학, 아이콘 기반, 화소지향적, 위계적, 그래프, 하이브리드, 왜곡, 동적 인터랙션 기술 등
- 시각적 표현 : 크기, 색상, 위치, 네트워크, 시간, 다중표현 등
- 관계 표현 : 선, 지도, 다이어그램, 트리 등

데이터 시각화 방법

차트 통계 도구, 프로그래밍, 지도, 일러스트레이션, SPSS, 자동화 도구, 구글 제공 도구 등

시간 시각화

- 관측값이 시간적 순서(주로 시계열 데이터)를 가지는 경우, 주가, 매출액, 실업률, 환율 등, 관측시점들 사이의 간격(시차)이 표현 방법에 중요한 역할 담당
- 막대 그래프, 누적 막대 그래프, 점 그래프 등

공간 시각화

좌푯값을 가진 데이터의 경우 지도상에서 표현(직관적 시각화), 구글 및 네이버 등의 지도

분포 시각화

- 구분 단위로 분류, 세부 분류 등과 같은 가짓수의 경우 가능한 선택들, 샘플의 측정 범위에서의 분류 결과를 나타내기 위해 사용
- 파이 차트, 도넛 차트, 누적 막대 그래프 등

(주)시대고시기획

관계 시각화

- 서로 다른 변수들 사이의 관계를 시각적으로 표현. 하나의 변수가 다른 변수에 어떤 영향을 주는지에 대한 분석결과 해석
- Scatter Plot(산점도), 버블 차트 등

비교 시각화

- 비교 대상의 변수가 둘 이상인 경우 변숫값을 비교하며 변수들 사이의 관계 이해, 다양한 변수의 특징을 한 번에 비교함으로써 전체적인 정보 표현이 가능
- 체르노프 페이스, 스타 차트, 평행좌표 그래프, 히트맵 등

인포그래픽[Infographics(Information + Graphics)]

다량의 정보를 효율적으로 표현, 차트, 지도, 다이어그램, 로고, 일러스트레이터 등 이용

빅데이터 분석모형 구축 프로세스

데이터 수집 → 데이터 정제 → 분석모형 구축 → 예측 및 모형 업데이트 → 시각화 및 대시보드 구축

BI(Business Intelligence)

- 많은 데이터가 혼재되어 있는 상태에서 의사결정에 필요한 데이터를 정제하여 필요한 만큼 적절하게 제공하는 기법과 함께 데이터를 수집, 분석하여 이를 토대로 기업의 올바른 의사결정을 내릴 수 있도록 해 줌
- 분석결과 자동화 시스템 주요 기능 : 엔터프라이즈 레포팅, 통계 및 데이터 마이닝, 보고서 Alerting, Cube 분석(예측분석결과 제공), Adhoc 쿼리 작성 및 분석

머신러닝 기반의 데이터 분석모형 절차

비즈니스 이해 및 정의 → 데이터 수집 → 데이터 전처리와 탐색 → 데이터 모델 훈련 → 모델 성능평가 → 모델 성능향상 및 적용

데이터 분석결과 사용자 분류

- 내부 : 의사결정자, 관리자, 감독, 직원 등
- 외부 : 고객, 청중 및 개인 등

시각화 활용 목적 검토

- 사업적 요구사항, 기술적 요구사항, 시각화 품질 요건 검토
- 절차 : 사용자별 데이터세트 및 정보 기술 → 사용자 시나리오 작성 → 사업 및 기술적 요구사항 검토 → 품질요건 반영 → 스토리보드 기획 및 개발

(주)시대고시기획

분석결과 모니터링 및 문서화 시 주요 고려사항

- 문서화 : 구조화된 데이터 정렬, 그룹, 합계, 필터링, 형식화의 과정을 거쳐 최종적으로 사전에 정의된 양식에 구조화된 데이터를 처리하는 프로세스
- 최근 많은 보고서들이 모바일 기기에 표기되는 방식 제공
- 보고서 작성 : 읽기용(보고 받는 사람에게 좀 더 구체적인 자료 제공, 도표와 설명을 잘 배합하여 자세한 내용 구성)과 발표용(요약본, 그래프, 표 등 활용, 수치 시각화 표현, 한눈에 전체 내용 파악 및 이해하기 쉽게 구성)으로 구분
- 보고서 구성 : 서식 디자인, 목차 구성, 작성 기준 수립, 결과보고, 시사점 및 제언 등 작성

보고서 작성 원칙

독자 이해, 명확한 문장의 흐름, 객관성, 간결성, 표 및 그래프 활용

데이터 분석결과의 산출물

데이터분석 계획서, 데이터 전처리 및 변환 수행 절차, 훈련 및 예측 결과 비교, 비즈니스 기여도 평가 계량 자료, 데이터 분석용 스크립트 코드 및 주석 등, 데이터 분석 모델 유지보수 및 교육을 위한 가이드 및 매뉴얼, 효과검증[POC(Proof of Concept), 솔루션이나 접근 방법 등 개념 검증을 위해 업체들에게 요청하여 수행하는 작업], 프로젝트 수행 계획 및 결과 보고서, 시스템 연동 개발 시 개발 요건 정의서, 화면설계 정의서 등

데이터 분석결과 최적화 과정

분석목적에 따른 보고서 배포 → 산출물에 대한 문서화 → 모델 개선 결과의 현업 적용 최적화

머신러닝 기반의 데이터 분석모형 모니터링 절차

데이터 분석의 목적과 비즈니스 문제 이해 → 데이터 확보 및 수집 → 분석환경 구축 및 데이터 전처리 → 머신러닝 기법에 따른 모델 훈련 → 모델 성능평가 → 산출물 및 문서관리

데이터 분석결과 자동화 시스템

- OLTP(Online Transaction Processing, 온라인 트랜잭션 처리) : 데이터베이스에 데이터 저장 및 처리, 은행 창구 업무나 항공사 예약 등의 데이터 처리
- OLAP(Online Analytical Processing, 온라인 분석 처리) : 데이터웨어하우스에서 데이터 저장 및 처리, 사용자의 분석적 질의 처리(View 등) 솔루션을 이용하여 대량의 데이터를 실시간으로 정확하게 분석하고 예측

데이터 분석모형 리모델링 절차

데이터 수집 → 데이터 저장 → 데이터 처리 → 데이터 분석 → 분석결과 평가 → 사회물리적 환경 적용 → 피드백

데이터 분석모형 리모델링 운영 프로세스

운영계획 수립 → 시스템 구축 → 분석 및 운영

(주)시대고시기획

데이터 저장 시스템 운영 시 주요 고려사항

데이터베이스 용량, 장애 대응, 사용자 권한 설정, 시스템 및 데이터베이스 백업 및 복구 등

소프트웨어 운영 계획 수립 절차

저장관리 시스템 설치 및 운영계획 수립 → 데이터베이스 용량 계획 수립 → 관련 소프트웨어 운영계획 수립

데이터 분석모형 리모델링 후 분석결과 재활용 사례

효과검증(POC), 서비스 적용 및 구현, 반복적 피드백 등