1. DIKW 피라미드
   ① 데이터 Data : 존재형식을 불문하고 타 데이터와의 상관관계가 없는 가공하기 전의 순수한 수치나 기호
   ② 정보 Information : 데이터 가공 및 상관관계의 이해를 통해 패턴을 인식하고 그 의미를 부여하는 데이터
   ③ 지식 Knowledge : 상호 연결된 정보 패턴을 이해하여 이를 토대로 예측한 결과물
   ④ 지혜 Widsom : 근본 원리에 대한 깊은 이해를 바탕으로 도출되는 창의적 아이디어
2. 데이터는 다른 객체와의 상호관계일 때 가치를 갖는다.
   객관적 사실로서 개별 데이터는 중요하지 않다.
3. 데이터의 유형<구분 문제>
   ① 정성적 데이터 Qualitative data
      a) 언어, 문자 등 형태와 형식이 정해져 있지 않음
      b) 비정형 데이터 형태로 저장, 분석에 시간과 비용이 필요
      c) 숫자나 금액으로 환산할 수 없는 것, 설문 조사 주관식 응답, 트위터, 페이스북
   ② 정량적 데이터 Quantitative data
      a) 수치, 기호, 도형으로 표시, 데이터양이 증가하더라도 저장, 분석 용이
      b) 숫자나 금액으로 환산 가능한 것, 온도, 풍속, 강수량 등이 해당
   ③ 주관식 설문조사는 정성적 데이터지만, 비정형 데이터라고 하면 틀림
   ④ 객관식 설문문항은 수치로 처리가 가능하면 정량적 데이터 가능
4. 암묵지 vs 형식지
   ① 암묵지 : 학습과 체험을 통해 개인에게 습득되어 있지만, 겉으로 드러나지 않은 지식, 시행착오와 오랜 경험을 통해 개인에게 습득된 무형의 지식
      → 개인에게 체화되어 있으므로 외부에 표출되어 공유가 어려움
   ② 형식지 : 교과서, 매뉴얼, 비디오, DB와 같이 형상화된 지식을 의미, 유형의 대상이 있어서 지식의 전달과 공유가 쉬움
   ③ 암묵지와 형식지의 상호 작용
      a) 공통화 Socialization : 암묵지 지식 노하우를 다른 사람에게 알려줌
      b) 표출화 Externalization : 암묵지 지식 노하우를 책, 교본 형식으로 전환
      c) 연결화 Combination : 책, 교본에 자신이 알고 있는 새로운 지식을 추가
      d) 내면화 Internalization : 만들어진 책, 교본을 보고 다른 직원의 암묵적 지식을 습득함

5. DIKW 피라미드
   ① _____ : 존재형식을 불문하고 타 데이터와의 상관관계가 없는 가공하기 전의 순수한 수치나 기호
   ② _____ : 데이터 가공 및 상관관계의 이해를 통해 패턴을 인식하고 그 의미를 부여하는 데이터
   ③ _____ : 상호 연결된 정보 패턴을 이해하여 이를 토대로 예측한 결과물
   ④ _____ : 근본 원리에 대한 깊은 이해를 바탕으로 도출되는 창의적 아이디어
6. 데이터는 다른 객체와의 상호관계일 때 가치를 갖는다.
   객관적 사실로서 개별 데이터는 _____
7. 데이터의 유형<구분 문제>
   ① _____ data
      a) 언어, 문자 등 형태와 형식이 정해져 있지 않음
      b) _____ 데이터 형태로 저장, 분석에 시간과 비용이 필요
      c) 숫자나 금액으로 환산할 수 없는 것, 설문 조사 주관식 응답, 트위터, 페이스북
   ② _____ata
      a) 수치, 기호, 도형으로 표시, 데이터양이 증가하더라도 저장, 분석 용이
      b) 숫자나 금액으로 환산 가능한 것, 온도, 풍속, 강수량 등이 해당
   ③ 주관식 설문조사는 _____데이터지만, 비정형 데이터라고 하면 틀림
   ④ 객관식 설문문항은 수치로 처리가 가능하면 정량적 데이터 가능
8. 암묵지 vs 형식지
   ① _____ : 학습과 체험을 통해 개인에게 습득되어 있지만, 겉으로 드러나지 않은 지식, 시행착오와 오랜 경험을 통해 개인에게 습득된 무형의 지식
      → 개인에게 체화되어 있으므로 외부에 표출되어 공유가 어려움
   ② _____ : 교과서, 매뉴얼, 비디오, DB와 같이 형상화된 지식을 의미, 유형의 대상이 있어서 지식의 전달과 공유가 쉬움
   ③ 암묵지와 형식지의 상호 작용
      a) _____ Socialization : 암묵지 지식 노하우를 다른 사람에게 알려줌
      b) _____ Externalization : 암묵지 지식 노하우를 책, 교본 형식으로 전환
      c) _____ Combination : 책, 교본에 자신이 알고 있는 새로운 지식을 추가
      d) _____ Internalization : 만들어진 책, 교본을 보고 다른 직원의 암묵적 지식을 습득함

1. ERP : 전사적 자원 관리 Enterprise Resource Planning

조직의 회계, 구매, 프로젝트 관리, 리스트 관리 규정 준수 및 공급망 운영 같은 일상적인 비즈니스 활용을 관리하는 데 사용하는 소프트웨어 유형을 의미한다. 다양한 비즈니스 분야에서 생산, 구매, 재고, 주문, 공급자와의 거래, 고객서비스 제공 등 주요 프로세스 관리를 돕는 통합 어플리케이션이다.

2. SCM : 공급망 관리 Supply Chain Management (SCM과 CRM은 연동, 상호 밀접)

물류, 유통업체 등 유통공급망에 참여하는 모든 업체들이 협력을 바탕으로 정보기술(Information Technology)을 활용, 재고를 최적화하기 위한 솔루션

3. CRM : 고객 관계 관리 Customer Relationship Management

선별된 고객으로부터 수익을 창출하고 장기적인 고객 관계를 가능케 함으로써 보다 높은 이익을 창출할 수 있는 솔루션

4. 데이터웨어하우스 : Data Warehouse(데이터웨어하우스의 특징 출제)

기업의 의사결정을 지원할 수 있는 분석 정보를 제공하는 데이터베이스로 데이터의 주제 지향성, 통합성, 시계열성, 비휘발성을 특징으로 하는 데이터베이스

5. 데이터마트 : Datamart, 데이터웨어하우스 환경에서 정의된 접근 계층

데이터웨어하우스에서 데이터를 꺼내 특정 사용자에게 제공

6. DBMS에 관한 설명

① 우리나라는 주로 관계형 데이터베이스를 사용

② 응용 프로그램 개발 비용이 줄어듦, 데이터를 동시에 공유할 수 있다

③ 모든 데이터 문제를 완전히 해결할 수는 없음

④ 데이터베이스에 있는 모든 데이터가 분석 가능한 것은 아님

⑤ 단점 : 비용이 많이 들고, 백업과 회복방법이 복잡, 중앙 집중 관리로 인한 취약점

7. 관계형 데이터베이스관리시스템 RDBMS vs 객체지향 데이터베이스관리시스템 OODBMS

	RDBMS	OODBMS
데이터 타입	문자, 숫자, 날짜의 단순한 정보타입만 지원	사용자 정의 타입 및 비정형 복합 정보 타입 지원
주된 장점	오랜기간에 걸쳐 검증된 시스템 안정성과 대규모 정보처리 성능	복잡한 정보 구조의 모델링 가능
주된 단점	제한된 형태의 정보만 처리 가능 복잡한 정보 구조의 모델링이 어려움	기본적인 데이터 베이스 관리 기능에 있어서의 안정성 및 성능의 검증 미비

빅데이터 분석기사-1과목 빅데이터 분석기획 02

8. ____ :

조직의 회계, 구매, 프로젝트 관리, 리스트 관리 규정 준수 및 공급망 운영 같은 일상적인 비즈니스 활용을 관리하는 데 사용하는 소프트웨어 유형을 의미한다. 다양한 비즈니스 분야에서 생산, 구매, 재고, 주문, 공급자와의 거래, 고객서비스 제공 등 주요 프로세스 관리를 돕는 통합 어플리케이션이다.

9. ____ : _____

물류, 유통업체 등 유통공급망에 참여하는 모든 업체들이 협력을 바탕으로 정보기술(Information Technology)을 활용, 재고를 최적화하기 위한 솔루션

10. ____ :

선별된 고객으로부터 수익을 창출하고 장기적인 고객 관계를 가능케 함으로써 보다 높은 이익을 창출할 수 있는 솔루션

11. _____ : _____(_____의 특징 출제)

기업의 의사결정을 지원할 수 있는 분석 정보를 제공하는 데이터베이스로 데이터의 성, 성, 성, 성을 특징으로 하는 데이터베이스

12. _____ : , 데이터웨어하우스 환경에서 정의된 접근 계층

데이터웨어하우스에서 데이터를 꺼내 특정 사용자에게 제공

13. DBMS에 관한 설명

① 우리나라는 주로 ____데이터베이스를 사용

② 응용 프로그램 개발 비용이 줄어듦, 데이터를 동시에 공유할 수 있다

③ 모든 데이터 문제를 완전히 해결할 수는 없음

④ 데이터베이스에 있는 모든 데이터가 분석 가능한 것은 아님

⑤ 단점 : 비용이 많이 들고,____과 방법이 복잡함, 관리로 인한 취약점

14. _____ 데이터베이스관리시스템 RDBMS vs _____ 데이터베이스관리시스템 OODBMS

	RDBMS	OODBMS
데이터 타입	____, __, 의 단순한 정보타입만 지원	_____ 타입 및 _____타입 지원
주된 장점	오랜기간에 걸쳐 검증된 시스템 안정성과 _____보처리 성능	_____의 모델링 가능
주된 단점	_____의 정보만 처리 가능 복잡한 정보 구조의 모델링이 어려움	기본적인 데이터 베이스 관리 기능에 있어서의 ____ 및 __의 검증 미비

1. Database : 상호 연관된 다수의 콘텐츠를 정보 처리 및 정보통신 기기에 의하여 체계적으로 수집/축적하여 다양한 용도와 방법으로 이용할 수 있도록 정리한 정보의 집합체

2. DBMS : 사용자와 데이터베이스 사이에서 사용자의 요구에 따라 정보를 처리해주고 데이터베이스를 관리해주는 소프트웨어

3. DBMS 발전과정

① 1세대 : 네트워크 DBMS, 계층 DBMS, 복잡하고 변경이 어려움

② 2세대 : 관계 Relation DBMS, 데이터베이스를 테이블 형태로 구성
Oracle, Access, My SQL

③ 3세대

a) 객체 지향 Objected DBMS
멀티미디어의 확산으로 관계형 데이터 모델 표현하기 어려움,
같은 행위를 갖는 객체는 한 클래스에 속하며, 클래스 연산을 나타내기 위해 메소드 함수 정의

b) 객체 관계형 모델 ORDBMS : 관계형 모델 + 객체 지향형 모델의 장점

④ 4세대 : NoSQL DBMS, 비정형 데이터를 저장하고 처리

⑤ SQL과 NoSQL의 특징 출제

	SQL 데이터베이스(관계형)	NoSQL 데이터베이스
데이터 모델	데이터를 행과 열로 구성된 테이블로 정형화	키-값, 문서, 그래프 등 성능과 규모 확장에 최적화된 다양한 데이터 모델 제공
최적의 워크로드	일관성이 뛰어난 온라인 트랜잭션 프로세싱(OLTP) 애플리케이션을 위해 설계되어 온라인 분석 프로세싱(OLAP)에 적합함	수많은 데이터 액세스 패턴에 맞도록 설계됨 NoSQL 검색 데이터베이스는 반정형 또는 비정형 데이터에서 분석을 위해 설계됨

4. OLTP(On-Line Transaction Processing) vs OLAP(On-Line Analytic Processing)

① OLTP : 네트워크 상의 여러 이용자가 실시간으로 데이터베이스의 데이터를 갱신하거나 조회하는 등의 단위작업을 처리하는 방식(은행 동시 입출금)

② OLAP : 정보 위주의 처리 분석, 의사결정에 활용할 수 있는 정보를 얻을 수 있게 해주는 기술(판매 추이, 구매성향 파악, 재무회계 분석 등을 프로세싱)

5. _____ : 상호 연관된 다수의 콘텐츠를 정보 처리 및 정보통신 기기에 의하여 체계적으로 수집/축적하여 다양한 용도와 방법으로 이용할 수 있도록 정리한 정보의 집합체

6. _____ : 사용자와 데이터베이스 사이에서 사용자의 요구에 따라 정보를 처리해주고 데이터베이스를 관리해주는 소프트웨어

7. DBMS 발전과정

① 1세대 : 네트워크 DBMS, 계층 DBMS, 복잡하고 변경이 어려움

② 2세대 : _____DBMS, 데이터베이스를 테이블 형태로 구성
Oracle, Access, My SQL

③ 3세대

a) 객체 지향 Objected DBMS
멀티미디어의 확산으로 관계형 데이터 모델 표현하기 어려움,
같은 행위를 갖는 객체는 한 클래스에 속하며, 클래스 연산을 나타내기 위해 메소드 함수 정의

b) 객체 관계형 모델 ORDBMS : 관계형 모델 + 객체 지향형 모델의 장점

④ 4세대 : _____ DBMS, 비정형 데이터를 저장하고 처리

⑤ SQL과 NoSQL의 특징 출제

	SQL 데이터베이스(관계형)	NoSQL 데이터베이스
데이터 모델	데이터를 행과 열로 구성된 ____로 정형화	키-값, 문서, 그래프 등 성능과 규모 확장에 최적화된 다양한 데이터 모델 제공
최적의 워크로드	일관성이 뛰어난 온라인 트랜잭션 프로세싱(___) 애플리케이션을 위해 설계되어 온라인 분석 프로세싱(___)에 적합함	수많은 데이터 액세스 패턴에 맞도록 설계됨 NoSQL 검색 데이터베이스는 _____또는 ____ 데이터에서 분석을 위해 설계됨

8. OLTP(On-Line Transaction Processing) vs OLAP(On-Line Analytic Processing)

① _____: 네트워크 상의 여러 이용자가 실시간으로 데이터베이스의 데이터를 갱신하거나 조회하는 등의 단위작업을 처리하는 방식(은행 동시 입출금)

② _____ : 정보 위주의 처리 분석, 의사결정에 활용할 수 있는 정보를 얻을 수 있게 해주는 기술(판매 추이, 구매성향 파악, 재무회계 분석 등을 프로세싱)

1. 데이터의 유형(특징 구분, 종류 출제)
   ① **정형** 데이터 : RDB, 스프레드 시트
   RDBMS의 **고정된 필드**에 저장, 데이터 스키마 지원
   ② **반정형** 데이터 : HTML, JSON, 웹 문서, 센서 데이터
   데이터 속성인 **메타데이터**를 가지며, 스토리지에 저장되는 데이터 파일
   ③ **비정형** 데이터 : 소셜 데이터, 문서 이미지, 오디오, 비디오
   형태와 구조가 복잡한 **이미지**, **동영상** 같은 **멀티미디어** 데이터
2. 데이터베이스 설계 순서
   ① **요구조건 분석**
   ② **개념**적 설계(**E-R** 모델)
   ③ **논리**적 설계(**테이블** 설계)
   ④ **물리**적 설계(데이터 **구조화**)
3. 데이터베이스의 특징
   ① **통합**된 데이터 **Integrated** data
   ② **저장**된 데이터 **Stored** data
   ③ **공용** 데이터 **Shared** data
   ④ **변화**되는 데이터 **Changed** data
4. 데이터베이스 특성
   ① 정보의 **축적** 및 **전달** 측면
   ② 정보 **이용** 측면
   ③ 정보 **관리** 측면
   ④ 정보**기술 발전** 측면
   ⑤ **경제**, **산업**적 측면
5. **RTE** : **실시간 기업 Real-Time Enterprise**
   최신 정보를 사용해 자사의 핵심 비즈니스 프로세스들의 관리와 실행 과정에서 생기는 지연 사태를 지속해서 제거함으로써 경쟁하는 기업
6. **BI** : **Business Intelligence**
   데이터 기반 의사결정을 돕는 도구, 기업 사용자들이 의사 결정을 위해 사용하는 데이터의 접근, 수집, 보관, 분석 등을 위한 응용 프로그램과 기술의 집합

7. 데이터의 유형(특징 구분, 종류 출제)
   ① ___ 데이터 : RDB, 스프레드 시트
   RDBMS의 에 저장, 데이터 스키마 지원
   ② _____ 데이터 : HTML, JSON, 웹 문서, 센서 데이터
   데이터 속성인 _____를 가지며, 스토리지에 저장되는 데이터 파일
   ③ _____데이터 : 소셜 데이터, 문서 이미지, 오디오, 비디오
   형태와 구조가 복잡한 , 같은 데이터
8. 데이터베이스 설계 순서
   ① _____
   ② ___적 설계(모델)
   ③ ___적 설계(설계)
   ④ ___적 설계(데이터)
9. 데이터베이스의 특징
   ① ___된 데이터 data
   ② ___된 데이터 data
   ③ ___ 데이터 data
   ④ ___되는 데이터 _____ data
10. 데이터베이스 특성
   ① 정보의 ___ 및 측면
   ② 정보 ___ 측면
   ③ 정보 _ 측면
   ④ 정보_____ 측면
   ⑤ ____ 적 측면
11. ___ :
   최신 정보를 사용해 자사의 핵심 비즈니스 프로세스들의 관리와 실행 과정에서 생기는 지연 사태를 지속해서 제거함으로써 경쟁하는 기업
12. __ :
   데이터 기반 의사결정을 돕는 도구, 기업 사용자들이 의사 결정을 위해 사용하는 데이터의 접근, 수집, 보관, 분석 등을 위한 응용 프로그램과 기술의 집합

1. BA : Business Analytics

소프트웨어로 데이터를 분석해 미래를 에측하거나(예측 분석), 특정 접근법을 적요했을 때 발생할 수 있는 일을 내다보는(처방적 분석) 기술의 도움을 받는 과정, 고급 분석 advanced analytics

2. EAI : Enterprise Architecture Integration

기업 애플리케이션 통합, 기업 내의 ERP(전사적자원관리), CRM(고객관계관리), SCM(공급망계획) 시스템이나 인트라넷 등의 시스템 간에 상호 연동이 가능하도록 통합하는 솔루션

3. EDW : Enterprise Data Warehouse

기존 DW(DataWarehouse)를 전사적으로 확장한 모델인 동시에 BPR과 CRM, BSC 같은 다양한 분석 애플리케이션들을 위한 원천이 됨

기업 리소스의 유기적 통합, 다원화된 관리 체계 정비, 데이터의 중복 방지 등을 위해 시스템을 재설계 하는 것

4. 블록체인 : Blockchain

데이터 분산 처리 기술, 네트워크에 참여하는 모든 사용자가 모든 거래내용 등의 데이터를 분산, 저장하는 기술. 블록들을 체인 형태로 묶는 것'

기존 거래 방식에서 데이터를 위/변조하기 위해 은행의 중앙 서버를 공격하면 가능했으나, 블록체인인 경우 사실상 해킹 불가능

빅데이터 분석기사-1과목 빅데이터 분석기획 05

5. ____:

소프트웨어로 데이터를 분석해 미래를 에측하거나(예측 분석), 특정 접근법을 적요했을 때 발생할 수 있는 일을 내다보는(처방적 분석) 기술의 도움을 받는 과정, 고급 분석 advanced analytics

6. ____:

기업 애플리케이션 통합, 기업 내의 ERP(전사적자원관리), CRM(고객관계관리), SCM(공급망계획) 시스템이나 인트라넷 등의 시스템 간에 상호 연동이 가능하도록 통합하는 솔루션

7. ____ : _____

기존 DW(DataWarehouse)를 전사적으로 확장한 모델인 동시에 BPR과 CRM, BSC 같은 다양한 분석 애플리케이션들을 위한 원천이 됨

기업 리소스의 유기적 통합, 다원화된 관리 체계 정비, 데이터의 중복 방지 등을 위해 시스템을 재설계 하는 것

8. _____ :

데이터 분산 처리 기술, 네트워크에 참여하는 모든 사용자가 모든 거래내용 등의 데이터를 분산, 저장하는 기술. 블록들을 체인 형태로 묶는 것'

기존 거래 방식에서 데이터를 위/변조하기 위해 은행의 중앙 서버를 공격하면 가능했으나, 블록체인인 경우 사실상 해킹 불가능

빅데이터 분석기사-1과목 빅데이터 분석기획 06

1. 빅데이터 양 측정을 위한 바이트 크기

   KB → MB → GB → TB(Tera) → PB(Peta) → EB(Exa) → ZB(Zeta) → YB(Yota)

2. 빅데이터 주요 특징

   ① 3V

      a) Volumn(크기)

      b) Variety(다양성)

      c) Velocity(속도)

   ② 4V

      a) Value(가치)

   ③ 7V

      a) Veracity(진실성)

      b) Validity(정확성)

      c) Volatility(휘발성)

3. 빅데이터의 활용 3요소 : 자원, 기술, 인력

4. 빅데이터가 만들어내는 변화

   ① 사전처리 → 사후처리

   ② 표본조사 → 전수조사

   ③ 질 → 양

   ④ 인과관계 → 상관관계

5. 빅데이터의 가치 산정이 어려운 이유

   ① 데이터의 활용 방식: 데이터를 언제, 어디서, 누가 활용할지 모름. 구글 검색결과 재활용

   ② 새로운 가치 창출 : 아마존 킨들 전자책 → 독서패턴 파악

   ③ 새로운 분석기술 발전 : SNS 비정형 데이터를 이용한 텍스트 마이닝 활용

6. 빅데이터의 위기요인과 통제 방안

   ① 사생활 침해 : 개인정보 사용자에게 책임을 지도록 함

   ② 책임 원칙의 훼손 : 책임 원칙 보강과 강화

   ③ 데이터의 오용 : 알고리즘에 대한 접근권 보장

   ④ 알고리즈미스트 : 알고리즘으로 부당한 피해를 입은 사람에 대한 구제 담당

빅데이터 분석기사-1과목 빅데이터 분석기획 06

7. 빅데이터 양 측정을 위한 바이트 크기

   KB → MB → GB → __(____) → __(____) → __(___) → __(____) → __(____)

8. 빅데이터 주요 특징

   ① 3V

      a) _____(___)

      b) _____(_____)

      c) _____(___)

   ② 4V

      a) ____(___)

   ③ 7V

      a) _____(_____)

      b) _____(_____)

      c) _____(_____)

9. 빅데이터의 활용 3요소 : ___, ___, ___

10. 빅데이터가 만들어내는 변화

   ① 사전처리 → _____

   ② 표본조사 → _____

   ③ 질 → _

   ④ 인과관계 → _____

11. 빅데이터의 가치 산정이 어려운 이유

   ① 데이터의 _____: 데이터를 언제, 어디서, 누가 활용할지 모름. 구글 검색결과 재활용

   ② 기존에 없던 ___의 창출 : 아마존 킨들 전자책 → 독서패턴 파악

   ③ 새로운 _____ : SNS 비정형 데이터를 이용한 텍스트 마이닝 활용

12. 빅데이터의 위기요인과 통제 방안

   ① _____ 침해 : 개인정보 사용자에게 책임을 지도록 함

   ② _____의 훼손 : 책임 원칙 보강과 강화

   ③ 데이터의 ___ : 알고리즘에 대한 접근권 보장

   ④ _____ : 알고리즘으로 부당한 피해를 입은 사람에 대한 구제 담당

1. 가트너의 비즈니스 분석 4가지 유형

① **묘사적 분석** Descriptive Analytics

과거의 비즈니스 활동수행 결과를 이해하고, 추세를 발견, 활동 성과 모니터

② **진단적 분석** Diagnostic Analytics

과거나 현재에 발생한 사건의 원인 분석, 데이터간 관계 발견과 원인 설명

③ **예측분석** Predictive Analytics

미래의 상황 예측 또는 알려지지 않은 결과의 가능성 파악

④ **처방분석** Prescritive Analytics

앞으로 무엇을 해야 비즈니스에 도움이 될 것인가 분석

제한된 자원을 효율적으로 할당하여 최상의 대안을 찾기 위해 활용

2. 데이터 산업의 진화

① 데이터 **처리**시대 : **EDPS** Electronic Data Processing System

② 데이터 **통합**시대 : **BPR** Business Process Reengineering, **DBMS**

CRM Customer Relationship Management, **ERP**

③ 데이터 **분석**시대 : **하둡**, **스파크** 등의 빅데이터 기술 등장

④ 데이터 **연결**시대 : **오픈 API**를 통해 많은 기업 및 정부 기관 등이 서비스와 데이터 공개

⑤ 데이터 **권리**시대 : **My Data**

3. 빅데이터 분석 조직의 구조

① **집중형** 구조

a) 분석 업무를 별도의 분석전담 조직에서 담당

b) 현업 업무부서의 분석업무와 **이중화/이원화** 가능성 높음

c) 부석 전담조직 내부에서 전사 분석과제의 전략적 중요도에 따라 우선순위를 정하여 추진 가능

② **기능중심**형 구조

a) 별도의 분석조식이 없고, 해당 업무 부서에서 분석 수행

b) 전사적관점 핵심 분석이 어렵고 **중복**된 분석업무 수행 우려

③ **분산**형 구조

a) 분석조직의 인력을 현업부서로 배치하여 분석업무 수행

b) 전사차원에서 분석과제의 우선순위를 선정해 수행 가능

c) 분석결과를 **신속하게 실무에 적용**할 수 있는 장점

4. 가트너의 비즈니스 분석 4가지 유형

① _____ Descriptive Analytics

과거의 비즈니스 활동수행 결과를 이해하고, 추세를 발견, 활동 성과 모니터

② _____ Diagnostic Analytics

과거나 현재에 발생한 사건의 원인 분석, 데이터간 관계 발견과 원인 설명

③ _____Predictive Analytics

미래의 상황 예측 또는 알려지지 않은 결과의 가능성 파악

④ _____ Prescritive Analytics

앞으로 무엇을 해야 비즈니스에 도움이 될 것인가 분석

제한된 자원을 효율적으로 할당하여 최상의 대안을 찾기 위해 활용

5. 데이터 산업의 진화

① 데이터 ___시대 : ____ Electronic Data Processing System

② 데이터 ___시대 : ___ Business Process Reengineering, _____

___ Customer Relationship Management, ___

③ 데이터 ___시대 : ___, _____ 등의 빅데이터 기술 등장

④ 데이터 ___시대 : _____를 통해 많은 기업 및 정부 기관 등이 서비스와 데이터 공개

⑤ 데이터 ___시대 : _____

6. 빅데이터 분석 조직의 구조

① _____ 구조

a) 분석 업무를 별도의 분석전담 조직에서 담당

b) 현업 업무부서의 분석업무와 _____/_____ 가능성 높음

c) 부석 전담조직 내부에서 전사 분석과제의 전략적 중요도에 따라 우선순위를 정하여 추진 가능

② _____형 구조

a) 별도의 분석조식이 없고, 해당 업무 부서에서 분석 수행

b) 전사적관점 핵심 분석이 어렵고 ___된 분석업무 수행 우려

③ ___형 구조

a) 분석조직의 인력을 현업부서로 배치하여 분석업무 수행

b) 전사차원에서 분석과제의 우선순위를 선정해 수행 가능

c) 분석결과를 _____할 수 있는 장점

빅데이터 분석기사-1과목 빅데이터 분석기획 08

1. 빅데이터 전문 인력

① 데이터 사이언티스트 : 데이터의 다각적 분석을 통해 인사이트를 도출하고 조직의 전략 방향을 제시하는 기획자이자 전략가

a) Hard Skill : 빅데이터에 대한 이론적 지식, 분석기술에 대한 숙련

b) Soft Skill : 통찰력 있는 분석, 설득력있는 전달, 다분야 간 협력

② 알고리즈미스트 : 알고리즘 코딩을 통해 빅데이터 알고리즘에 의해 부당하게 피해를 입은 사람을 구제하는 전문 인력

③ 인포그래픽 아티스트 : 대규모 데이터를 분석하여 결과를 차트, 지도, 다이어그림 등을 통해 시각화함으로써 이해하기 쉽게 전달

2. 분석 준비도

① 기업의 데이터 분석 도입의 수준을 파악하기 위한 진단방법

② 구성 : 분석업무파악, 인력 및 조직, 분석기법, 분석데이터, 분석문화, IT인프라

3. 분석 성숙도 모델

시스템 개발 업무 능력과 성숙도를 파악하기 위해 CMMI Capability Maturity Model Integration 모델을 기반으로 조직의 성숙도를 평가함

① 도입 : 분석을 시작하여 환경과 시스템 구축

② 활용 : 분석 결과를 실제 업무에 적용

③ 확산 : 전사 차원에서 분석을 관리하고 공유

④ 최적화 : 분석을 진화시켜 혁신 및 성과 향상에 기여

4. 데이터 거버넌스

① 전사 차원의 모든 데이터에 대하여 정책 및 지침, 표준화, 운영조직 및 책임 등의 표준화된 관리 체계를 수립하고 운영을 위한 프레임워크 및 저장소를 구축하는 것

② 기업에서 가치있는 양질의 데이터를 지속적으로 발굴 및 관리해 비즈니스 자산으로 활용하기 위한 데이터 통합관리체계

③ 마스터데이터, 메타데이터, 데이터 사전은 데이터 거버넌스의 중요한 관리대상

④ 데이터 거버넌스 체계 구축으로 데이터의 가용성, 유용성, 통합성, 보안성, 안전성 확보

⑤ 구성요소 : 원칙, 조직, 프로세스

5. 데이터 거버넌스 체계 요소

데이터 표준화, 데이터 관리 체계, 데이터 저장소 관리, 표준화 활동

빅데이터 분석기사-1과목 빅데이터 분석기획 08

6. 빅데이터 전문 인력

① _____ : 데이터의 다각적 분석을 통해 인사이트를 도출하고 조직의 전략 방향을 제시하는 기획자이자 전략가

a) _____ : 빅데이터에 대한 이론적 지식, 분석기술에 대한 숙련

b) _____ : 통찰력 있는 분석, 설득력있는 전달, 다분야 간 협력

② _____ : 알고리즘 코딩을 통해 빅데이터 알고리즘에 의해 부당하게 피해를 입은 사람을 구제하는 전문 인력

③ _____ 아티스트 : 대규모 데이터를 분석하여 결과를 차트, 지도, 다이어그림 등을 통해 시각화함으로써 이해하기 쉽게 전달

7. 분석 _____

① 기업의 데이터 분석 도입의 수준을 파악하기 위한 진단방법

② 구성 : 분석___파악, ___ 및 ___, 분석___, 분석_____ 분석___, _____

8. _____ 모델

시스템 개발 업무 능력과 성숙도를 파악하기 위해 ____ Capability Maturity Model Integration 모델을 기반으로 조직의 성숙도를 평가함

① ___ : 분석을 시작하여 환경과 시스템 구축

② ___ : 분석 결과를 실제 업무에 적용

③ ___ : 전사 차원에서 분석을 관리하고 공유

④ _____ : 분석을 진화시켜 혁신 및 성과 향상에 기여

9. _____

① 전사 차원의 모든 데이터에 대하여 정책 및 지침, 표준화, 운영조직 및 책임 등의 _____ _____를 수립하고 운영을 위한 프레임워크 및 저장소를 구축하는 것

② 기업에서 가치있는 양질의 데이터를 지속적으로 발굴 및 관리해 비즈니스 자산으로 활용하기 위한 데이터 통합관리체계

③ 마스터데이터, 메타데이터, 데이터 사전은 데이터 거버넌스의 중요한 관리대상

④ _____체계 구축으로 데이터의 가용성, 유용성, 통합성, 보안성, 안전성 확보

⑤ 구성요소 : ___, ___, _____

10. 데이터 거버넌스 체계 요소

데이터 _____, 데이터 _____, 데이터 _____, _____ 활동

1. 빅데이터 플랫폼 : 데이터의 수집, 저장, 처리, 분석, 시각화 제공
2. 하둡 Hadoop : 자바기반 프레임워크로 대용량의 데이터를 분산처리하는 기능을 제공
3. 하둡 에코 시스템(Hadoop Ecosystem)
   ① 하둡 프레임워크를 이루고 있는 다양한 서브 프로젝트들의 집합
   ② 비정형 데이터 수집
      a) 척와 Chuckwa : 분산된 각 서버에서 에이전트 실행 후 데이터를 받아 HDFS에 저장
      b) 플럼 Flume : 많은 양의 로그 데이터를 효율적으로 수집, 집계, 이동
      c) 스크라이브 Scribe : 대용량 실시간 로그 수집 기술
   ③ 정형 데이터 수집
      a) 스쿱 Sqoop : RDBMS에서 HDFS로 데이터를 수집 또는 반대로 데이터를 보내는 기술
      b) 히호 Hiho : JDBC 인터페이스를 지원하는 대용량 데이터 전송 솔루션
         하둡에서 SQL 지정 가능
   ④ 분산 데이터 저장 HDFS
      대용량 파일을 분산된 서버에 저장하고, 그 저장된 데이터를 빠르게 처리할 수 있게 하는 하둡 분산 파일 시스템, 네임 노드(마스터)와 데이터 노드(슬레이브)
   ⑤ 분산 데이터베이스 HBase : HDFS를 기반으로 구현된 컬럼 기반의 분산 데이터베이스
   ⑥ 분산 데이터 처리 맵리듀스
      대용량 데이터 세트를 분산 병렬 컴퓨팅에서 처리하거나 생성하기 위한 목적으로 만들어진 소프트웨어 프레임워크로 모든 데이터를 key-value 쌍으로 구성
   ⑦ 리소스 관리 Yarn : 자원 관리 플랫폼, 리소스 매니저와 노드 매니저로 구성
   ⑧ 인메모리 처리 아파치 스파크 : 대규모 데이터 분산처리시스템, 맵리듀스 입출력 보완
   ⑨ 데이터 가공
      a) 피그 Pig : 대용량 데이터 집합을 분석하기 위한 플랫폼, 피그라틴(자체 언어) 제공
      b) 하이브 : 하둡 기반 DW 솔루션, HiveQL 쿼리 제공
   ⑩ 데이터 마이닝 Mahout : 하둡 기반으로 데이터 마이닝 알고리즘을 구현한 오픈소스
   ⑪ 실시간 SQL 질의
      a) 임팔라 Impala : 하둡 기반의 실시간 SQL 질의 시스템
      b) 타조 Tajo : 하둡 기반의 ETL 기술을 이용해서 데이터 웨어하우스에 적재
   ⑫ 워크플로우 관리 Oozie 우지 : 하둡 작업을 관리하는 워크플로우 및 코디네이터 시스템
   ⑬ 분산 코디네이션 Zookeeper 주키퍼 : 서비스가 하나의 서버에만 집중되지 않도록 분산

4. 빅데이터 플랫폼 : 데이터의 ____, ____, ____, ____, _____ 제공
5. _____ : 자바기반 프레임워크로 대용량의 데이터를 분산처리하는 기능을 제공
6. 하둡 에코 시스템(Hadoop Ecosystem)
   ① 하둡 프레임워크를 이루고 있는 다양한 서브 프로젝트들의 집합
   ② 비정형 데이터 수집
      a) _____ : 분산된 각 서버에서 에이전트 실행 후 데이터를 받아 HDFS에 저장
      b) _____ : 많은 양의 로그 데이터를 효율적으로 수집, 집계, 이동
      c) _____ : 대용량 실시간 로그 수집 기술
   ③ 정형 데이터 수집
      a) _____ : RDBMS에서 HDFS로 데이터를 수집 또는 반대로 데이터를 보내는 기술
      b) _____ : JDBC 인터페이스를 지원하는 대용량 데이터 전송 솔루션
         하둡에서 SQL 지정 가능
   ④ 분산 데이터 저장 _____
      대용량 파일을 분산된 서버에 저장하고, 그 저장된 데이터를 빠르게 처리할 수 있게 하는 하둡 분산 파일 시스템, 네임 노드(마스터)와 데이터 노드(슬레이브)
   ⑤ 분산 데이터베이스 _____ : HDFS를 기반으로 구현된 컬럼 기반의 분산 데이터베이스
   ⑥ 분산 데이터 처리 _____
      대용량 데이터 세트를 분산 병렬 컴퓨팅에서 처리하거나 생성하기 위한 목적으로 만들어진 소프트웨어 프레임워크로 모든 데이터를 key-value 쌍으로 구성
   ⑦ 리소스 관리 ____ : 자원 관리 플랫폼, 리소스 매니저와 노드 매니저로 구성
   ⑧ 인메모리 처리 _____ : : 대규모 데이터 분산처리시스템, 맵리듀스 입출력 보완
   ⑨ 데이터 가공
      a) _____ : 대용량 데이터 집합을 분석하기 위한 플랫폼, 피그라틴(자체 언어) 제공
      b) _____ : 하둡 기반 DW 솔루션, HiveQL 쿼리 제공
   ⑩ 데이터 마이닝 _____: 하둡 기반으로 데이터 마이닝 알고리즘을 구현한 오픈소스
   ⑪ 실시간 SQL 질의
      a) _____ : 하둡 기반의 실시간 SQL 질의 시스템
      b) _____ : 하둡 기반의 ETL 기술을 이용해서 데이터 웨어하우스에 적재
   ⑫ 워크플로우 관리 _____ : 하둡 작업을 관리하는 워크플로우 및 코디네이터 시스템
   ⑬ 분산 코디네이션 _____ : 서비스가 하나의 서버에만 집중되지 않도록 분산

빅데이터 분석기사-1과목 빅데이터 분석기획 10

1. 빅데이터 플랫폼 프로세스

① **빅데이터 수집 및 정제**

a) 데이터 품질을 향상시키기 위해 데이터의 오류 및 불일치를 감지하고 제거

b) ETL 프로세스가 데이터 **추출**, **변환**, **로딩** 수행

② **빅데이터 저장 및 관리**

a) No SQL Not Only SQL

(i) 기존 RDBMS가 분산 환경에 적합하지 않으므로, 이를 극복하기 위해 개발

(ii) Key와 Value의 형태로 저장하고 빠르게 조회할 수 있는 자료구조를 제공하는 저장소, 대용량 데이터와 대규모 확장성 제공

a) **분산파일 시스템** : 네트워크로 연결된 여러 머신의 스토리지를 관리하는 파일 시스템

② **빅데이터 처리** : 수집 및 정제된 데이터를 효과적으로 분석하기 위한 처리, 병렬 및 분산처리

a) 기존 RDBMS는 데이터가 저장된 서버에서 데이터를 처리하는 방식으로, 비정형 데이터를 저장하기에 데이터의 크기가 너무 크고, 스토리지 확장에 비용이 많이 든다는 단점이 있음.

b) **하둡**은 여러 대의 서버에 데이터를 저장하고, 데이터가 저장된 각 서버에서 동시에 데이터를 처리하여 상상도 못했던 성과를 창출함

② **빅데이터 분석**

a) EFA : Exploratory Factor Analysis, **탐구 요인 분석**

데이터 간 상호관계를 파악하여 데이터를 분석하는 방법

b) CFA : Confirmatory Factor Analysis, **확인 요인 분석**

관찰된 변수들의 집합요소의 구조를 파악하기 위한 통계적 기법을 통해 데이터를 분석하는 방법

③ 빅데이터 시각화

2. **지도 학습** : Supervised Learning, **문제와 답**의 쌍으로 구성된 데이터들이 주어질 때, 새로운 문제를 풀 수 있는 함수 또는 패턴을 찾는 것

3. **비지도 학습** : Unsupervised Learning, **답이 없는(목표 변수) 문제**들만 있는 데이터들로부터 패턴을 추출하는 것

4. **강화학습** : Reinforcement Learning, 직접 답을 주지 않지만 경험을 통해 **기대 보상**이 최대가 되는 정책을 찾는 학습

빅데이터 분석기사-1과목 빅데이터 분석기획 10

2. 빅데이터 플랫폼 프로세스

② **빅데이터 수집 및 정제**

a) 데이터 품질을 향상시키기 위해 데이터의 오류 및 불일치를 감지하고 제거

b) ___ 프로세스가 데이터 ___, ___, ___ 수행

③ **빅데이터 저장 및 관리**

b) _____ ___ ___ ___

(iii) 기존 RDBMS가 분산 환경에 적합하지 않으므로, 이를 극복하기 위해 개발

(iv) Key와 Value의 형태로 저장하고 빠르게 조회할 수 있는 자료구조를 제공하는 저장소, 대용량 데이터와 대규모 확장성 제공

a) _____ : 네트워크로 연결된 여러 머신의 스토리지를 관리하는 파일 시스템

③ **빅데이터 처리** : 수집 및 정제된 데이터를 효과적으로 분석하기 위한 처리, 병렬 및 분산처리

a) 기존 _____는 데이터가 저장된 서버에서 데이터를 처리하는 방식으로, 비정형 데이터를 저장하기에 데이터의 크기가 너무 크고, 스토리지 확장에 비용이 많이 든다는 단점이 있음.

b) ___은 여러 대의 서버에 데이터를 저장하고, 데이터가 저장된 각 서버에서 동시에 데이터를 처리하여 상상도 못했던 성과를 창출함

② **빅데이터 분석**

a) ___ : _____, _____ **분석**

데이터 간 상호관계를 파악하여 데이터를 분석하는 방법

b) ___ :_____,_____ **분석**

관찰된 변수들의 집합요소의 구조를 파악하기 위한 통계적 기법을 통해 데이터를 분석하는 방법

③ 빅데이터 시각화

5. _____ : Supervised Learning, **문제와 답**의 쌍으로 구성된 데이터들이 주어질 때, 새로운 문제를 풀 수 있는 함수 또는 패턴을 찾는 것

6. _____ : Unsupervised Learning, **답이 없는(목표 변수) 문제**들만 있는 데이터들로부터 패턴을 추출하는 것

7. _____: Reinforcement Learning, 직접 답을 주지 않지만 경험을 통해 **기대 보상**이 최대가 되는 정책을 찾는 학습

빅데이터 분석기사-1과목 빅데이터 분석기획 11

1. 인공지능 경쟁력의 3요소 : 알고리즘, H/W 발달, Big Data
2. 인공지능 〉 머신러닝 〉 딥러닝
3. 인공지능 : 사람이 해야 할 일을 기계가 대신할 수 있는 모든 자동화
4. 머신러닝 : 명시적으로 규칙을 프로그래밍하지 않고 데이터로부터 의사결정을 위한 패턴을 기계가 스스로 학습, Data 제공 필수
5. 딥러닝 : 인공신경망 기반의 모델로, 비정형 데이터로부터 특징 추출 및 판단까지 기계가 한 번에 수행, 분류에 사용할 데이터를 스스로 학습 할 수 있음.
6. 전이 학습 Transfer Learning
   방대한 양의 데이터로 이미 학습한 인공지능을 유사하지만, 다른 분야에 적용하는 방법
7. 개인정보 위기 요인
   ① 사생활 침해 : 익명화 기술 발전 필요
   ② 책임 원칙 훼손 : 분석 대상이 되는 사람들이 예측 알고리즘의 희생양이 될 가능성
   ③ 데이터 오용 : 잘못된 지표 사용의 위험
8. 통제 방안
   ① 동의에서 책임으로 : 개인정보를 사용하는 사용자의 책임으로 해결
   ② 결과 기반 책임 원칙 고수 : 예측 자료에 의한 불이익을 당할 가능성을 최소화하는 장치 마련
   ③ 알고리즘 접근 허용 : 알고리즘에 대한 접근권을 제공하여 예측 알고리즘의 부당함을 반증할 수 있는 방법 명시해 공개할 것을 주문함 알고리즈미스트
9. 개인 정보 관련법
   ① 개인정보보호법
      a) 개인정보 판단 기준 명확화(살아있는 개인, 가명처리한 정보)
      b) 가명처리된 정보는 통계작성, 과학적 연구, 공익적 기록 보존 등의 목적으로 동의없이 처리 가능
      c) 당초 수집 목적과 합리적으로 관련된 범위내에서 정보 주체의 동의 없이 개인정보 이용, 제공 가능
   ② 정보통신망법 : 정보통신망법의 우선 적용
   ③ 신용정보법 : 신용정보의 오용, 남용으로부터 사생활의 비밀 등을 적절히 보호
   ④ 개인정보처리시 익명이 가능하면 익명이 원칙, **익명이 불가할 때 가명처리**

빅데이터 분석기사-1과목 빅데이터 분석기획 11

10. 인공지능 경쟁력의 3요소 : 알고리즘, H/W 발달, Big Data
11. 인공지능 _ 머신러닝 _ 딥러닝
12. _____ : 사람이 해야 할 일을 기계가 대신할 수 있는 모든 자동화
13. _____ : 명시적으로 규칙을 프로그래밍하지 않고 데이터로부터 의사결정을 위한 패턴을 기계가 스스로 학습, Data 제공 필수
14. _____ : 인공신경망 기반의 모델로, 비정형 데이터로부터 특징 추출 및 판단까지 기계가 한 번에 수행, 분류에 사용할 데이터를 스스로 학습 할 수 있음.
15. _____
    방대한 양의 데이터로 이미 학습한 인공지능을 유사하지만, 다른 분야에 적용하는 방법
16. 개인정보 위기 요인
    ① _____ : 익명화 기술 발전 필요
    ② _____ : 분석 대상이 되는 사람들이 예측 알고리즘의 희생양이 될 가능성
    ③ _____ : 잘못된 지표 사용의 위험
17. 통제 방안
    ① ___에서 ___으로 : 개인정보를 사용하는 사용자의 책임으로 해결
    ② _____ 원칙 고수 : 예측 자료에 의한 불이익을 당할 가능성을 최소화하는 장치 마련
    ③ _____ 접근 허용 : 알고리즘에 대한 접근권을 제공하여 예측 알고리즘의 부당함을 반증할 수 있는 방법 명시해 공개할 것을 주문함 알고리즈미스트
18. 개인 정보 관련법
    ① _____
       a) 개인정보 판단 기준 명확화(살아있는 개인, ___처리한 정보)
       b) ___처리된 정보는 통계작성, 과학적 연구, 공익적 기록 보존 등의 목적으로 동의없이 처리 가능
       c) 당초 수집 목적과 합리적으로 관련된 범위내에서 정보 주체의 동의 없이 개인정보 이용, 제공 가능
    ② _____ : 정보통신망법의 우선 적용
    ③ _____ : 신용정보의 오용, 남용으로부터 사생활의 비밀 등을 적절히 보호
    ④ 개인정보처리시 익명이 가능하면 ___이 원칙, **___이 불가할 때 가명처리**

1. 데이터분석 계획 - **분석 로드맵** 설정

분석대상이 되는 과제를 도출하고 우선순위를 평가하여 단기적인 세부이행계획과 중/장기적인 로드맵을 작성

2. **분석 로드맵** 단계별 추진목표 및 과제

① **분석체계** 도입 : 분석 기회 발굴, 분석과제 정의, 로드맵 수립

② 분석**유효성** 검증 : 분석과제 수행, 성과검증, 분석아키텍처 설계

③ 분석**확산** 및 **고도화** : 분석과제 업무 프로세스 내재화, 검증결과 확산 활용시스템 구축 및 고도화

3. 분석 주제 유형

		분석의 대상(What)	
		Known	Un-Known
분석의 방법(How)	Known	최적화 Optimization	통찰 Insight
	Un-Known	솔루션 Solution	발견 Discoverly

① **Optimization 최적화**

분석 대상과 분석 방법을 모두 알 때 이를 이해하고 현 문제를 **최적화** 형태로 수행 가능

② **Solution 솔루션**

분석 대상은 알고 있지만, 분석 방법을 모를 때 **솔루션**을 찾아 분석 수행

③ **Insight 통찰**

분석 대상에 대해서는 명확히 알 수 없지만 분석 방법을 알고 있을 때 **인사이트** 도출

④ **Discovery 탐색**

분석 대상 및 방법 모두를 잘 알지 못하는 경우 **탐색**을 통해 분석 대상 자체를 새롭게 도출

4. 목표 시점별 분석 기획 방안

① **과제 중심적인 접근 방식** : 당면한 과제를 빠르게 해결

② **장기적인 마스터 플랜** : 지속적인 분석 내재화, 효율적 자원 배치 및 관리

5. 데이터분석 계획 - _____ 설정

분석대상이 되는 과제를 도출하고 우선순위를 평가하여 단기적인 세부이행계획과 중/장기적인 로드맵을 작성

6. _____ 단계별 추진목표 및 과제

① _____ 도입 : 분석 기회 발굴, 분석과제 정의, 로드맵 수립

② 분석_____ 검증 : 분석과제 수행, 성과검증, 분석아키텍처 설계

③ 분석___ 및 _____ : 분석과제 업무 프로세스 내재화, 검증결과 확산 활용시스템 구축 및 고도화

7. 분석 주제 유형

		분석의 대상(What)	
		Known	Un-Known
분석의 방법(How)	Known	_____ _____	___ _____
	Un-Known	_____ _____	___ _____

① _____

분석 대상과 분석 방법을 모두 알 때 이를 이해하고 현 문제를 _____ 형태로 수행 가능

② _____

분석 대상은 알고 있지만, 분석 방법을 모를 때 _____을 찾아 분석 수행

③ _____

분석 대상에 대해서는 명확히 알 수 없지만 분석 방법을 알고 있을 때 _____ 도출

④ _____

분석 대상 및 방법 모두를 잘 알지 못하는 경우 ___을 통해 분석 대상 자체를 새롭게 도출

8. 목표 시점별 분석 기획 방안

① _____**인 접근 방식** : 당면한 과제를 빠르게 해결

② **장기적인** _____ : 지속적인 분석 내재화, 효율적 자원 배치 및 관리

1. 분석 기획 시 고려사항

① 가용 데이터 : 분석을 위한 가용 데이터 확보, 데이터 유형 분석 필요

② 적절한 유즈케이스 탐색 : 분석을 통해 가치가 창출될 수 있는 적절한 활용 방안과 유즈케이스 탐색이 필요

③ 낮은 실행 장벽 : 분석 수행 시 발생하는 장애요소들에 대한 사전계획 수립 필요

2. 분석 마스터플랜 수립 프레임워크

ISP(정보전략계획) 방법론을 활용하되 데이터 분석 기획의 특성을 고려하여 수행하고 기업에서 필요한 데이터 분석 과제를 빠짐없이 도출한 후 과제의 우선순위를 결정하고 단기 및 중/장기로 나누어 계획을 수립

① 우선순위 고려요소

a) 전략적 중요도

b) 비즈니스 성과/ROI(Return On Investment) 투자 수익률

c) 실행 용이성

② 적용범위/방식 고려요소

a) 업무 내재화 적용 수준

b) 분석 데이터 적용 수준

c) 기술 적용 수준

③ ISP(Information Strategy Planning)

기업의 경영 목표달성에 필요한 전략적 주요정보를 포착하고, 주요정보를 지원하기 위한 전사적관점의 정보구조를 도출하며, 이를 수행하기 위한 전략 및 실행 계획을 수립하는 전사적인 종합정보 추진계획

④ ROI(투자 자본 수익률) 관점에서 보는 빅데이터의 4V

a) 투자 비용 요소(Investment)

(i) Volumne : 데이터의 규모/양

(ii) Variety : 데이터의 종류/유형

(iii) Velocity : 데이터 생성 속도/처리 속도

b) 비즈니스 효과

(i) Value : 분석 결과 활용 및 실행을 통한 비즈니스 가치

⑤ ROI 관점에서의 분석과제 우선순위 평가기준

a) 시급성 : Value (전략적 중요도, 목표가치)

b) 난이도 : Volume, Variety, Velocity (데이터 저장 비용, 분석 비용, 분석 수준)

2. 분석 기획 시 고려사항

⑥ _____ : 분석을 위한 가용 데이터 확보, 데이터 유형 분석 필요

⑦ 적절한 _____탐색 : 분석을 통해 가치가 창출될 수 있는 적절한 활용 방안과 유즈케이스 탐색이 필요

⑧ 낮은 _____ : 분석 수행 시 발생하는 장애요소들에 대한 사전계획 수립 필요

3. 분석 마스터플랜 수립 프레임워크

ISP(정보전략계획) 방법론을 활용하되 데이터 분석 기획의 특성을 고려하여 수행하고 기업에서 필요한 데이터 분석 과제를 빠짐없이 도출한 후 과제의 우선순위를 결정하고 단기 및 중/장기로 나누어 계획을 수립

① 우선순위 고려요소

a) _____ 중요도

b) _____/___(_____) _____

c) ____용이성

② 적용범위/방식 고려요소

a) _____ 적용 수준

b) _____적용 수준

c) ___ 적용 수준

③ _____

기업의 경영 목표달성에 필요한 전략적 주요정보를 포착하고, 주요정보를 지원하기 위한 전사적관점의 정보구조를 도출하며, 이를 수행하기 위한 전략 및 실행 계획을 수립하는 전사적인 종합정보 추진계획

④ ROI(투자 자본 수익률) 관점에서 보는 빅데이터의 4V

a) 투자 비용 요소(Investment)

(i) _____ : 데이터의 규모/양

(ii) _____ : 데이터의 종류/유형

(iii) _____ : 데이터 생성 속도/처리 속도

b) 비즈니스 효과

(i) _____ : 분석 결과 활용 및 실행을 통한 비즈니스 가치

⑤ ROI 관점에서의 분석과제 우선순위 평가기준

a) 시급성 : _____ (전략적 중요도, 목표가치)

b) 난이도 : _____, _____, _____ (데이터 저장 비용, 분석 비용, 분석 수준)

1. 포트폴리오 사분면 분석을 통한 과제 우선순위를 선정하는 기법

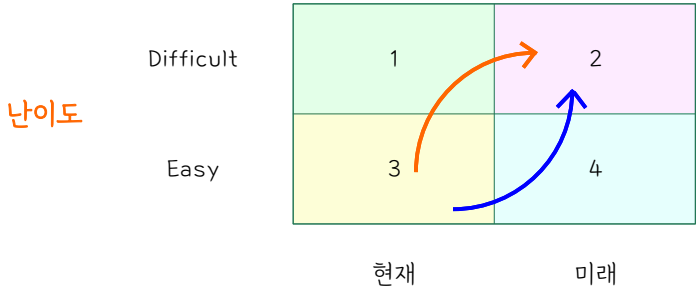

① 1 : 전략적 중요도가 높아 경영에 미치는 영향이 크므로 **현재** 시급하게 추진이 필요함.
난이도가 높아 현재 수준에서 과제를 바로 적용하기에 **어려움**

② 2 : 현재 시점에서는 전략적 중요도가 높지 않지만 **중장기적** 관점에서는 반드시 추진되어야 함
분석과제를 바로 적용하기에는 **난이도가 높음**

③ 3 : 전략적 중요도가 높아 **현재 시점**에 가치를 두고 있음
과제 추진의 난이도가 어렵지 않아 우선적으로 **바로 적용** 가능

④ 4 : 전략적 중요도가 높지 않아 **중장기적** 관점에서 과제 추진이 바람직함
과제를 바로 적용하는 것은 **어렵지 않음**

⑤ 우선 순위 기준을 **시급성**에 둔다면 : 3 → 4 → 2

⑥ 우선 순위 기준을 **난이도**에 둔다면 : 3 → 1 → 2

2. 분석 문제 정의

① **하향식 접근방법 Top Down Approach**
문제가 주어지고 이에 대한 해답을 찾기 위하여 각 과정이 체계적으로 단계화되어 수행하는 방식

② **상향식 접근방법 Bottom Up Approach**
a) 문제의 정의자체가 어려울 경우 데이터를 기반으로 문제의 재정의 및 해결방안을 탐색하고 이를 지속적으로 개선하는 방식
b) 데이터를 활용하여 생각하지 못했던 인사이트를 도출하고 시행착오를 통해 개선해가는 방식

3. 포트폴리오 사분면 분석을 통한 과제 우선순위를 선정하는 기법

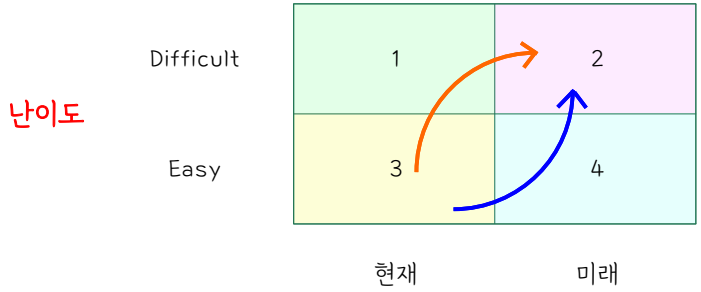

① 1 : 전략적 중요도가 높아 경영에 미치는 영향이 크므로 ___ 시급하게 추진이 필요함.
난이도가 높아 현재 수준에서 과제를 바로 적용하기에 _____

② 2 : 현재 시점에서는 전략적 중요도가 높지 않지만 _____**적** 관점에서는 반드시 추진되어야 함
분석과제를 바로 적용하기에는 **난이도가** ___

③ 3 : 전략적 중요도가 높아 _____**시점**에 가치를 두고 있음
과제 추진의 난이도가 어렵지 않아 우선적으로 ___ ___ 가능

④ 4 : 전략적 중요도가 높지 않아 _____ 관점에서 과제 추진이 바람직함
과제를 바로 적용하는 것은 _____ **않음**

⑤ 우선 순위 기준을 **시급성**에 둔다면 : _ → _ → _

⑥ 우선 순위 기준을 **난이도**에 둔다면 : _ → _ → _

4. 분석 문제 정의

① _____
문제가 주어지고 이에 대한 해답을 찾기 위하여 각 과정이 체계적으로 단계화되어 수행하는 방식

② _____
a) 문제의 정의자체가 어려울 경우 데이터를 기반으로 문제의 재정의 및 해결방안을 탐색하고 이를 지속적으로 개선하는 방식
b) 데이터를 활용하여 생각하지 못했던 인사이트를 도출하고 시행착오를 통해 개선해가는 방식

1. 분석문제 정의 1 - **하향식 접근방식(Top Down Approach)**

① **문제 탐색(Problem Discovery)** 단계

무엇(What)을 어떤 목적(Why)으로 수행해야 하는가

a) **비즈니스 모델 기반 문제 탐색**

(i) **업무**(재고량 최소화), **제품**(기능 개선), **고객**(고객 전화 대기 시간 최소화) 단위로 문제 발굴

(ii) **규제**와 **감사**(품질의 이상 징후 관리) 영역

(iii) **지원 인프라**(EDW 최적화, 인력 도출) 영역에 대한 기회를 추가로 도출

b) **분석 기회 발굴의 범위 확장**

(i) **거시적 관점 : 사회**, **기술**, **경제**, **정치**, **환경**(STEEP)적 측면

(ii) **경쟁자 확대 관점** : **경쟁자**, **신규** 진입자 및 **대체재** 제공업체 고려

(iii) **시장의 니즈 탐색** : **고객**, **채널**, **이해관계자**(주주, 투자자 등)

(iv) **역량의 재해석** : **내부역량**, **파트너**와 네트워크

c) **외부참조 모델기반 문제탐색**

(i) 유사, 동종 사례 **벤치마킹**을 통한 분석 기회 발굴

(ii) **산업별, 업무 서비스별 분석 테마 후보 그룹을 통해** Quick & Easy 방식으로 필요한 분석 기회가 뭉엇인지에 대한 아이디어를 얻고, 기업에 적용할 분석 테마 후보 목록을 워크숍 형태의 **브레인 스토밍**을 통해 빠르게 도출

d) **분석 유즈케이**스 : 문제에 대한 상세한 설명과 문제를 해결했을 때 발생하는 효과를 명시함으로써 향후 데이터 분석 문제로의 전환 및 적합성 평가에 활용

② **문제 정의(Problem Definition)** 단계

a) 식별된 **비즈니스 문제를 데이터의 문제로 변환**하여 정의하는 단계

b) 데이터 및 **기법(How)** 정의

③ **해결방안 탐색(Solution Search)** 단계

a) 기존 정보시스템의 단순한 보완으로 **분석이 가능한지** 고려

b) 엑셀 등의 간단한 도구로 분석이 가능한지 고려

c) 하둡 등 분산병렬처리를 활용한 빅데이터 분석 도구를 통해 보다 체계적이고 심도 있는 방안 고려

④ **타당성 검토(Feasibility Study)** 단계

a) **경제적** 타당도 : 비용대비 편익분석관점, 실질적 **비용 절감**, **추가적 매출**

b) **데이터** 및 **기술적** 타당도 : 데이터 존재 여부, 시스템 환경, 분석 역량

2. 분석문제 정의 1 - **하향식 접근방식(Top Down Approach)**

① _____(_____) 단계

무엇(What)을 어떤 목적(Why)으로 수행해야 하는가

a) **비즈니스 모델 기반 문제 탐색**

(i) ___(재고량 최소화), ___(기능 개선), ___(고객 전화 대기 시간 최소화) 단위로 문제 발굴

(ii) ___와 ___(품질의 이상 징후 관리) 영역

(iii) _____(EDW 최적화, 인력 도출) 영역에 대한 기회를 추가로 도출

b) **분석 기회 발굴의 범위 확장**

(i) _____ **관점 :** ___, ___, ___, ___, ___(_____)적 측면

(ii) _____ **관점** : **경쟁자**, ___ 진입자 및 _____ 제공업체 고려

(iii) **시장의** ___ **탐색** : ___, ___, _____(주주, 투자자 등)

(iv) ___**의 재해석** : **내부역량**, **파트너**와 네트워크

c) **외부참조 모델기반 문제탐색**

(i) 유사, 동종 사례 _____을 통한 분석 기회 발굴

(ii) **산업별, 업무 서비스별 분석 테마 후보 그룹을 통해** Quick & Easy 방식으로 필요한 분석 기회가 뭉엇인지에 대한 아이디어를 얻고, 기업에 적용할 분석 테마 후보 목록을 워크숍 형태의 **브레인 스토밍**을 통해 빠르게 도출

d) ___ _____ : 문제에 대한 상세한 설명과 문제를 해결했을 때 발생하는 효과를 명시함으로써 향후 데이터 분석 문제로의 전환 및 적합성 평가에 활용

② _____(_____) 단계

a) 식별된 **비즈니스 문제를 데이터의 문제로 변환**하여 정의하는 단계

b) 데이터 및 ___(___) 정의

③ _____(_____) 단계

a) 기존 정보시스템의 단순한 보완으로 **분석이** _____ 고려

b) 엑셀 등의 간단한 도구로 분석이 가능한지 고려

c) 하둡 등 분산병렬처리를 활용한 빅데이터 분석 도구를 통해 보다 체계적이고 심도 있는 방안 고려

④ _____(_____) 단계

a) _____ 타당도 : 비용대비 편익분석관점, 실질적 ___ **절감**, **추가적** ___

b) _____및 _____타당도 : 데이터 존재 여부, 시스템 환경, 분석 역량

1. 분석문제 정의 2 - **상향식 접근방식(Bottom Up Approach)**

① 문제의 정의 자체가 어려운 경우 데이터를 기반으로 문제의 재정의 및 해결 방안을 탐색하고 이를 지속적으로 개선하는 방식,

② 주로 **비지도** 학습 방법에 의해 수행

③ 기존 **하향식 접근법**은 해결 방안 도출에는 유효하지만, **새로운 문제를 탐색하기에 한계**가 있어 최근 복잡하고 다양한 환경에서 발생하는 문제에 적합하지 않을 수 있음

④ **Design Thinking** 접근법 : 전통적인 분석적 사고의 극복

⑤ **프로토타이핑** 접근법 : 하향식 접근방법에 대한 문제점 극복

a) 완벽하지는 않지만 신속하게 해결책이나 모형을 제시함으로써 이를 바탕으로 문제를 좀 더 명확하게 인식하고 필요한 데이터를 식별하고 구체화할 수 있게 하는 상향식 접근방식

b) **가설**의 생성 → **디자인 실험** → **Test** → **통찰 Insight** 도출 및 **가설 확인**

c) 분석요건 정의 후 분석을 통해 얻고자 하는 목표를 명화히 하기 위해 **분석목표(요건) 정의서** 수립

⑥ 상향식 접근방식 절차

a) 프로세스 **분류**

b) 프로세스 **흐름 분석**

c) **분석 요건 식별**

d) **분석 요건 정의**

2. **분석과제 정의서** : 분석별로 필요한 **소스 데이터**, **분석 방법**, 데이터 입수 및 **분석의 난이도**와 사유, **분석 수행 주기**, **분석결과 검증 책임자** 등을 기술

3. 분석 방법론

① 기업의 합리적 의사결정을 가로막는 장애 요소

a) **고정 관념**(Stereotype)

b) **편향된 생각**(Bias)

c) **프레이밍 효과 Framing Effect** : 문제의 표현 방식에 따라 동일한 사건이나 상황임에도 불구하고, 개인의 판단이나 선택이 달라질 수 있는 현상

② **방법론**은 학습과 경험으로 개인에게 체화되어, 겉으로는 드러나지 않는 **암묵지**가 **형식화**를 통해 문서나 매뉴얼처럼 외부로 표출되어 여러 사람이 공유할 수 있는 **형식지**로 나타나고, 이 과정을 짜임새 있게 조직화한 방법론을 개인의 학습과 경험에 활용하는 순환 과정으로 생성된다.

2. 분석문제 정의 2 - **상향식 접근방식(Bottom Up Approach)**

③ 문제의 정의 자체가 어려운 경우 데이터를 기반으로 문제의 재정의 및 해결 방안을 탐색하고 이를 지속적으로 개선하는 방식,

④ 주로 _____ 학습 방법에 의해 수행

⑤ 기존 _____ **접근법**은 해결 방안 도출에는 유효하지만, **새로운 문제를 탐색하기에 한계**가 있어 최근 복잡하고 다양한 환경에서 발생하는 문제에 적합하지 않을 수 있음

⑥ _____ 접근법 : 전통적인 분석적 사고의 극복

⑦ _____ 접근법 : 하향식 접근방법에 대한 문제점 극복

a) 완벽하지는 않지만 신속하게 해결책이나 모형을 제시함으로써 이를 바탕으로 문제를 좀 더 명확하게 인식하고 필요한 데이터를 식별하고 구체화할 수 있게 하는 상향식 접근방식

b) ___의 생성 → _____ → ___ → ___ _____ 도출 및 ____**확인**

c) 분석요건 정의 후 분석을 통해 얻고자 하는 목표를 명화히 하기 위해 _____ 수립

⑧ 상향식 접근방식 절차

a) 프로세스 ___

b) 프로세스 ___ ___

c) _____**식별**

d) _____ **정의**

4. **분석과제 정의서** : 분석별로 필요한 _____, **분석**____, 데이터 입수 및 **분석의** _____와 사유, **분석** _____, **분석결과 검증** _____ 등을 기술

5. 분석 방법론

① 기업의 합리적 의사결정을 가로막는 장애 요소

a) _____(_____)

b) _____(___)

c) _____ _____ : 문제의 표현 방식에 따라 동일한 사건이나 상황임에도 불구하고, 개인의 판단이나 선택이 달라질 수 있는 현상

② **방법론**은 학습과 경험으로 개인에게 체화되어, 겉으로는 드러나지 않는 _____가 _____를 통해 문서나 매뉴얼처럼 외부로 표출되어 여러 사람이 공유할 수 있는 _____로 나타나고, 이 과정을 짜임새 있게 조직화한 방법론을 개인의 학습과 경험에 활용하는 순환 과정으로 생성된다.

1. 빅데이터 분석방법론의 계층적 프로세스 모델 : **단계** → **태스크** → **스텝**(WBS)
2. **빅데이터 분석 방법 절차** Work Breakdown Structure : 작업 분할 구조도, 전체 업무 계획/할당
   ① **분석 기획** : 비즈니스 이해 및 범위 설정, 프로젝트 정의 및 계획 수립
   ② **데이터 준비** : 필요 데이터 정의, 데이터 스토어 설계, 데이터 수집 및 적합성 점검
   ③ **데이터 분석** : 분석용 데이터 준비, 텍스트 분석, 모델링, 모델 평가 및 검증
   ④ **시스템 구현** : 설계 및 구현, 시스템 테스트 및 운영
   ⑤ **평가 및 전개** : 모델 발전 계획, 프로젝트 평가 보고, 평가 및 전개
3. 빅데이터 분석 방법론 분석 환류

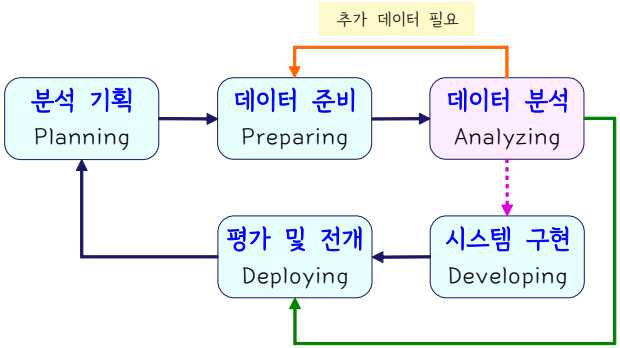

① **분석 기획**
   a) 비즈니스 도메인과 문제점을 인식하고 **분석 계획** 및 **프로젝트 수행계획** 수립
   b) 프로젝트 수행시 발생 가능한 **위험 상황에 대처하기 위한 계획**도 함께 수립
② **데이터 준비**
   a) 비즈니스 요구사항과 데이터 분석에 필요한 **원천 데이터 정의** 및 **준비**
   b) 필요한 데이터를 수집하고 수집한 데이터에 대한 **정합성** 점검
③ **데이터 분석**
   a) 원천 데이터를 분석용 데이터 셋으로 편성하고 다양한 분석 기법과 알고리즘을 이용하여 데이터를 분석
   b) **분석 모델을 설정**하고, **설정된 모델을 평가**하며, 검증된 모델을 이용하여 데이터 **분석 수행**
   c) 추가 데이터 확보가 필요한 경우 데이터 **준비** 단계로 **피드백**
④ **시스템 구현**
   a) 분석 기획에 맞는 모델을 도출하고 이를 운영 중인 가동 시스템에 적용하거나 시스템 개발을 위한 사전 검증으로 **프로토타입 시스템 구현**
   b) **프로토타입**을 통해 검증한 후 시스템 수정 및 보완을 반복하여 최종 시스템 구현
⑤ **평가 및 전개** : 프로젝트의 성과를 평가하고 정리, 모델의 발전 계획을 수립하여 차기 분석 기획으로 전달하고 프로젝트 종료

4. 빅데이터 분석방법론의 계층적 프로세스 모델 : ____ → _____ → ____(WBS)
5. **빅데이터 분석 방법 절차** Work Breakdown Structure : 작업 분할 구조도, 전체 업무 계획/할당
   ① _____ : 비즈니스 이해 및 범위 설정, 프로젝트 정의 및 계획 수립
   ② _____ : 필요 데이터 정의, 데이터 스토어 설계, 데이터 수집 및 적합성 점검
   ③ _____ _____: 분석용 데이터 준비, 텍스트 분석, 모델링, 모델 평가 및 검증
   ④ _____ ____ : 설계 및 구현, 시스템 테스트 및 운영
   ⑤ ____ 및 ____ : 모델 발전 계획, 프로젝트 평가 보고, 평가 및 전개
6. 빅데이터 분석 방법론 분석 환류

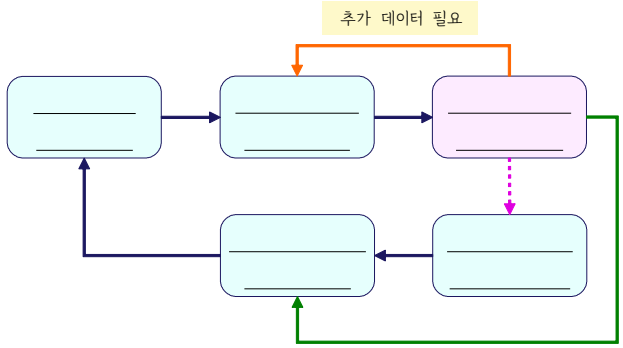

① _____
   a) 비즈니스 도메인과 문제점을 인식하고 **분석 계획** 및 **프로젝트 수행계획** 수립
   b) 프로젝트 수행시 발생 가능한 **위험 상황에 대처하기 위한 계획**도 함께 수립
② _____
   a) 비즈니스 요구사항과 데이터 분석에 필요한 **원천 데이터 정의** 및 **준비**
   b) 필요한 데이터를 수집하고 수집한 데이터에 대한 **정합성** 점검
③ _____
   a) 원천 데이터를 분석용 데이터 셋으로 편성하고 다양한 분석 기법과 알고리즘을 이용하여 데이터를 분석
   b) **분석 모델을 설정**하고, **설정된 모델을 평가**하며, 검증된 모델을 이용하여 데이터 **분석 수행**
   c) 추가 데이터 확보가 필요한 경우 데이터 ____ 단계로 **피드백**
④ _____
   a) 분석 기획에 맞는 모델을 도출하고 이를 운영 중인 가동 시스템에 적용하거나 시스템 개발을 위한 사전 검증으로 _____ **시스템 구현**
   b) _____을 통해 검증한 후 시스템 수정 및 보완을 반복하여 최종 시스템 구현
⑤ ____ **및** ____ : 프로젝트의 성과를 평가하고 정리, 모델의 발전 계획을 수립하여 차기 분석 기획으로 전달하고 프로젝트 종료

빅데이터 분석기사-1과목 빅데이터 분석기획 18

1. 방법론의 적용 업무의 특성에 따른 모델

① 폭포수 모델

a) 고전적 수명주기라고도 하는 전통적인 개발 모델

b) 요구분석, 설계, 구현, 테스트, 유지보수의 각 단계가 하향식으로 진행되며 병행되거나 거슬러 반복되지 않는 방법

c) 각 단계가 끝날 때마다 결과 확인 후 다음 단계로 진행

d) 관리가 용이하고 체계적인 문서화 가능

② 프로토타입 모델

a) 폭포수 모델의 단점을 보완하기 위해 점진적으로 개발해 나가는 접근 방식

b) 사용자의 기본 요구사항에 따른 프로토타입을 신속히 개발하여 사용자의 의견을 바탕으로 개선하고 보완해가는 모델

③ 나선형 모델

a) 진화적 프로토타입 모델의 태표적 형태

b) 사용자의 초기 요구분석 후 위험분석 단계를 거쳐 프로토타입을 개발하고, 사용자 평가 후 추가 또는 수정요구를 받아들여 다시 위험분석 후 2차 프로토타입 제작

c) 폭포수 모델과 프로토타입 모델의 장점에 위험분석 단계를 추가

d) 처음 시도하는 프로젝트에 적용이 용이하지만 관리 체계를 효과적으로 갖추지 못한 경우 복잡도가 상승하여 프로젝트 진행이 어려울 수 있음

2. SEMMA Sampling Exploration Modification Modeling Assessment 분석 방법론

① 기술 중심, 통계 중심의 방법론

② 주요 5단계

a) 샘플링 Sampling : 데이터 생성 및 준비, 통계적 추출, 조건 추출

b) 탐색 Exploration : 분석 데이터 탐색, 데이터 오류 검색, 그래프, 기초 통계 변수 유의성 및 상관 분석

c) 수정 Modification : 분석 데이터 수정 및 변환, 변수 생성, 선택, 변형 수량화, 표준화, 변환, 그룹화

d) 모델링 Modeling : 통계기법을 이용한 모델 구축, 패턴 발견, 모델링, 알고리즘 적용 신경망, 의사결정나무, 로지스틱 회귀

e) 검증 Assessment : 모델 평가 및 검증, 서로 다른 모델 비교, 보고서, 피드백

빅데이터 분석기사-1과목 빅데이터 분석기획 18

3. 방법론의 적용 업무의 특성에 따른 모델

① _____ 모델

a) 고전적 수명주기라고도 하는 전통적인 개발 모델

b) 요구분석, 설계, 구현, 테스트, 유지보수의 각 단계가 ___식으로 진행되며 병행되거나 거슬러 반복되지 않는 방법

c) 각 단계가 끝날 때마다 결과 확인 후 다음 단계로 진행

d) 관리가 용이하고 체계적인 _____ 가능

② _____ 모델

a) 폭포수 모델의 단점을 보완하기 위해 점진적으로 개발해 나가는 접근 방식

b) 사용자의 기본 요구사항에 따른 프로토타입을 신속히 개발하여 사용자의 의견을 바탕으로 개선하고 보완해가는 모델

③ _____ 모델

a) 진화적 프로토타입 모델의 태표적 형태

b) 사용자의 초기 요구분석 후 위험분석 단계를 거쳐 프로토타입을 개발하고, 사용자 평가 후 추가 또는 수정요구를 받아들여 다시 위험분석 후 2차 프로토타입 제작

c) _____ 모델과 _____ 모델의 장점에 _____ 단계를 추가

d) 처음 시도하는 프로젝트에 적용이 ___하지만 관리 체계를 효과적으로 갖추지 못한 경우 _____가 상승하여 프로젝트 진행이 어려울 수 있음

4. _____ _____ _____ _____ _____ _____ 분석 방법론

① 기술 중심, ___ 중심의 방법론

② 주요 5단계

a) _____ _____ : 데이터 생성 및 준비, 통계적 추출, 조건 추출

b) ___ _____ : 분석 데이터 탐색, 데이터 오류 검색, 그래프, 기초 통계 변수 유의성 및 상관 분석

c) ___ _____ : 분석 데이터 수정 및 변환, 변수 생성, 선택, 변형 수량화, 표준화, 변환, 그룹화

d) _____ _____ : 통계기법을 이용한 모델 구축, 패턴 발견, 모델링, 알고리즘 적용 신경망, 의사결정나무, 로지스틱 회귀

e) ___ _____ : 모델 평가 및 검증, 서로 다른 모델 비교, 보고서, 피드백

1. KDD Knowledge Discovery in Databases 분석 방법론

① 프로파일링 기술을 기반으로 데이터로부터 통계적 패턴이나 지식을 찾기 위해 활용할 수 있도록 체계적으로 정리한 데이터 마이닝 프로세스

② 데이터 마이닝, 기계학습, 인공지능, 패턴인식, 데이터 시각화 등에서 응용될 수 있는 구조

③ 분석 절차

a) 데이터셋 선택 Selection : 목표 데이터 구성, 필요시 추가 데이터 셋 생성

b) 데이터 전처리 Preprocessing : 잡음, 이상치, 결측치 식별하고 제거 또는 재처리

c) 데이터 변환 Transformation : 분석 목적에 맞게 변수 생성, 선택, 차원 축소
학습용 데이터와 검증용 데이터로 데이터 분리

d) 데이터 마이닝 Data Mining : 분석 목적에 맞는 데이터 마이닝 기법 선택,
실행 필요에 따라 데이터 전처리와 데이터 변환
프로세스 추가로 실행

e) 데이터 마이닝 결과/평가 Interpretation/Evaluation
데이터 마이닝 결과에 대한 해석과 평가, 분석 목적과의 일치성 확인
데이터 마이닝을 통해 발견한 지식을 업무에 활용하기 위한 방안 마련

2. CRISP-DM 분석 방법론

① 4레벨 구조

a) 단계 Phases : 최상위 레벨은 여러 단계로 구성됨, 일반화 태스크 포함

b) 일반화 태스크 Generic Tasks : 데이터 마이닝의 단일 프로세스 수행

c) 세분화 태스크 Specialized Tasks : 일반화 태스크를 구체적으로 실행

d) 프로세스 실행 Process Instances : 데이터 마이닝을 위한 구체적 실행

② CRISP-DM 분석 절차

단방향으로 구성되어 있지 않고 단계 간 피드백을 통하여 단계별 완성도를 높임

a) 업무 이해 : 프로젝트의 목적과 요구사항 이해, 업무 목적 파악, 목표 설계, 계획 수립

b) 데이터 이해 : 분석을 위한 데이터 수집 및 데이터 속성 이해, 탐색, 품질 확인
KDD 데이터셋 선택, 데이터 전처리

c) 데이터 준비 : 분석기법에 적합한 데이터 편성, 데이터셋 선택, 정제, 통합
KDD 데이터 변환

d) 모델링 : 모델링 기법과 알고리즘을 선택하고 파라미터 최적화, 모델 작성,
모델 평가, 모델링 결과를 테스트용 데이터셋으로 평가하여 과적합 문제 확인
KDD 데이터 마이닝

e) 평가 : 모델링 결과가 프로젝트 목적에 부합하는지 평가, 결과 수용 여부 판단
KDD 데이터 마이닝 결과 평가

f) 전개 : 모델을 실 업무에 적용하기 위한 계획 수립, 유지보수 계획 수립, 리뷰
KDD 데이터 마이닝 활용

3. ___ _____ 분석 방법론

① 프로파일링 기술을 기반으로 데이터로부터 통계적 패턴이나 지식을 찾기 위해 활용할 수 있도록 체계적으로 정리한 데이터 마이닝 프로세스

② 데이터 마이닝, 기계학습, 인공지능, 패턴인식, 데이터 시각화 등에서 응용될 수 있는 구조

③ 분석 절차

a) 데이터셋 _____ : 목표 데이터 구성, 필요시 추가 데이터 셋 생성

b) 데이터 _____ _____ : 잡음, 이상치, 결측치 식별하고 제거 또는 재처리

c) 데이터 ___ _____ : 분석 목적에 맞게 변수 생성, 선택, 차원 축소
학습용 데이터와 검증용 데이터로 데이터 분리

d) 데이터 _____ _____ : 분석 목적에 맞는 데이터 마이닝 기법 선택,
실행 필요에 따라 데이터 전처리와 데이터 변환
프로세스 추가로 실행

e) 데이터 마이닝 ___/___ _____/_____
데이터 마이닝 결과에 대한 해석과 평가, 분석 목적과의 일치성 확인
데이터 마이닝을 통해 발견한 지식을 업무에 활용하기 위한 방안 마련

4. _____ 분석 방법론

① 4레벨 구조

a) ___ _____ : 최상위 레벨은 여러 단계로 구성됨, 일반화 태스크 포함

b) _____ _____ _____ _____ : 데이터 마이닝의 단일 프로세스 수행

c) _____ _____ _____ _____ : 일반화 태스크를 구체적으로 실행

d) _____ ___ _____ _____ : 데이터 마이닝을 위한 구체적 실행

② _____ 분석 절차

단방향으로 구성되어 있지 않고 단계 간 피드백을 통하여 단계별 완성도를 높임

a) _____ : 프로젝트의 목적과 요구사항 이해, 업무 목적 파악, 목표 설계, 계획 수립

b) _____ : 분석을 위한 데이터 수집 및 데이터 속성 이해, 탐색, 품질 확인
KDD 데이터셋 ___, 데이터 _____

c) _____ : 분석기법에 적합한 데이터 편성, 데이터셋 선택, 정제, 통합
KDD 데이터 ___

d) _____ : 모델링 기법과 알고리즘을 선택하고 파라미터 최적화, 모델 작성,
모델 평가, 모델링 결과를 테스트용 데이터셋으로 평가하여 과적합 문제 확인
KDD 데이터 _____

e) ___ : 모델링 결과가 프로젝트 목적에 부합하는지 평가, 결과 수용 여부 판단
KDD 데이터 마이닝 _____

__ ___ : 모델을 실 업무에 적용하기 위한 계획 수립, 유지보수 계획 수립, 리뷰
KDD 데이터 마이닝 ___

빅데이터 분석기사-1과목 빅데이터 분석기획 20

1. 분석 작업 계획

① 데이터 확보 계획

a) 목표 정의(데이터 분석이 왜 필요한가)

(i) 구체적인 성과 목표 정의

(ii) 성과목표 달성 여부를 측정하기 위한 성과 지표 개발

b) 요구사항 도출(어떠한 데이터가 필요한가)

(i) 필요 데이터에 대한 확보 계획 설정

(ii) 데이터의 전처리, 정제 수준, 데이터의 저장 및 관리 형태 정의

(iii) 시스템 및 분석 도구에 대한 활용 가능성 파악

c) 예산안 수립(어떤 방법으로 데이터를 확보할 것인가)

(i) 데이터 확보에 필요한 비용, 관리 등에 필요한 HW, SW 운영 예산안

(ii) 인력 및 관리 예산을 비롯하여 외부 컨설팅 비용 고려

d) 구체적 계획 수립(어떻게 진행할 것인가)

(i) 인력 및 자원 활용에 대한 방안 마련

(ii) 프로젝트 범위 정의서(SOW), 빅데이터 분석 프로젝트 지시서, 소요비용 배분 계획 등을 중심으로 데이터 분석 작업 절차 고려

② 빅데이터 분석 데이터셋

분석 결과의 일반화 오류를 예방하기 위해 교차타당성검증 기법 적용하여

세 데이터셋을 혼합하여 빅데이터 분석 변수로 활용

a) Training Set : 모형 구축을 위해 학습에 사용되는 데이터 집합

b) Test Set : 구축된 모형의 성과 평가에 사용되는 데이터 집합

c) Validation Set : 최적 모형을 선택하기 위해 각 모형의 성과 평가에 사용

③ 분석 변수 유형에 따른 형성 알고리즘

a) 범주형(빈도수 기반) : 카이제곱 검정의 P값, 지니 지수, 엔트로피

b) 연속형(통계적 접근) : 분산 분석에서의 F-검정, 분산의 감소량

④ 연관성 분석

a) 명목, 서열 척도 : 교차 분석

b) 등간, 비율 척도 : 상관 분석

⑤ 공공데이터 포털에서 얻을 수 있는 데이터 종류

a) 파일 데이터(csv, xlsx, hwp 등)

b) Open API(xml, json 등)

c) 시각화 데이터(rdf, jpg, shp 등)

빅데이터 분석기사-1과목 빅데이터 분석기획 20

2. 분석 작업 계획

① 데이터 확보 계획

a) _____(데이터 분석이 왜 필요한가)

(i) 구체적인 성과 목표 정의

(ii) 성과목표 달성 여부를 측정하기 위한 성과 지표 개발

b) _____(어떠한 데이터가 필요한가)

(i) 필요 데이터에 대한 확보 계획 설정

(ii) 데이터의 전처리, 정제 수준, 데이터의 저장 및 관리 형태 정의

(iii) 시스템 및 분석 도구에 대한 활용 가능성 파악

c) _____(어떤 방법으로 데이터를 확보할 것인가)

(i) 데이터 확보에 필요한 비용, 관리 등에 필요한 HW, SW 운영 예산안

(ii) 인력 및 관리 예산을 비롯하여 외부 컨설팅 비용 고려

d) _____(어떻게 진행할 것인가)

(i) 인력 및 자원 활용에 대한 방안 마련

(ii) 프로젝트 범위 정의서(SOW), 빅데이터 분석 프로젝트 지시서, 소요비용 배분 계획 등을 중심으로 데이터 분석 작업 절차 고려

② 빅데이터 분석 데이터셋

분석 결과의 일반화 오류를 예방하기 위해 _____ 기법 적용하여

세 데이터셋을 혼합하여 빅데이터 분석 변수로 활용

a) _____ Set : 모형 구축을 위해 학습에 사용되는 데이터 집합

b) ____ Set : 구축된 모형의 성과 평가에 사용되는 데이터 집합

c) _____ Set : 최적 모형을 선택하기 위해 각 모형의 성과 평가에 사용

③ 분석 변수 유형에 따른 형성 알고리즘

a) _____(빈도수 기반) : 카이제곱 검정의 P값, 지니 지수, 엔트로피

b) _____(통계적 접근) : 분산 분석에서의 F-검정, 분산의 감소량

④ 연관성 분석

a) ____, ____ 척도 : 교차 분석

b) ____, ____ 척도 : 상관 분석

⑤ 공공데이터 포털에서 얻을 수 있는 데이터 종류

a) _____(csv, xlsx, hwp 등)

b) _____(xml, json 등)

c) _____(rdf, jpg, shp 등)

빅데이터 분석기사-1과목 빅데이터 분석기획 21

1. 빅데이터 수집 기법
   ① Log Aggregator : 웹 서버 로그, 웹로그, DB 로그 등 각종 서비스 로그 수집
   Scribe, Flume, Chukwa
   ② 크롤링 : SNS, 웹, 뉴스 등 인터넷상에서 제공되는 웹 문서에 대한 정보 수집
   ③ 스크래핑 : 웹사이트 내용 중 특정 정보만을 추출하고 추출과 관련된 모든 동작을 자동으로 수행하는 기술
   ④ FTP File Transfer Protocol : 인터넷 서버로부터 각종 파일 송수신, 파일 수집
   ⑤ Open API : 오픈된 정보로부터 API를 통해 실시간 데이터 수집
   ⑥ RSS : XML 기반의 콘텐츠 배급 프로토콜, 콘텐츠 수집
   ⑦ Streaming : 음성, 오디오, 비디오 등 멀티미디어 데이터를 실시간으로 송/수신
   ⑧ RDB Aggregator : 관계형 데이터베이스에서 정형 데이터를 수집하여 HDFS나 NoSQL에 저장하는 오픈 소스 기술
2. 정형 데이터 수집 기법 - RDB, 스프레드 시트(난이도 하)
   ① ETL : Extract 추출, Transform 변환, Load 적재, 수집한 데이터를 데이터 웨어하우스와 데이터 마트로 이동시키기 위한 추출, 변환, 적재 기술
   ② FTP : 파일 수집
   ③ API : Application Programming Interface, 운영 체제나 프로그래밍 언어가 제공하는 기능을 제어할 수 있게 만든 인터페이스
   시스템 간 연동을 통해 실시간으로 데이터 수신 기능 제공
   ④ 스쿱 Sqoop : 관계형 데이터베이스에서 HDFS로 데이터를 가져와 하둡 맵리듀스로 변환, 변환된 데이터를 다시 관계형 데이터베이스로 내보내는 기능
3. 반정형 데이터 수집 기법 - HTML, JSON, 웹 문서, 센서 데이터(난이도 중)
   ① Scribe : 페이스북에서 개발한 실시간 스트리밍 로그 데이터 수집 애플리케이션
   ② Flume : 분산 환경에서 대량의 로그 데이터를 효과적으로 수집하고 합친 후 전송
   신뢰성, 확장성, 운영가능성, 가용성
   ③ Chukwa : 분산된 노드들의 다양한 로그 데이터를 수집하고 수집된 데이터를 HDFS에 저장하고 분석(반정형, 비정형 모두 수집 가능)
4. 비정형 데이터 수집 기법 - 소셜 데이터, 문서 이미지, 오디오, 비디오(난이도 상)
   ① 스크래피 Scrapy : Python으로 작성된 오픈소스 웹 크롤링 프레임워크, 웹데이터 수집
   ② 아파치 카프카 Apache Kafka : 실시간 데이터 피드 관리, 스트리밍 데이터 처리
   ③ 크롤링 : 여러 웹페이지에서 html 코드, 문서 등의 데이터 수집 및 분류, 저장
5. 데이터 소스에 따른 수집 방법 : 내부 데이터(ETL 방식), 외부 데이터(크롤링)
6. 빅데이터 수집 시스템의 요건 : 확장성, 안정성, 유연성, 실시간성

빅데이터 분석기사-1과목 빅데이터 분석기획 21

7. 빅데이터 수집 기법
   ① ____Aggregator : 웹 서버 로그, 웹로그, DB 로그 등 각종 서비스 로그 수집
   Scribe, Flume, Chukwa
   ② _____ : SNS, 웹, 뉴스 등 인터넷상에서 제공되는 웹 문서에 대한 정보 수집
   ③ _____ : 웹사이트 내용 중 특정 정보만을 추출하고 추출과 관련된 모든 동작을 자동으로 수행하는 기술
   ④ ___ File Transfer Protocol : 인터넷 서버로부터 각종 파일 송수신, 파일 수집
   ⑤ _____ : 오픈된 정보로부터 API를 통해 실시간 데이터 수집
   ⑥ ___ : XML 기반의 콘텐츠 배급 프로토콜, 콘텐츠 수집
   ⑦ _____ : 음성, 오디오, 비디오 등 멀티미디어 데이터를 실시간으로 송/수신
   ⑧ ___ Aggregator : 관계형 데이터베이스에서 정형 데이터를 수집하여 HDFS나 NoSQL에 저장하는 오픈 소스 기술
8. 정형 데이터 수집 기법 - RDB, 스프레드 시트(난이도 __)
   ① ___ : Extract 추출, Transform 변환, Load 적재, 수집한 데이터를 데이터 웨어하우스와 데이터 마트로 이동시키기 위한 추출, 변환, 적재 기술
   ② ___ : 파일 수집
   ③ ___ : Application Programming Interface, 운영 체제나 프로그래밍 언어가 제공하는 기능을 제어할 수 있게 만든 인터페이스
   시스템 간 연동을 통해 실시간으로 데이터 수신 기능 제공
   ④ ___ _____ : 관계형 데이터베이스에서 HDFS로 데이터를 가져와 하둡 맵리듀스로 변환, 변환된 데이터를 다시 관계형 데이터베이스로 내보내는 기능
9. 반정형 데이터 수집 기법 - HTML, JSON, 웹 문서, 센서 데이터(난이도 __)
   ① _____ : 페이스북에서 개발한 실시간 스트리밍 로그 데이터 수집 애플리케이션
   ② _____ : 분산 환경에서 대량의 로그 데이터를 효과적으로 수집하고 합친 후 전송
   신뢰성, 확장성, 운영가능성, 가용성
   ③ _____ : 분산된 노드들의 다양한 로그 데이터를 수집하고 수집된 데이터를 HDFS에 저장하고 분석(반정형, 비정형 모두 수집 가능)
10. 비정형 데이터 수집 기법 - 소셜 데이터, 문서 이미지, 오디오, 비디오(난이도 __)
   ① _____ _____ : Python으로 작성된 오픈소스 웹 크롤링 프레임워크, 웹데이터 수집
   ② _____ _____ _____ _____ : 실시간 데이터 피드 관리, 스트리밍 데이터 처리
   ③ _____ : 여러 웹페이지에서 html 코드, 문서 등의 데이터 수집 및 분류, 저장
11. 데이터 소스에 따른 수집 방법 : 내부 데이터(___ 방식), 외부 데이터(_____)
12. 빅데이터 수집 시스템의 요건 : 확장성, 안정성, 유연성, 실시간성

1. 데이터의 구분
   ① **질적 자료** : 정성적 자료, 범주 또는 순서 형태의 속성을 가지는 자료
      a) **명목**자료(범주형 자료) : 순서 없고, 셀 수 있음. 사람의 피부색, 성별, 혈액형
      b) **순서**자료(순위 자료) : 제품의 품질, 등급, 순위, 선호도 조사
   ② **양적 자료** : 정량적 자료, 관측된 값이 수치 형태의 속성을 가지는 자료
      a) **구간** 자료(범위형 자료) : 온도, 시간, 구간 간격 동일, 수치간 차이가 의미를 가지는 자료
      절대적 원점이 없음
      b) **비율** 자료 : 무게와 같이 수치의 차이 뿐 아니라 비율 또한 의미를 가지는 자료
      절대적 원점이 존재함, 모든 사칙 연산 가능
2. 데이터 변환
   ① 데이터 **전처리** : 수집된 데이터를 **저장소에 적재하기 위해** 필터링, 유형 변환, 정제
   ② 데이터 **후처리** : 저장된 데이터를 **분석에 용이하도록** 변환, 통합, 축소
3. **데이터 변환 기술**
   ① **평활화 Smoothing** : **잡음을 제거**하기 위해 데이터 추세에서 벗어나는 값 변환
      구간화, 군집화 방법 이용
   ② **집계 Aggregation** : **데이터 요약**, 여러 표본을 하나로 줄이고, 함수로 일괄 변환
   ③ **일반화 Generalization** : 특정 구간에 분포하는 값으로 **스케일 변화**
      범용 데이터에 적합한 모델을 만드는 방법
   ④ **정규화 Normalization** : 데이터가 정**해진 구간 내에 포함되도록** 변환
      최소-최대 정규화, z-스코어 정규화, 소수 스케일링
   ⑤ **속성 생성 Attribute/Feature Construction** : 데이터 통합을 위해 새로운 속성 만들기
4. **데이터 비식별화**(2020년 8월)
   ① 프라이버시 침해 최소화 및 분석 기술의 효용을 극대화할 수 있는 개인정보 활용
   ② 데이터 내에 개인을 식별할 수 있는 정보가 있는 경우 이의 일부 또는 전부를
      삭제하거나 혹은 일부를 속성 정보로 대체하여 처리
   ③ 비식별화 기술
      a) **가명처리** : 다른 값으로 대체, 김은지, 25세, 서울 거주 → 홍길동, 20대, 서울 거주
      b) **총계처리** : **통계값**을 적용하여 개인 판단 불가하도록 처리
         정밀 분석이 어렵고 집계수량이 적을 경우 추론에 의해 식별 가능
         홍길동 175cm, 이현우 166cm, 박소연 168cm
         → 물리학과 키 합 509cm, 평균 169.6cm
      c) **데이터 삭제** : 개인정보 식별 가능한 **특정 값 삭제**, 주민번호 → 90년대 생, 남자
      d) **데이터 범주화** : 그룹의 **대푯값, 구간값**으로 변환 홍길동 35세 → 홍씨, 30대
      e) **데이터 마스킹** : 개인 식별 정보의 전체 또는 부분을 **공백, *, 노이즈 등으로 변환**

5. 데이터의 구분
   ① ____ **자료** : 정성적 자료, 범주 또는 순서 형태의 속성을 가지는 자료
      a) ____자료(범주형 자료) : 순서 없고, 셀 수 있음. 사람의 피부색, 성별, 혈액형
      b) ____자료(순위 자료) : 제품의 품질, 등급, 순위, 선호도 조사
   ② ____ **자료** : 정량적 자료, 관측된 값이 수치 형태의 속성을 가지는 자료
      a) ____자료(범위형 자료) : 온도, 시간, 구간 간격 동일, 수치간 차이가 의미를 가지는 자료
      절대적 원점이 없음
      b) ____자료 : 무게와 같이 수치의 차이 뿐 아니라 비율 또한 의미를 가지는 자료
      절대적 원점이 존재함, 모든 사칙 연산 가능
6. 데이터 변환
   ① 데이터 ____ : 수집된 데이터를 **저장소에 적재하기 위해** 필터링, 유형 변환, 정제
   ② 데이터 ____ : 저장된 데이터를 **분석에 용이하도록** 변환, 통합, 축소
7. **데이터 변환 기술**
   ① ____ ____ : **잡음을 제거**하기 위해 데이터 추세에서 벗어나는 값 변환
      구간화, 군집화 방법 이용
   ② ____ ____ : **데이터 요약**, 여러 표본을 하나로 줄이고, 함수로 일괄 변환
   ③ ____ ____ : 특정 구간에 분포하는 값으로 **스케일 변화**
      범용 데이터에 적합한 모델을 만드는 방법
   ④ ____ ____ : 데이터가 정**해진 구간 내에 포함되도록** 변환
      최소-최대 정규화, z-스코어 정규화, 소수 스케일링
   ⑤ ____ ____ : 데이터 통합을 위해 새로운 속성 만들기
8. **데이터 비식별화**(2020년 8월)
   ① 프라이버시 침해 최소화 및 분석 기술의 효용을 극대화할 수 있는 개인정보 활용
   ② 데이터 내에 개인을 식별할 수 있는 정보가 있는 경우 이의 일부 또는 전부를
      삭제하거나 혹은 일부를 속성 정보로 대체하여 처리
   ③ 비식별화 기술
      a) ____ : 다른 값으로 대체, 김은지, 25세, 서울 거주 → 홍길동, 20대, 서울 거주
      b) ____ : **통계값**을 적용하여 개인 판단 불가하도록 처리
         정밀 분석이 어렵고 집계수량이 적을 경우 추론에 의해 식별 가능
         홍길동 175cm, 이현우 166cm, 박소연 168cm
         → 물리학과 키 합 509cm, 평균 169.6cm
      c) ____ ____ : 개인정보 식별 가능한 **특정 값 삭제**, 주민번호 → 90년대 생, 남자
      d) ____ ____ : 그룹의 **대푯값, 구간값**으로 변환 홍길동 35세 → 홍씨, 30대
      e) ____ ____ : 개인 식별 정보의 전체 또는 부분을 **공백, *, 노이즈 등으로 변환**

1. 비식별 처리 기법(5회 기출)
   ① 가명처리 : 휴리스틱 가명화, 암호화, 교환 방법
   ② 총계처리 : 총계 처리, 부분 총계, 라운딩, 재배열
   ③ 데이터 삭제 : 식별자 삭제, 식별자 부분삭제, 레코드 삭제, 식별요소 전부 삭제
   ④ 데이터 범주화 : 랜덤 라운딩(수치를 올림/내림), 범위 방법
   제어 라운딩(라운딩 시 합이 일치하지 않는 단점 해결, 나이, 키, 소득 등)
   ⑤ 데이터 마스킹 : 임의 잡음 추가(섭동, 교란), 공백과 대체(치환)
2. 프라이버시 모델 기반 추론 방지 기술
   개인정보 추론 위험 정도를 확률적, 정량적으로 제한하는 방법론
   ① k-익명성 : 특정인에 대한 추론 가능여부를 검토, 확률수준 이상 비식별되도록 조치
   ② l-다양성 : k-익명성 취약점 보완, 민감한 정보의 다양성을 높여 추론 가능성 낮춤
   ③ t-근접성 : 민감한 정보의 분포를 낮추어 추론 가능성을 더욱 낮추는 기법
3. 고품질 데이터의 특징 : 관련성, 정확성, 시의성/정시성, 비교성/일관성, 접근성/명확성
4. 데이터 품질 관리의 중요성
   ① 데이터 분석결과의 신뢰성 확보
   ② 일원화된 프로세스
   ③ 데이터 활용도 향상
   ④ 양질의 데이터 확보
5. 데이터의 품질 기준
   ① 정형 데이터 : 완전성(누락 없음), 유일성(중복 불가), 유효성, 일관성, 정확성
   ② 비정형 데이터 : 신뢰성(오류 방지), 기능성, 효율성, 사용성, 이식성
6. 정형 데이터 품질 진단
   ① 데이터 프로파일링 기법을 통해 진단 가능
   ② 데이터 프로파일링 기법
      a) 데이터 현황 분석을 위한 자료 수집, 데이터의 통계 패턴 등을 수집하여 잠재적 오류 징후를 발견하는 방법
      b) 메타데이터 수집 및 분석, 칼럼 속성 분석, 누락값 분석, 허용값 분석
      c) 문자열 패턴 분석, 날짜 유형 분석, 주민번호 및 사업자 등록번호 유효성 분석
      d) 유일값 분석(유일 데이터의 중복 발생 여부), 구조 분석

7. 비식별 처리 기법(5회 기출)
   ① _____ : 휴리스틱 가명화, 암호화, 교환 방법
   ② ____처리 : 총계 처리, 부분 총계, 라운딩, 재배열
   ③ 데이터 ____ : 식별자 삭제, 식별자 부분삭제, 레코드 삭제, 식별요소 전부 삭제
   ④ 데이터 _____ : 랜덤 라운딩(수치를 올림/내림), 범위 방법
   제어 라운딩(라운딩 시 합이 일치하지 않는 단점 해결, 나이, 키, 소득 등)
   ⑤ 데이터 _____ : 임의 잡음 추가(섭동, 교란), 공백과 대체(치환)
8. 프라이버시 모델 기반 추론 방지 기술
   개인정보 추론 위험 정도를 확률적, 정량적으로 제한하는 방법론
   ① _____ : 특정인에 대한 추론 가능여부를 검토, 확률수준 이상 비식별되도록 조치
   ② _____ : k-익명성 취약점 보완, 민감한 정보의 다양성을 높여 추론 가능성 낮춤
   ③ _____ : 민감한 정보의 분포를 낮추어 추론 가능성을 더욱 낮추는 기법
9. 고품질 데이터의 특징 : 관련성, 정확성, 시의성/정시성, 비교성/일관성, 접근성/명확성
10. 데이터 품질 관리의 중요성
   ① 데이터 분석결과의 신뢰성 확보
   ② 일원화된 프로세스
   ③ 데이터 활용도 향상
   ④ 양질의 데이터 확보
11. 데이터의 품질 기준
   ① 정형 데이터 : _____(누락 없음), _____(중복 불가), _____, 일관성, 정확성
   ② 비정형 데이터 : _____(오류 방지), _____, _____ 사용성, 이식성
12. 정형 데이터 품질 진단
   ① _____ 기법을 통해 진단 가능
   ② _____ 기법
      a) 데이터 현황 분석을 위한 자료 수집, 데이터의 통계 패턴 등을 수집하여 잠재적 _____징후를 발견하는 방법
      b) 메타데이터 수집 및 분석, 칼럼 속성 분석, 누락값 분석, 허용값 분석
      c) 문자열 ___ 분석, 날짜 유형 분석, 주민번호 및 사업자 등록번호 유효성 분석
      d) _____분석(유일 데이터의 중복 발생 여부), 구조 분석

빅데이터 분석기사-2과목 빅데이터 탐색 01

1. 데이터 전처리 유형
   ① 데이터 정제 : 결측 데이터, 이상치 파악 및 제거하고 정합성이 맞도록 교정
   ② 데이터 통합 : 여러 개의 데이터베이스, 데이터 집합 또는 파일 통합
   ③ 데이터 축소 : 샘플링, 차원축소, 변수선택 및 추출을 통해 차원을 줄이는 작업
   ④ 데이터 변환 : 데이터를 정규화, 이산화, 파생변수 등으로 변환하는 작업
2. 데이터 정제 Data Cleaning
   ① 결측값 Missing Value
      a) 입력이 누락되어 값이 존재하지 않고 비어있는 값(NA, NULL, 99999, Unknown..)
      b) 결측값 대체 - 중위수, 평균값 등
   ② 노이즈 Noise
      a) 측정된 편수에서의 오류나 오차 값
      b) 오류나 오차 값에 의해 경향성 훼손 발생
      c) 데이터 평활화 기법 사용, 구간화, 회귀, 군집화
   ③ 이상값 Outlier
      a) 관측된 데이터 범주에서 일반적인 데이터 값의 범위를 벗어난 값
      b) 상한보다 높으면 상한값으로 대체, 하한보다 낮으면 하한값으로 대체
3. 데이터 결측값의 구분
   ① 완전 무작위 결측 MCAR Missing Completely at Random
      관측된 다른 변수와 아무런 연관 없이 발생한 경우(우연히 질문을 건너뜀)
      제거하거나 단순 무작위 표준추출을 통해 완벽한 데이터셋으로 만듦
   ② 무작위 결측 MAR Missing at Rnadom
      결측된 변수와는 관련이 없지만 다른 변수와 관련이 있는 경우
      여성이 체중 누락-체중이 아닌 성별과 관련됨
   ③ 비무작위 결측 NMAR Not Missing at Random
      결측값이 결측된 변수와 관련이 있는 경우
      서비스에 불만족한 고객들은 만족도 설문에 응답하지 않음
4. 데이터 결측값 대치법
   ① 단순 대치법 Single Imputation
      a) 완전분석법 Completes Analysis : 불완전한 자료 무시, 완전한 자료만 분석
      b) 평균대치법 Mean Imputation : 관측된 자료의 평균값으로 결측값 대치
      c) 단순 삭제 Completes Analysis : 불완전 데이터는 모두 삭제, 데이터 손실
      d) 단순확률 대치법 Single Stochastic Imputation : 평균 대치법에서 확률 값 부여
   ② 다중 대치법 : 단순 대치법을 m번 수행, 대치 → 분석 → 결합

빅데이터 분석기사-2과목 빅데이터 탐색 01

5. 데이터 전처리 유형
   ① 데이터 ____ : 결측 데이터, 이상치 파악 및 제거하고 정합성이 맞도록 교정
   ② 데이터 ____ : 여러 개의 데이터베이스, 데이터 집합 또는 파일 통합
   ③ 데이터 ____ : 샘플링, 차원축소, 변수선택 및 추출을 통해 차원을 줄이는 작업
   ④ 데이터 ____ : 데이터를 정규화, 이산화, 파생변수 등으로 변환하는 작업
6. 데이터 정제 Data Cleaning
   ① _____ Missing Value
      a) 입력이 누락되어 값이 존재하지 않고 비어있는 값(NA, NULL, 99999, Unknown..)
      b) 결측값 대체 - 중위수, 평균값 등
   ② _____ Noise
      a) 측정된 편수에서의 오류나 오차 값
      b) 오류나 오차 값에 의해 경향성 훼손 발생
      c) 데이터 평활화 기법 사용, 구간화, 회귀, 군집화
   ③ _____ Outlier
      a) 관측된 데이터 범주에서 일반적인 데이터 값의 범위를 벗어난 값
      b) 상한보다 높으면 상한값으로 대체, 하한보다 낮으면 하한값으로 대체
7. 데이터 결측값의 구분
   ① _____ 결측 MCAR Missing Completely at Random
      관측된 다른 변수와 아무런 연관 없이 발생한 경우(우연히 질문을 건너뜀)
      제거하거나 단순 무작위 표준추출을 통해 완벽한 데이터셋으로 만듦
   ② _____결측 MAR Missing at Rnadom
      결측된 변수와는 관련이 없지만 다른 변수와 관련이 있는 경우
      여성이 체중 누락-체중이 아닌 성별과 관련됨
   ③ _____ 결측 NMAR Not Missing at Random
      결측값이 결측된 변수와 관련이 있는 경우
      서비스에 불만족한 고객들은 만족도 설문에 응답하지 않음
8. 데이터 결측값 대치법
   ① ____ 대치법 Single Imputation
      a) _____법 Completes Analysis : 불완전한 자료 무시, 완전한 자료만 분석
      b) _____법 Mean Imputation : 관측된 자료의 평균값으로 결측값 대치
      c) 단순 ____ Completes Analysis : 불완전 데이터는 모두 삭제, 데이터 손실
      d) 단순____ 대치법 Single Stochastic Imputation : 평균 대치법에서 확률 값 부여
   ② ____ 대치법 : 단순 대치법을 m번 수행, 대치 → 분석 → 결합

1. 이상치 발생원인

① 비자연적 이상치 Non-Natural Outlier : 데이터 수집 기록 또는 입력 중 발생한 에러

② 측정 오류 Measurement Error ; 측정 도구의 오류, 불량 저울

③ 실험적 오류 Experiment Error : 실험 중 발생한 오류(달리기 주자의 실수)

④ 의도적 오류 Intentional Erro : 민감한 데이터, 10대들의 술 소비량 기록 낮춤

⑤ 샘플링 또는 표본 오류 Sampling Error : 대학생 키 측정시 농구선수 포함

2. 이상치 탐지 방법

① 단변량 자료에서 이상치 탐색

a) 상자 그림 Box Plot

최대값은 Q3+1.5(Q3-Q1), 최솟값은 Q1-1.5(Q3-Q1)을 벗어난 데이터

b) 산점도 Scatter Plot : 직선의 함수관계를 벗어난 관측치의 시각적 판단

c) 표준화 점수의 활용

(i) 표준화 점수는 평균이 μ이고, 표준편차가 σ인 정규분포를 따르는 관측치들이 자료의 중심(평균)에서 얼마나 떨어져 있는가를 나타냄

(ii) 절대값이 3보다 큰 경우 이상치로 정의

d) 통계적 가설검정을 활용한 이상치 탐색

(i) 딕슨의 Q검정 : 관측치 간의 차이에 대한 비율 활용, 임계값보다 크면 이상치

(ii) 그럽스 T 검정 : t-분포에 근거한 임계치 산출, 임계치보다 크면 이상치

(iii) ESD Extreme Studentized Deviate : 평균으로부터 ±3σ 떨어진 값

e) 카이제곱 검정 Chi-Square Test

(i) 데이터가 정규분포를 만족하나, 자료의 수가 적은 경우 이상치로 검정

② 다변량 자료에서 이상치 탐색

a) 회귀진단(Regression diagnostics)에서의 이상치 탐색

레버리지, 표준화 잔차, 스튜던트 잔차, 쿡의 거리, DFFITS, DFBETAS

b) 마할라노비스 거리를 이용한 이상치 탐색

c) LOF Local Outlier Factor

관측치 주변의 밀도와 근접한 관측치 주변의 밀도와 비교

d) iForest (Isolation Forest)

의사결정나무 이용, 적은 횟수로 leaf 노드에 도달하는 관측치일수록 이상치

3. 이상치 처리방법

① 관측치 삭제 : 입력, 처리 오류 또는 이상 관측치가 매우 작다면 삭제

② 변환과 범주화 : 결정트리 알고리즘(변수의 구간화로 이상치 처리)

③ 대치 : 평균, 중간값, 최빈값 대치 방법 사용, 자연/비자연적 이상치 구분 필수

4. 이상치 발생원인

① _____ 이상치 Non-Natural Outlier : 데이터 수집 기록 또는 입력 중 발생한 에러

② ___ 오류 Measurement Error ; 측정 도구의 오류, 불량 저울

③ _____ 오류 Experiment Error : 실험 중 발생한 오류(달리기 주자의 실수)

④ _____ 오류 Intentional Erro : 민감한 데이터, 10대들의 술 소비량 기록 낮춤

⑤ _____ 또는 표본 오류 Sampling Error : 대학생 키 측정시 농구선수 포함

5. 이상치 탐지 방법

① 단변량 자료에서 이상치 탐색

a) _____ _____

최대값은 _____, 최솟값은 _____을 벗어난 데이터

b) 산점도 Scatter Plot : 직선의 함수관계를 벗어난 관측치의 시각적 판단

c) 표준화 점수의 활용

(i) 표준화 점수는 평균이 μ이고, 표준편차가 σ인 정규분포를 따르는 관측치들이 자료의 중심(평균)에서 얼마나 떨어져 있는가를 나타냄

(ii) 절대값이 _보다 큰 경우 이상치로 정의

d) 통계적 가설검정을 활용한 이상치 탐색

(i) 딕슨의 _검정 : 관측치 간의 차이에 대한 비율 활용, 임계값보다 크면 이상치

(ii) _____ 검정 : t-분포에 근거한 임계치 산출, 임계치보다 크면 이상치

(iii) ___ Extreme Studentized Deviate : 평균으로부터 _____ 떨어진 값

e) 카이제곱 검정 Chi-Square Test

(i) 데이터가 정규분포를 만족하나, 자료의 수가 적은 경우 이상치로 검정

② 다변량 자료에서 이상치 탐색

a) 회귀진단(Regression diagnostics)에서의 이상치 탐색

레버리지, 표준화 잔차, 스튜던트 잔차, 쿡의 거리, DFFITS, DFBETAS

b) _____ 거리를 이용한 이상치 탐색

c) ___ Local Outlier Factor

관측치 주변의 밀도와 근접한 관측치 주변의 밀도와 비교

d) _____ (Isolation Forest)

의사결정나무 이용, 적은 횟수로 leaf 노드에 도달하는 관측치일수록 이상치

6. 이상치 처리방법

④ 관측치 ___ : 입력, 처리 오류 또는 이상 관측치가 매우 작다면 삭제

⑤ ___과 _____ : 결정트리 알고리즘(변수의 구간화로 이상치 처리)

⑥ ___ : 평균, 중간값, 최빈값 대치 방법 사용, 자연/비자연적 이상치 구분 필수

빅데이터 분석기사-2과목 빅데이터 탐색 03

1. 변수 Variable Feature

① 결과에 영향을 미치는 값, 결과는 종속변수, 원인이 되는 변수는 독립변수

② 두 변수 모두 연속형 자료와 범주형 자료 가능

2. 변수 선택

① 필터 방법 : 데이터의 통계적 특성으로부터 변수를 선택

a) 높은 상관계수(영향력)을 가진 변수 추출, 분산이 낮은 데이터는 도움이 안된다고 판단하여 제거

b) 필터 방법 선택 기준

(i) 정보 이득 : 어떤 변수를 선택함으로써 데이터를 잘 구분하게 됨

정보 이득이 클수록 변별력이 좋음

(ii) 카이제곱검정 : 관찰된 빈도가 기대 빈도와 통계적으로 다른지를 판단, 독립성 검정

② 래퍼 방법 : 변수의 일부만을 모델링에 사용하고 결과를 확인하며 변수 선택(중요)

a) Forward Selection 전진 선택법

(i) 변수가 없는 상태로 시작하여 중요한 변수를 추가

(ii) 한 번 추가된 변수는 제거할 수 없음

b) Backward Elimination 후진 제거법

(i) 모든 변수를 가지고 시작하여 덜 중요한 변수를 하나씩 제거

(ii) 한 번 제거된 변수는 추가할 수 없음

c) Stepwise Method 단계 선택법

(i) 전진 선택법 + 후진 제거법

(ii) 새롭게 추가된 변수에 기인해 기존 변수의 중요도가 약화되면 해당 변수 제거

③ 임베디드 메소드

a) 필터링 + 래퍼 방법, 모델링 기법 자체에 변수 선택이 포함된 방법

b) 정규화 선형회귀 : 선형회귀 계수(weight)에 대한 제약조건을 추가함으로써 모형이 과도하게 최적화되는 현상, 즉 과대적합을 막는 방법

c) 능형 Ridge 회귀모형 : 가중치들의 제곱합을 최소화하는 것을 추가적인 제약조건으로 함

$$w = \arg\min_{w} \left(\sum_{i=1}^{N} e_i^2 + \lambda \sum_{j=1}^{M} w_j^2 \right)$$

회귀모수에 대해 축소추정과 함께 모든 예측변수를 모형에 참여시키며 변수선택의 기능은 없다.

d) Lasso 회귀모형 : 가중치의 절대값의 합을 최소화하는 것을 추가적인 제약조건으로 함

$$w = \arg\min_{w} \left(\sum_{i=1}^{N} e_i^2 + \lambda \sum_{j=1}^{M} |w_j| \right)$$

축소추정과 변수선택의 기능을 동시에 가진다.

e) Elastic Net 회귀모형 : 가중치의 절대값의 합과 제곱합을 동시에 제약 조건으로 가지는 모형

$$w = \arg\min_{w} \left(\sum_{i=1}^{N} e_i^2 + \lambda_1 \sum_{j=1}^{M} |w_j| + \lambda_2 \sum_{j=1}^{M} w_j^2 \right)$$

빅데이터 분석기사-2과목 빅데이터 탐색 03

3. 변수 Variable Feature

① 결과에 영향을 미치는 값, 결과는 ____변수, 원인이 되는 변수는 ____변수

② 두 변수 모두 연속형 자료와 범주형 자료 가능

4. 변수 선택

① 필터 방법 : 데이터의 통계적 특성으로부터 변수를 선택

a) 높은 상관계수(영향력)을 가진 변수추출, 분산 낮은 데이터는 도움이 안된다고 판단하여 제거

b) 필터 방법 선택 기준

(i) 정보 이득 : 어떤 변수를 선택함으로써 데이터를 잘 구분하게 됨

정보 이득이 _____ 변별력이 좋음

(ii) 카이제곱검정 : 관찰된 빈도가 기대 빈도와 통계적으로 다른지를 판단, _____ 검정

② 래퍼 방법 : 변수의 일부만을 모델링에 사용하고 결과를 확인하며 변수 선택(중요)

a) _____

(i) 변수가 없는 상태로 시작하여 중요한 변수를 추가

(ii) 한 번 추가된 변수는 제거할 수 없음

b) _____

(i) 모든 변수를 가지고 시작하여 덜 중요한 변수를 하나씩 제거

(ii) 한 번 제거된 변수는 추가할 수 없음

c) _____

(i) 전진 선택법 + 후진 제거법

(ii) 새롭게 추가된 변수에 기인해 기존 변수의 중요도가 약화되면 해당 변수 제거

③ 임베디드 메소드

a) 필터링 + 래퍼 방법, 모델링 기법 자체에 변수 선택이 포함된 방법

b) _____선형회귀 : 선형회귀 계수(weight)에 대한 제약조건을 추가함으로써 모형이 과도하게 최적화되는 현상, 즉 과대적합을 막는 방법

c) _____ 회귀모형 : 가중치들의 ___합을 최소화하는 것을 추가적인 제약조건으로 함

$$w = \arg\min_{w} \left(\sum_{i=1}^{N} e_i^2 + \lambda \sum_{j=1}^{M} w_j^2 \right)$$

회귀모수에 대해 축소추정과 함께 모든 예측변수를 모형에 참여시키며 변수선택의 기능은 없다.

d) _____ 회귀모형 : 가중치의_____의 합을 최소화하는 것을 추가적인 제약조건으로 함

$$w = \arg\min_{w} \left(\sum_{i=1}^{N} e_i^2 + \lambda \sum_{j=1}^{M} |w_j| \right)$$

축소추정과 변수선택의 기능을 동시에 가진다.

e) _____회귀모형 : 가중치의 _____의 합과 ___합을 동시에 제약 조건으로 가지는 모형

$$w = \arg\min_{w} \left(\sum_{i=1}^{N} e_i^2 + \lambda_1 \sum_{j=1}^{M} |w_j| + \lambda_2 \sum_{j=1}^{M} w_j^2 \right)$$

빅데이터 분석기사-2과목 빅데이터 탐색 04

1. 차원 축소 : 다차원 데이터 셋에서 변수의 개수를 줄임으로서 차원을 축소

2. 차원의 저주

① 데이터의 차원이 커질수록 분석을 위한 알고리즘 실행이 매우 복잡해지고 어려워지는 것

① 데이터보다 변수가 많으면 학습을 느리게 하고 과적합이 발생할 가능성이 높아짐

② 자원의 필요-차원이 커질수록 계산 시간이 증가하고, 많은 공간을 필요로 함

③ 입력 변수의 수가 너무 많으면 잡음이 발생하여 분류 모형의 정확도가 감소함

④ 입력 변수 간에 상관관계가 있는 경우 다중공선성이 발생해 모형이 불안정해짐

3. 차원축소 유형

① 피처 선택(Feature Selection) : 데이터의 특징을 가장 잘 나타내는 주요 피처만 선택

② 피처 추출(Feature Extraction) : 기존의 변수를 함축하는 새 피처 생성

4. 차원축소 방법1

① 다차원 척도법 MDS, Multi Dimentsional Scaling

다차원 관측값 또는 개체들 간의 거리(distance) 또는 비유사성(dissimilarity)을 이용하여 개체들을 원래의 차원보다 낮은 차원(보통 2차원)의 공간상에 위치시켜 (spatial configuration) 개체들 사이의 구조 또는 관계를 쉽게 파악

② 주성분 분석 PCA, Principal Component Analysis 비지도 학습

a) 분석변수들을 선형적으로 결합하여 데이터를 가장 잘 표현할 수 있는 축(원데이터의 분산을 최대한 유지하는 축)을 중심으로 데이터의 차원을 축소해서 표현

a) 데이터들을 어떠한 벡터로 투영시켰을 때, 투영들의 분산이 큰 벡터들을 찾는다. 투영들의 분산을 적게 만드는 벡터들은 제거하여 데이터의 차원 감소

b) 적절한 행렬 A를 활용해 X를 대신할 수 있는 Y = AX를 얻고, Y 행렬의 변수 중요 변수 몇 개를 추려 X 대신 사용, A를 찾는 데에 공분산행렬이나 상관계수 행렬을 사용(고유값과 고유벡터 계산)

c) 제1주성분이 가장 중요하고, 그 다음으로 제2주성분이 중요하게 취급됨

d) 변수 사이에 강력한 선형 관계가 존재하는 경우 유용, 비선형 데이터 분포에 적합하지 않음, 다중회귀분석 및 군집분석에서 입력 데이터에 대해 많이 이용됨

e) 벡터(기저축)에 대한 직관적 해석이 쉽지 않음

f) 주성분들이 완전히 독립적이기 위해서는 입력 변수로 사용되는 데이터의 집합이 정규분포의 성질을 갖고 있어야 함

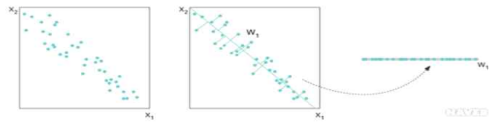

x:측정된 변수 개수
파란 점:n차원에서의 샘플
w1:첫 주성분 분석 로딩
연두색 선:본래 차원의 샘플이 주성분 공간으로 투사되는 변환을 나타냄

빅데이터 분석기사-2과목 빅데이터 탐색 04

5. 차원 축소 : 다차원 데이터 셋에서 변수의 개수를 줄임으로서 차원을 축소

6. 차원의 저주

② 데이터의 차원이 커질수록 분석을 위한 알고리즘 실행이 매우 복잡해지고 어려워지는 것

① 데이터보다 변수가 많으면 학습을 느리게 하고 _____이 발생할 가능성이 높아짐

② ____의 필요-차원이 커질수록 계산 시간이 증가하고, 많은 공간을 필요로 함

③ 입력 변수의 수가 너무 많으면 ____이 발생하여 분류 모형의 정확도가 감소함

④ 입력 변수 간에 상관관계가 있는 경우 _____이 발생해 모형이 불안정해짐

7. 차원축소 유형

① _____(_____) : 데이터의 특징을 가장 잘 나타내는 주요 피처만 선택

② _____(_____) : 기존의 변수를 함축하는 새 피처 생성

8. 차원축소 방법1

① _____ ___, _____

다차원 관측값 또는 개체들 간의 거리(distance) 또는 비유사성(dissimilarity)을 이용하여 개체들을 원래의 차원보다 낮은 차원(보통 2차원)의 공간상에 위치시켜 (spatial configuration) 개체들 사이의 구조 또는 관계를 쉽게 파악

② _____ ___, _____ _____학습

a) 분석변수들을 ___적으로 결합하여 데이터를 가장 잘 표현할 수 있는 축(원데이터의 분산을 최대한 유지하는 축)을 중심으로 데이터의 차원을 축소해서 표현

a) 데이터들을 어떠한 벡터로 투영시켰을 때, 투영들의 분산이 __ 벡터들을 찾는다. 투영들의 분산을 ___ 만드는 벡터들은 제거하여 데이터의 차원 감소

b) 적절한 행렬 A를 활용해 X를 대신할 수 있는 Y = AX를 얻고, Y 행렬의 변수 중요 변수 몇 개를 추려 X 대신 사용, A를 찾는 데에 _____행렬이나 _____ __ 행렬을 사용(고유값과 고유벡터 계산)

c) _____이 가장 중요하고, 그 다음으로 제2주성분이 중요하게 취급됨

d) 변수 사이에 강력한 ___ 관계가 존재하는 경우 유용, 비선형 데이터 분포에 적합하지 않음, 다중회귀분석 및 군집분석에서 입력 데이터에 대해 많이 이용됨

e) 벡터(기저축)에 대한 직관적 해석이 쉽지 않음

f) 주성분들이 완전히 독립적이기 위해서는 입력 변수로 사용되는 데이터의 집합이 ___분포의 성질을 갖고 있어야 함

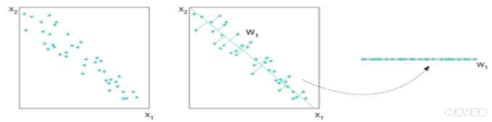

x:측정된 변수 개수
파란 점:n차원에서의 샘플
w1:첫 주성분 분석 로딩
연두색 선:본래 차원의 샘플이 주성분 공간으로 투사되는 변환을 나타냄

9. 차원축소 방법2

① 선형 판별분석 LDA, Linear Discriminant Analysis, 지도 학습

a) PCA와 유사하게 데이터를 저차원 공간에 투영해 차원을 축소하는 방법

a) 클래스 내부 분산과 클래스 간 분산 행렬을 생성한 후 이들의 고유벡터와 고유값을 구해 축소

b) 데이터 포인트들을 투영시켰을 때 각 클래스에 속하는 투영들의 평균간의 거리의 합이 최대가 되게 하는 벡터. 다른 말로, 클래스 간(between-class)의 거리가 최대가 되게 하는 벡터를 찾음.

c) 데이터 포인트들을 투영시켰을 때 클래스 내의 투영들의 분산이 최소가 되게 하는 벡터를 찾음. 선형 데이터에 적절하며 비선형 데이터에 적절하지 않음.

d) PCA는 비지도 학습, LDA는 지도학습

e) PCA는 데이터의 분산을 가장 잘 설명하는 축을 찾지만, LDA는 입력 데이터의 예측 변수 클래스를 최대한 잘 구분할 수 있는 축을 찾음

f) 분류된 군집의 수가 적은데 분석 데이터셋의 분석차원이 너무 많거나 수집한 케이스 데이터의 양이 많은 경우 오류가 발생할 위험이 높으므로 주의

② 요인분석 Factor Analysis

a) 변수들 간의 상관관계를 고려하여 서로 유사한 변수들을 묶어주는 방법

b) 수학, 과학 → 수리능력, 국어, 영어 → 언어능력 으로 차원 축소

c) 도출된 요인들은 중요도가 다르지 않으며 서로 대등한 관계

d) 요인으로 묶어지지 않은 변수 중 중요도가 낮은 변수 제거

e) 생성변수의 이름은 분석자가 직접 결정

③ 특이값 분해 SVD, Singular Value Decomposition

a) 실수 또는 복합 행렬의 인수분해, 실수 공간에서 정의된 $m \times n$차원 행렬에서 특이값을 추출하고 이를 이용하여 데이터의 차원 축소

b) 임의의 $m \times n$행렬 $A = U\sum V^T$로 분해

c) PCA와 LDA는 정방행렬에 대한 작업, 특이값 분해는 비정방행렬에 대해 적용 가능

d) 데이터 축소 및 영상처리 및 압축, 이상치 감지에 적용

④ t-SNE T-distributed stochastic neighbor embedding

a) 데이터에서 지역 인접성을 보조하려고 시도하는 차원축소 알고리즘

b) 비선형적, 비결정적, 데이터셋이 매우 큰 경우에는 구조 파악이 어려움

⑤ 서포트 벡터 머신

a) 내부에 있는 차원축소 기법을 활용하여 2 또는 3차원으로 축소한 후 결과를 그래프로 제공, 비선형 관계가 있는 경우에도 사용 가능

10. 차원축소 방법2

⑥ _____ ___, _____, ___ 학습

a) PCA와 유사하게 데이터를 저차원 공간에 투영해 차원을 축소하는 방법

g) 클래스 내부 분산과 클래스 간 분산 행렬을 생성한 후 이들의 고유벡터와 고유값을 구해 축소

h) 데이터 포인트들을 투영시켰을 때 각 클래스에 속하는 투영들의 평균간의 거리의 합이 최대가 되게 하는 벡터. 다른 말로, 클래스 __(_____-class)의 거리가 ___가 되게 하는 벡터를 찾음.

i) 데이터 포인트들을 투영시켰을 때 클래스 __의 투영들의 분산이 ___가 되게 하는 벡터를 찾음. ___ 데이터에 적절하며 비선형 데이터에 적절하지 않음.

j) PCA는 _____ 학습, LDA는 ___학습

k) PCA는 데이터의 ___을 가장 잘 설명하는 축을 찾지만, LDA는 입력 데이터의 예측 변수 _____를 최대한 잘 구분할 수 있는 축을 찾음

l) 분류된 군집의 수가 적은데 분석 데이터셋의 분석차원이 너무 많거나 수집한 케이스 데이터의 양이 많은 경우 오류가 발생할 위험이 높으므로 주의

⑦ _____ _____

a) 변수들 간의 ___관계를 고려하여 서로 유사한 변수들을 묶어주는 방법

b) 수학, 과학 → 수리능력, 국어, 영어 → 언어능력 으로 차원 축소

c) 도출된 요인들은 중요도가 다르지 않으며 서로 ___한 관계

d) 요인으로 묶어지지 않은 변수 중 중요도가 ___ 변수 제거

e) 생성변수의 이름은 분석자가 직접 결정

⑧ _____ ___, _____

a) 실수 또는 복합 행렬의 인수분해, 실수 공간에서 정의된 $m \times n$차원 행렬에서 특이값을 추출하고 이를 이용하여 데이터의 차원 축소

b) 임의의 $m \times n$행렬 $A = U\sum V^T$로 분해

c) PCA와 LDA는 정방행렬에 대한 작업, 특이값 분해는 비정방행렬에 대해 적용 가능

d) 데이터 축소 및 영상처리 및 압축, 이상치 감지에 적용

⑨ _____ _____

a) 데이터에서 지역 인접성을 보조하려고 시도하는 차원축소 알고리즘

b) 비선형적, 비결정적, 데이터셋이 매우 큰 경우에는 구조 파악이 어려움

⑩ _____

a) 내부에 있는 차원축소 기법을 활용하여 2 또는 3차원으로 축소한 후 결과를 그래프로 제공, _____ 관계가 있는 경우에도 사용 가능

빅데이터 분석기사-2과목 빅데이터 탐색 06

1. 파생변수
   ① 기존 변수에 특정 조건 혹은 함수를 사용하여 새롭게 재정의한 변수
   ② 주관적일 수 있으므로 논리적 타당성 필수
   ③ 세분화, 고객 행동 예측, 캠페인 반응 예측에 활용
2. 요약변수
   ① 수집된 정보를 분석에 맞게 종합한(Aggregate) 변수
   ② 고객 클래스별 고객 수 및 구매금액, 제품군별 상품 수, 구매여부, 총구매 금액 등 데이터 분석을 위해 만들어지는 변수
   ③ 재활용성이 높고, 다른 많은 모델을 공통으로 사용할 수 있는 장점
   ④ 생성 전 값들의 의미를 정확히 정의하여 해석상의 차이가 발생하지 않도록 주의
3. 변수 변환 목적 : 분포의 대칭화, 산포의 균일화, 변수 사이의 관계 단순화
4. 범주형 변환
   ① 변수 구간화 Binning
      a) 노이즈를 제거하기 위해 연속형 변수를 다수(보통 5개)의 구간으로 나눔
      b) 신용평가모형, 고객 세분화
   ② 더미 변수 Dummy Variable(6회 기출)
      a) 범주형 독립변수의 범주를 변수로 두고, 해당 범주에 속하면 1, 그렇지 않으면 0
      b) 범주형 독립변수가 n개의 범주를 가지고 이를 더미변수로 만들면 변수는 n-1개
   ③ 데이터 인코딩(5, 6회 기출)
      a) 레이블 인코딩 : 범주형 데이터를 숫자로 치환
      b) 원-핫 인코딩 : 여러 값 중 하나만 활성화, k개의 범주가 k개의 열로 변환
      c) 타겟 인코딩 : 평균값으로 범주를 대체, 데이터 관측치가 많을 때 적합
      d) 오디널 인코딩 : 변수의 순서를 유지하는 인코딩
5. 정규변환
   ① 로그 변환 : 데이터 간 편차를 줄여 왜도와 첨도를 줄임, 정규성 높임
      큰 수 작아짐, 큰 값(오른)쪽으로 치우친 분포를 중앙 중심으로 변환
   ② 제곱근 변환 : 오른쪽 긴 꼬리를 갖는 분포를 대칭화하는데 유용
      데이터 분산의 안정화
   ③ 지수 변환 : 작은 숫자의 크기를 크게 넓혀줌, 오른쪽 부분이 넓어지고 왼쪽 부분은 좁혀짐
   ④ 박스-칵스 변환 : 데이터를 정규분포에 가깝게 만들거나 데이터의 분산 안정화

빅데이터 분석기사-2과목 빅데이터 탐색 06

6. _____
   ① 기존 변수에 특정 조건 혹은 함수를 사용하여 새롭게 재정의한 변수
   ② 주관적일 수 있으므로 논리적 타당성 필수
   ③ 세분화, 고객 행동 예측, 캠페인 반응 예측에 활용
7. _____
   ① 수집된 정보를 분석에 맞게 종합한(Aggregate) 변수
   ② 고객 클래스별 고객 수 및 구매금액, 제품군별 상품 수, 구매여부, 총구매 금액 등 데이터 분석을 위해 만들어지는 변수
   ③ _____이 높고, 다른 많은 모델을 공통으로 사용할 수 있는 장점
   ④ 생성 전 값들의 의미를 정확히 정의하여 해석상의 차이가 발생하지 않도록 주의
8. 변수 변환의 목적 : ____의 대칭화, ____의 균일화, 변수 사이의 관계 단순화
9. 범주형 변환
   ① _____ _____
      a) 노이즈를 제거하기 위해 연속형 변수를 다수(보통 5개)의 구간으로 나눔
      b) 신용평가모형, 고객 세분화
   ② _____ _____
      a) 범주형 독립변수의 범주를 변수로 두고, 해당 범주에 속하면 1, 그렇지 않으면 0
      b) 범주형 독립변수가 n개의 범주를 가지고 이를 더미변수로 만들면 변수는 n-1개
   ③ 데이터 인코딩
      a) _____ 인코딩 : 범주형 데이터를 숫자로 치환
      b) _____ 인코딩 : 여러 값 중 하나만 활성화, k개의 범주가 k개의 열로 변환
      c) _____인코딩 : 평균값으로 범주를 대체, 데이터 관측치가 많을 때 적합
      d) _____인코딩 : 변수의 순서를 유지하는 인코딩
10. 정규변환
   ① _____변환 : 데이터 간 편차를 줄여 왜도와 첨도를 줄임, 정규성 높임
      큰 수 작아짐, 큰 값(오른)쪽으로 치우친 분포를 중앙 중심으로 변환
   ② _____ 변환 : 오른쪽 긴 꼬리를 갖는 분포를 대칭화하는데 유용
      데이터 분산의 안정화
   ③ ___ 변환 : 작은 숫자의 크기를 크게 넓혀줌, 오른쪽 부분이 넓어지고 왼쪽 부분은 좁혀짐
   ④ _____ 변환 : 데이터를 정규분포에 가깝게 만들거나 데이터의 분산 안정화

1. **Data Scaling** : 데이터의 값의 범위를 조정하는 것, 입력 변수만 스케일링 실행
   ① **최소-최대 정규화**(6회 기출)
      a) 최소값 0, 최대값 1, 다른 값들은 0과 1사이 값들로 변환, 결측값, 이상값 미리 처리

$$\frac{X-Min}{Max-Min}$$

   ② **Z-점수 표준화** Z-Score Normalization
      a) 데이터가 표준정규분포에 해당하도록 변환

$$\frac{X-\text{평균}}{\text{표준편차}}$$

   ③ 최대절대 스케일리 MaxAbs Scaler : 데이터가 -1~1이 되도록 스케일링
   ④ **로버스트 스케일러** Robust Scaler : 데이터의 중앙값은 9, IQR은 1로 스케일링

$$\frac{X-\text{중앙값}}{IQR}$$

2. **불균형 데이터** : 분류할 각 집단에 속하는 데이터의 수가 동일하지 않은 경우
   ① **오버 샘플링 Over Sampling**
      a) **더 작은 수의 데이터를 가진 집단을 표본으로 더 많이 추출**하여 불균형 해결
      b) 데이터의 수를 증가시켜 시간이 많이 소요되거나, 복제되는 데이터에 과적합 우려
      c) **Random Over Sampling** : 작은 클래스의 데이터 무작위로 생성, 과적합 우려
      d) **ADASYN** Adaptive Synthetic Sampling
         클래스 간 **경계면에 가까울수록 많은 소수 클래스의 데이터 합성**, 과적합 해결
      e) **SMOTE**
         k-NN k-Nearest Neghbors 알고리즘을 활용하여 소수 범주에서 가상 데이터 생성
      f) **Borderling-SMOTE** : 소수 클래스 샘플과 다수 클래스 샘플 간의 경계를 기준으로 SMOTE 합성
   ② **언더 샘플링 Under Sampling**
      a) 소수 클래스 샘플 수에 맞도록 다수 클래스 **샘플 제거**, **정보 손실**, **시간 감소**
      b) **Random Under Sampling** : 무작위 언더샘플링, 수행할 때마다 결과가 다름
      c) **토멕링크 Tomek Links** : 경계선 가까이에 존재하는 데이터 중 다수 데이터 제거
      d) **CNN Condensed Nearest Neighbour**
         다수 범주 데이터 중 밀집된 데이터를 제거하고 대표하는 데이터만 남겨 샘플링
      e) **OSS One-Side Selection** : 토멕링크 + CNN 의 장점을 합한 방식
   ③ **임계값 이동 Threshold-moving** : 임계값을 양성과 음성의 비율을 이용해 조정
      비용민감 학습(소수클래스의 비용함수에 높은 가중치 부여, 비정형데이터 가능)
   ④ **앙상블** 방법 : 언더 샘플링과 오버 샘플링 조합, **SMOTE + TomekLinks** 결합

3. **Data Scaling** : 데이터의 값의 범위를 조정하는 것, 입력 변수만 스케일링 실행
   ① _____(6회 기출)
      a) 최소값 0, 최대값 1, 다른 값들은 0과 1사이 값들로 변환, 결측값, 이상값 미리 처리

$$\frac{X-Min}{Max-Min}$$

   ② _____ _____
      a) 데이터가 표준정규분포에 해당하도록 변환

$$\frac{X-\text{평균}}{\text{표준편차}}$$

   ③ 최대절대 스케일리 MaxAbs Scaler : 데이터가 -1~1이 되도록 스케일링
   ④ _____ _____ : 데이터의 중앙값은 9, IQR은 1로 스케일링

$$\frac{X-\text{중앙값}}{IQR}$$

4. **불균형 데이터** : 분류할 각 집단에 속하는 데이터의 수가 동일하지 않은 경우
   ① _____ _____
      a) **더 작은 수의 데이터를 가진 집단을 표본으로 더 많이 추출**하여 불균형 해결
      b) 데이터의 수를 증가시켜 시간이 많이 소요되거나, 복제되는 데이터에 과적합 우려
      c) _____ **Over Sampling** : 작은 클래스의 데이터 무작위로 생성, 과적합 우려
      d) _____ _____
         클래스 간 **경계면에 가까울수록 많은 소수 클래스의 데이터 합성**, 과적합 해결
      e) _____
         k-NN k-Nearest Neghbors 알고리즘을 활용하여 소수 범주에서 가상 데이터 생성
      f) _____
         소수 클래스 샘플과 다수 클래스 샘플 간의 경계를 기준으로 SMOTE 합성
   ② _____ _____
      a) 소수 클래스 샘플 수에 맞도록 다수 클래스 **샘플 제거**, **정보 손실**, **시간 감소**
      b) _____**Under Sampling** : 무작위 언더샘플링, 수행할 때마다 결과가 다름
      c) _____ _____ : 경계선 가까이에 존재하는 데이터 중 다수 데이터 제거
      d) ___ _____
         다수 범주 데이터 중 밀집된 데이터를 제거하고 대표하는 데이터만 남겨 샘플링
      e) ___ _____ : 토멕링크 + CNN 의 장점을 합한 방식
   ③ **임계값 이동 Threshold-moving** : 임계값을 양성과 음성의 비율을 이용해 조정
      비용민감 학습(소수클래스의 비용함수에 높은 가중치 부여, 비정형데이터 가능)
   ④ **앙상블** 방법 : 언더 샘플링과 오버 샘플링 조합, **SMOTE + TomekLinks** 결합

빅데이터 분석기사-2과목 빅데이터 탐색 08

1. 탐색적 데이터 분석 EDA Exploratory Data Analysis

① 데이터의 특징과 내재하는 구조적 관계를 알아내기 위한 기법들의 통칭

② EDA의 4가지 주제

a) 저항성 Resistance의 강조 : 이상치, 결측치 등의 영향을 받지 않는 도구 사용

b) 잔차 Residual 계산 : 이상치, 잔차 계산으로 주경향으로부터 벗어난 정도 체크

c) 데이터의 재표현 Data Re-expression : 로그 변환, 제곱근 변환 등의 변수변환

d) 그래프를 통한 현시성(Revelation) : 데이터 시각화, 히스토그램, 상자그림 등

2. 확증적 데이터 분석 CDA Confirmatory Data Analysis

① 가설을 설저한 후 수집한 데이터로 가설을 평가하고 추정

② 설문조사나 논문에 관한 내용 입증

3. 기초 통계량

① 평균 mean : $\overline{X}$

$$\overline{X}=\frac{1}{n}(X_1+X_2+\cdots+X_n)=\sum_{i=1}^{n}\frac{X_i}{n}$$

a) 소수의 극단값에 의해 영향을 받음

b) 각 집단 평균의 평균은 전체의 평균과 일치함

② 중앙값 median

n이 홀수인 경우 $\frac{(n+1)}{2}$, n이 짝수인 경우 $\frac{n}{2}$번째 값과 $\frac{n}{2}$+1번째 값의 평균

a) 자료를 분류한 각 집단 중앙값의 중앙값은 전체 중앙값과 항상 일치하지는 않음

③ 최빈값 mode

a) 관측빈도의 수가 가장 많은 값으로 소수의 극단값에 영향을 받지 않음

b) 양적으로 측정된 자료와 질적으로 측정된 자료 모두에 이용 가능

④ 세 통계량의 위치를 통해 자료의 분포 모양 파악 가능(평균은 꼬리쪽에 있음을 기억)

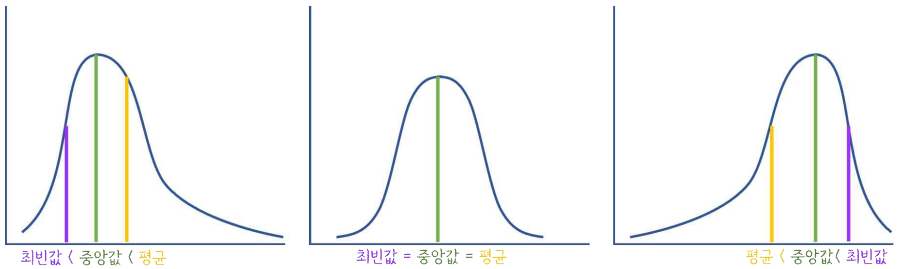

빅데이터 분석기사-2과목 빅데이터 탐색 08

4. _____ 데이터 분석 ___ _____ Data Analysis

① 데이터의 특징과 내재하는 구조적 관계를 알아내기 위한 기법들의 통칭

② ___의 4가지 주제

a) _____ _____의 강조 : 이상치, 결측치 등의 영향을 받지 않는 도구 사용

b) ___ _____ 계산 : 이상치, 잔차 계산으로 주경향으로부터 벗어난 정도 체크

c) 데이터의 _____ Data _____ : 로그 변환, 제곱근 변환 등의 변수변환

d) 그래프를 통한 _____(_____) : 데이터 시각화, 히스토그램, 상자그림 등

5. _____ 데이터 분석 ___ _____ Data Analysis

① 가설을 설저한 후 수집한 데이터로 가설을 평가하고 추정

② _____나 ___에 관한 내용 입증

6. 기초 통계량

① ___ ____ : $\overline{X}$

$$\overline{X}=\frac{1}{n}(X_1+X_2+\cdots+X_n)=\sum_{i=1}^{n}\frac{X_i}{n}$$

a) 소수의 극단값에 의해 영향을 받음

b) 각 집단 평균의 평균은 전체의 평균과 일치함

② _____ _____

n이 홀수인 경우 $\frac{(n+1)}{2}$, n이 짝수인 경우 $\frac{n}{2}$번째 값과 $\frac{n}{2}+1$번째 값의 평균

a) 자료를 분류한 각 집단 중앙값의 중앙값은 전체 중앙값과 항상 일치하지는 않음

③ _____ _____

a) 관측빈도의 수가 가장 많은 값으로 소수의 극단값에 영향을 받지 않음

b) 양적으로 측정된 자료와 질적으로 측정된 자료 모두에 이용 가능

④ 세 통계량의 위치를 통해 자료의 분포 모양 파악 가능(___은 꼬리쪽에 있음을 기억)

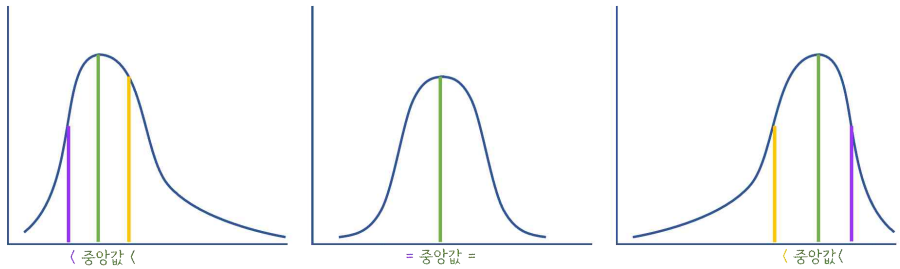

빅데이터 분석기사-2과목 빅데이터 탐색 09

1. 산포도 dispersion

① 범위 range : 가장 큰 값과 가장 작은 값의 차이

$R = X_{(n)} - X_{(l)}$

a) 소수의 극단값에 큰 영향을 받으므로 자료의 분포가 대칭인 경우 적절함

② 분산 variance : 편차 제곱의 합을 자료의 수로 나눈 값

표준편차 $\sigma = \sqrt{\sigma^2}$ (분산의 양의 제곱근)

a) 모집단의 수 N, 모집단의 평균 μ, 모집단의 분산 σ^2 일 때

$$\sigma^2 = \frac{\sum (X_i - \mu)^2}{N} = \frac{1}{N}\sum X_i^2 - \mu^2$$

b) 표본의 수 n, 표본의 평균 $\overline{X}$, 표본의 분산 S^2 일 때(6회 기출)

$$S^2 = \frac{\sum (X_i - \overline{X})^2}{n-1} = \frac{\sum X_i^2 - n\overline{X}^2}{n-1}$$

c) 분산이 0이면 모든 변량이 평균값에 집중, 분산의 값이 클수록 평균에서 멀어짐

d) 분산에 평균보다 더 크게 이상치에 민감함

③ 표준편차 standard deviation : 분산의 양의 제곱근, 자료의 흩어진 정도를 표현

$$\sigma^2 = \frac{\sum (X_i - \mu)^2}{N} = \frac{1}{N}\sum X_i^2 - \mu^2$$

④ 사분위수 Quatile : 데이터 표본을 4개의 동일한 부분으로 나눈 값

a) 제1사분위수 Q1 : 데이터의 25%가 이 값보다 작거나 같음(25백분위수)

b) 제2사분위수 Q2 : 중위수, 데이터의 50%가 이 값보다 작거나 같음(50백분위수)

c) 제3사분위수 Q3 : 데이터의 75%가 이 값보다 작거나 같음

d) 사분위간 범위 IQR Inter Quatile Range : Q3 - Q1, 정렬된 자료의 중간 50%

e) 이상치 : $Q1 - (1.5 \times IQR) \sim Q3 + (1.5 \times IQR)$ 범위를 벗어난 값

⑤ 평균의 표준오차 SE standard error : 모평균과 표본평균의 차이가 어느 정도인가

$SE_{\overline{X}} = \frac{S}{\sqrt{n}}$ 표본분포의 분산 추정량의 양의 제곱근

a) 표본의 통계량을 통해 모집단의 특성(모수)을 추정할 때 표준오차가 적을수록 표본의 대표성이 높다. 표본의 크기 n이 커지면 표준오차는 작아진다.

⑥ 변동계수 CV Coefficient of variation : 변수의 표준편차를 산술평균으로 나눈 값

$CV = \frac{\sigma}{\overline{X}}$ 상대표준편차 relative standard deviation RSD

a) 측정 단위가 서로 다른 자료를 비교할 때 사용

b) 값이 클수록 자료 간 상대적 차이가 큼

빅데이터 분석기사-2과목 빅데이터 탐색 09

2. 산포도 dispersion

① ___ _____ : 가장 큰 값과 가장 작은 값의 차이

$R = X_{(n)} - X_{(l)}$

a) 소수의 극단값에 큰 영향을 받으므로 자료의 분포가 대칭인 경우 적절함

② ___ _____ : 편차 제곱의 합을 자료의 수로 나눈 값

표준편차 $\sigma = \sqrt{\sigma^2}$ (분산의 양의 제곱근)

a) 모집단의 수 N, 모집단의 평균 μ, 모집단의 분산 σ^2 일 때

$$\sigma^2 = \frac{\sum (X_i - \mu)^2}{N} = \frac{1}{N}\sum X_i^2 - \mu^2$$

b) 표본의 수 n, 표본의 평균 $\overline{X}$, 표본의 분산 S^2 일 때(6회 기출)

$$S^2 = \frac{\sum (X_i - \overline{X})^2}{n-1} = \frac{\sum X_i^2 - n\overline{X}^2}{n-1}$$

c) 분산이 0이면 모든 변량이 평균값에 집중, 분산의 값이 클수록 평균에서 멀어짐

d) 분산에 평균보다 더 크게 이상치에 민감함

③ _____ _____ : 분산의 양의 제곱근, 자료의 흩어진 정도를 표현

$$\sigma^2 = \frac{\sum (X_i - \mu)^2}{N} = \frac{1}{N}\sum X_i^2 - \mu^2$$

④ _____ _____ : 데이터 표본을 4개의 동일한 부분으로 나눈 값

a) 제1사분위수 __ : 데이터의 __%가 이 값보다 작거나 같음(25백분위수)

b) 제2사분위수 __ : _____, 데이터의 __%가 이 값보다 작거나 같음(50백분위수)

c) 제3사분위수 __ : 데이터의 __%가 이 값보다 작거나 같음

d) 사분위간 범위 ___ Inter Quatile Range : _____, 정렬된 자료의 중간 50%

e) 이상치 : 범위를 벗어난 값

⑤ 평균의 _____ __ _____ : 모평균과 표본평균의 차이가 어느 정도인가

$SE_{\overline{X}} = \frac{S}{\sqrt{n}}$ 표본분포의 분산 추정량의 양의 제곱근

a) 표본의 통계량을 통해 모집단의 특성(모수)을 추정할 때 표준오차가 적을수록 표본의 대표성이 높다. 표본의 크기 n이 커지면 표준오차는 작아진다.

⑥ _____ __ _____ : 변수의 표준편차를 산술평균으로 나눈 값

$CV = \frac{\sigma}{\overline{X}}$ 상대표준편차 relative standard deviation RSD

a) 측정 단위가 서로 다른 자료를 비교할 때 사용(ADsP 기출)

b) 값이 클수록 자료 간 상대적 차이가 큼

1. **비대칭도 asymmetry**

① **왜도 skewness** : 비대칭도와 비대칭의 방향을 함께 보여주는 통계량

$$m_3 = E[(\frac{X-\mu}{\sigma})^3] = \frac{\mu^3}{\sigma^3}$$

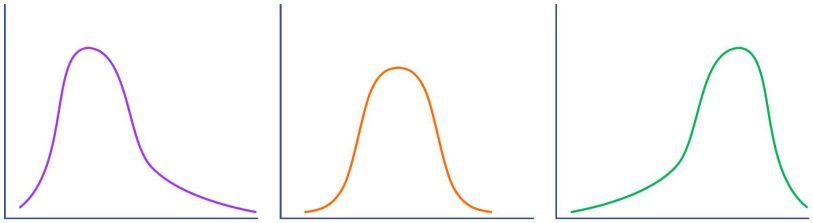

$m_3 > 0$ 오른쪽으로 긴 꼬리 $m_3 = 0$ 좌우 대칭 $m_3 < 0$ 왼쪽으로 긴 꼬리

양의 부분 분산이 더 큼 **음의 부분 분산이 더 큼**

② **첨도 kurtosis** : 분포의 중심에서 뾰족한 정도와 꼬리부분의 길이에 대한 정보 제공

$$m_4 = E[(\frac{X-\mu}{\sigma})^4] = \frac{\mu^4}{\sigma^4}$$ **정규분포의 첨도는 3**, 첨도에서 3을 뺀 후 이를 비교하기도 함

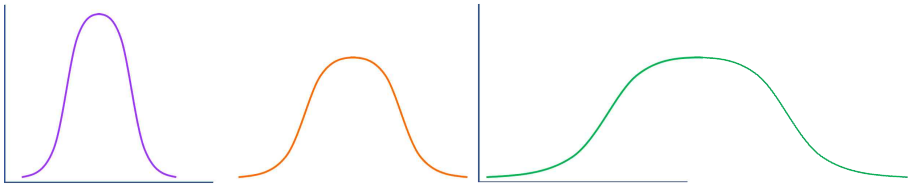

$m_4 > 3$ 표준정규분포보다 뾰족함 $m_4 = 3$ 표준정규분포와 유사함 $m_4 < 3$ 표준정규분포보다 덜 뾰족함

2. **비대칭도 asymmetry**

① ___ _____ : 비대칭도와 비대칭의 방향을 함께 보여주는 통계량

$$m_3 = E[(\frac{X-\mu}{\sigma})^3] = \frac{\mu^3}{\sigma^3}$$

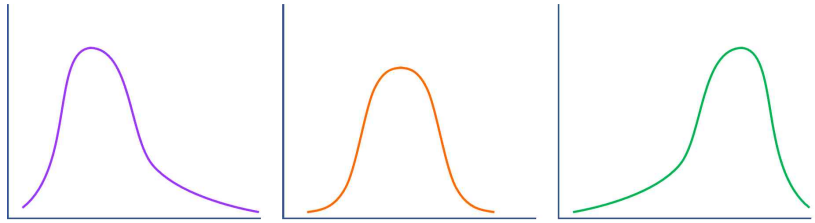

$m_3 > 0$ 오른쪽으로 긴 꼬리 $m_3 = 0$ 좌우 대칭 $m_3 < 0$ 왼쪽으로 긴 꼬리

양의 부분 분산이 더 큼 **음의 부분 분산이 더 큼**

② ___ _____ : 분포의 중심에서 뾰족한 정도와 꼬리부분의 길이에 대한 정보 제공

$$m_4 = E[(\frac{X-\mu}{\sigma})^4] = \frac{\mu^4}{\sigma^4}$$ **정규분포의 ___ 는 ___** 에서 3을 뺀 후 이를 비교하기도 함

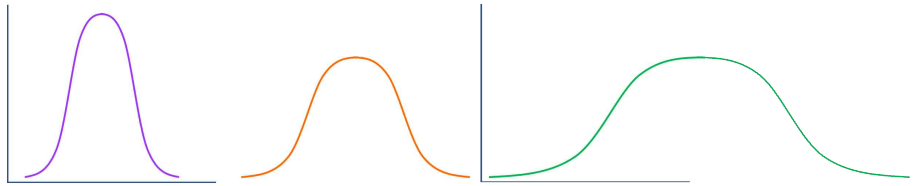

$m_4 > 3$ 표준정규분포보다 뾰족함 $m_4 = 3$ 표준정규분포와 유사함 $m_4 < 3$ 표준정규분포보다 덜 뾰족함

빅데이터 분석기사-2과목 빅데이터 탐색 11

1. 시각적 데이터 탐색

① 막대 그래프 : 범주형 변수의 계급 또는 값에 대한 관측치 도수를 나타냄
자료의 양이 많지 않을 때 유용

② 원 그래프 : 범주형 변수의 계급 또는 값에 대한 관측치의 백분율에 대한 상대적 차이 비교

③ 히스토그램 : 도수분포표에서 각 구간의 관측도수를 기둥 형태로 표현하여 크기 비교
자료의 분포 파악 가능-중심 경향도, 산포도, 비대칭도
표본 크기가 20 이상일 때 유용

④ 줄기-잎 그림 : 수치형 데이터를 줄기와 잎 모양으로 그린 그림
표본 크기가 50 이하일 때 효과적
각 구간의 분포와 구체적인 관측값, 이상치 존재 여부 및 위치 파악 가능
히스토그램에서 알 수 없는 최솟값, 최댓값, 구간 내 자료 분포 확인 가능

⑤ 상자 그림 : 최솟값, 최댓값, 사분위수의 순서 통계량을 이용하여 자료의 특성을 표현

⑥ 산점도 : 2개의 연속형 변수 간의 관계 확인, 직교좌표 평면에 관측점을 찍어 시각화

⑦ 선 그래프 : 연속형 변수에 해당하는 X축 변화에 따른 Y축의 변화를 선으로 나타냄
X축이 시간 또는 날짜의 순서이면 시계열 그래프라고 함
선의 기울기가 급할수록 변화가 큼을 의미

⑧ 도수다각형 : 꺾은선 그래프, 연속형 자료를 일정 크기의 계급으로 묶었을 때
계급의 중간점에서 해당 도수를 표시한 후 그 점들을 직선으로 연결

2. 시공간 데이터 탐색

① 등치지역도, 단계구분도 Choropleth Map 주제도 Thematic Map

a) 통계적 범위에 따라 행정 구역에 색상이 지정되거나 음영 처리되는 주제별 지도

b) 데이터의 값이 아닌 지리적 면적에 따라 실제 값이 왜곡될 위험

② 카토그램 Catogram

a) 의석수나 선거인단수, 인구 등 특정한 데이터 값의 변화에 따라 지도의 면적이 왜곡되는 그림, 변량비례도, 왜상 통계 지도

③ 버블 플롯맵 Bubble Plot Map

a) 버블 차트에 위도와 경도 정보를 적용하여 좌표를 원으로 시각화

b) 원의 크기, 색깔 등을 반영하여 데이터를 표현

④ 등치선도 Isarithmic map

a) 등치선(等値線)은 지도 상에서 같은 값을 가지는 점을 선으로 이은 것이며, 등치선도는 일정 간격으로 같은 값을 가지는 점을 등치선으로 이은 지도

빅데이터 분석기사-2과목 빅데이터 탐색 11

3. 시각적 데이터 탐색

① ___ 그래프 : 범주형 변수의 계급 또는 값에 대한 관측치 도수를 나타냄
자료의 양이 많지 않을 때 유용

② __ 그래프 : 범주형 변수의 계급 또는 값에 대한 관측치의 백분율에 대한 상대적 차이 비교

③ _____ : 도수분포표에서 각 구간의 관측도수를 기둥 형태로 표현하여 크기 비교
자료의 분포 파악 가능-중심 경향도, 산포도, 비대칭도
표본 크기가 20 이상일 때 유용

④ _____ ___ : 수치형 데이터를 줄기와 잎 모양으로 그린 그림
표본 크기가 50 이하일 때 효과적
각 구간의 분포와 구체적인 관측값, 이상치 존재 여부 및 위치 파악 가능
히스토그램에서 알 수 없는 최솟값, 최댓값, 구간 내 자료 분포 확인 가능

⑤ _____ : 최솟값, 최댓값, 사분위수의 순서 통계량을 이용하여 자료의 특성을 표현

⑥ _____ : 2개의 연속형 변수 간의 관계 확인, 직교좌표 평면에 관측점을 찍어 시각화

⑦ _____ : 연속형 변수에 해당하는 X축 변화에 따른 Y축의 변화를 선으로 나타냄
X축이 시간 또는 날짜의 순서이면 시계열 그래프라고 함
선의 기울기가 급할수록 변화가 큼을 의미

⑧ _____ : 꺾은선 그래프, 연속형 자료를 일정 크기의 계급으로 묶었을 때
계급의 중간점에서 해당 도수를 표시한 후 그 점들을 직선으로 연결

4. 시공간 데이터 탐색

① _____, _____ Choropleth Map _____ _____

b) 통계적 범위에 따라 행정 구역에 색상이 지정되거나 음영 처리되는 주제별 지도

c) 데이터의 값이 아닌 지리적 면적에 따라 실제 값이 왜곡될 위험

⑤ _____ _____

a) 의석수나 선거인단수, 인구 등 특정한 데이터 값의 변화에 따라 지도의 면적이 왜곡되는 그림, 변량비례도, 왜상 통계 지도

⑥ _____ _____

a) 버블 차트에 위도와 경도 정보를 적용하여 좌표를 원으로 시각화

b) 원의 크기, 색깔 등을 반영하여 데이터를 표현

⑦ _____ _____

a) 등치선(等値線)은 지도 상에서 같은 값을 가지는 점을 선으로 이은 것이며, 등치선도는 일정 간격으로 같은 값을 가지는 점을 등치선으로 이은 지도

1. 다변량 데이터 탐색 : 여러 현상이나 사건에 대한 측정치를 동시에 분석하여 관계성 파악

① 상관관계 분석

a) 변수들 간의 연관성을 파악하기 위해 변수 간 선형관계 정도를 분석

b) 산점도, 공분산, 상관계수를 이용

c) 공분산 covariance 분석

(i) 공분산 : 두 변수의 공통된 분포를 나타내는 분산

X와 X평균의 차와 Y와 Y평균의 차의 곱의 평균

$$Cov(X, Y) = E[(X-\mu_X)(Y-\mu_Y)]$$

(ii) 공분산이 0보다 크면 두 변수는 양의 상관관계, 0보다 작으면 음의 상관관계

(iii) 단위에 따라 값의 차이가 심하므로, 표준화된 공분산-상관계수를 사용

d) 상관계수 Correlation coefficient 분석

상관계수는 두 변수 사이의 통계적 관계를 표현하기 위해 특정한 상관 관계의 정도를 수치적으로 나타낸 계수

(i) 피어슨 상관계수 Pearson Correlation Coefficient ,PCC

- 두 변수 X 와 Y 간의 선형 상관 관계를 계량화한 수치
- 코시-슈바르츠 부등식에 의해 +1과 -1 사이의 값을 가지며, +1은 완벽한 양의 선형 상관 관계, 0은 선형 상관 관계 없음, -1은 완벽한 음의 선형 상관 관계를 의미, 일반적으로 상관관계는 피어슨 상관관계를 의미

$$\gamma_{XY} = \frac{\dfrac{\sum_{i=1}^{n}(X_i-\overline{X})(Y_i-\overline{Y})}{n-1}}{\sqrt{\dfrac{\sum_{i=1}^{n}(X_i-\overline{X})^2}{n-1}}\sqrt{\dfrac{\sum_{i=1}^{n}(Y_i-\overline{Y})^2}{n-1}}} = \frac{\text{공분산}}{\text{표준편차}\times\text{표준편차}}$$

(ii) 스피어만 서열상관계수 : 서열척도 변수 간의 상관관계

- 집단 내의 개별 관측치를 두 개의 서로 다른 관점이나 특성으로 평가한 순위값들을 이용하여 분석
- 예 : 3명 후보에 대한 선호도와 도덕성 순위 간의 관계 분석
- -1부터 1까지의 값을 가지며, 피어슨 상관계수와 동일한 방법으로 판단

(iii) 켄달의 타우 : 서열척도 변수 간의 상관관계

- 순위를 기준으로 상관관계 측정, 샘플 사이즈가 적거나 동률이 많을 때 유용

2. 다변량 데이터 탐색 : 여러 현상이나 사건에 대한 측정치를 동시에 분석하여 관계성 파악

① 상관관계 분석

a) 변수들 간의 연관성을 파악하기 위해 변수 간 선형관계 정도를 분석

b) _____, _____, _____를 이용

c) _____ _____

(i) 공분산 : 두 변수의 공통된 분포를 나타내는 분산

X와 X평균의 차와 Y와 Y평균의 차의 곱의 평균

$$Cov(X, Y) = E[(X-\mu_X)(Y-\mu_Y)]$$

(ii) 공분산이 0보다 크면 두 변수는 양의 상관관계, 0보다 작으면 음의 상관관계

(iii) 단위에 따라 값의 차이가 심하므로, 표준화된 공분산-상관계수를 사용

d) _____ _____ 분석

상관계수는 두 변수 사이의 통계적 관계를 표현하기 위해 특정한 상관 관계의 정도를 수치적으로 나타낸 계수

(i) _____ _____ ,___

- 두 변수 X 와 Y 간의 선형 상관 관계를 계량화한 수치
- _____ 부등식에 의해 +1과 -1 사이의 값을 가지며, ___은 완벽한 양의 선형 상관 관계, _은 선형 상관 관계 없음, ___은 완벽한 음의 선형 상관 관계를 의미, 일반적으로 상관관계는 피어슨 상관관계를 의미

$$\gamma_{XY} = \frac{\dfrac{\sum_{i=1}^{n}(X_i-\overline{X})(Y_i-\overline{Y})}{n-1}}{\sqrt{\dfrac{\sum_{i=1}^{n}(X_i-\overline{X})^2}{n-1}}\sqrt{\dfrac{\sum_{i=1}^{n}(Y_i-\overline{Y})^2}{n-1}}} = \frac{\text{공분산}}{\text{표준편차}\times\text{표준편차}}$$

(ii) _____ : _____ 변수 간의 상관관계

- 집단 내의 개별 관측치를 두 개의 서로 다른 관점이나 특성으로 평가한 ___값들을 이용하여 분석
- 예 : 3명 후보에 대한 선호도와 도덕성 순위 간의 관계 분석
- __부터 _까지의 값을 가지며, 피어슨 상관계수와 동일한 방법으로 판단

(iii) ___의 ____ : ___척도 변수 간의 상관관계

- 순위를 기준으로 상관관계 측정, 샘플 사이즈가 적거나 동률이 많을 때 유용

1. 다변량 데이터 탐색-상관관계 분석

① 상관계수의 유의성 검정

상관분석을 통해 얻은 상관계수를 일반화하여 사용하려면 통계적으로 유의한가 검정해야 함

② 가설 설정 Hypothesis

a) 모상관계수 ρ에 대한 귀무가설과 대립가설 설정

(i) 귀무가설 $H_0 : \rho = 0$ 두 변수 간에는 선형관계가 존재하지 않는다.

(ii) 대립가설 $H_1 : \rho \neq 0$ 두 변수 간에는 선형관계가 존재한다.

③ 검정통계량 Test statistics

a) 가설 검정에 t 통계량을 사용, 자유도가 n-2인 t 분포(t-distribuion)을 따름

$$t_{n-1} = \gamma \frac{\sqrt{n-2}}{\sqrt{1-\gamma^2}} \sim t(n-2)$$

④ 유의성 검정 Significance test

a) t 검정(t-test)으로 상관계수의 통계적 유의성 검정

b) 검정통계량 t값이 자유도 n-2인 t분포 상에서 유의수준 0.05로 하는 양측검정 임계치와 비교하여 검정통계량 t값이 양측 중 어느 한쪽의 임계치보다 크면 H_0기각(유의확률이 0.05보다 작으면 귀무가설 기각)

c) H_0이 기각되면 자동으로 H_1이 채택되어 두 변수의 상관계수가 유의수준 0.05에서 통계적으로 유의하다고 판단, 두 변수 간에 상관관계가 있음.

2. 기타 다변량 데이터 탐색

① 다차원 척도법 Multidimentional Scaling

개체들 사이의 유사/비유사성을 측정하여 개체들을 2차원 또는 3차원 공간상에 점으로 표현, 데이터 축소에 활용, 개체들간의 거리 계산은 유클리드 거리 행렬 사용

② 주성분 분석 PCA, Principal Component Analysis

분산이 최대인 축 찾기(주성분) → 첫 번째 축과 직교하면서 분산이 최대인 축 찾기

③ 선형판별분석 LDA, Linear Discriminant Analysis

같은 집단 내의 원소들은 뭉치고 집단 거리는 멀어지는 축 찾기

④ 조건부 플롯 : 3개 변수 X, Y, Z의 관계 탐색 시 X와 Y의 관계를 Z에 조건화

⑤ 평행좌표 플롯 Parallel Coordinates Plot

입력변수 X만큼 Y축을 만들고 동일한 행에 있는 값을 선으로 연결하여 시각화

서로 엇갈리는 방향으로 놓이면 음의 상관, 연결선들이 나란하면 양의 상관

3. 다변량 데이터 탐색-상관관계 분석

⑤ _____의 _____

상관분석을 통해 얻은 상관계수를 일반화하여 사용하려면 통계적으로 유의한가 검정해야 함

⑥ _____ _____

a) 모상관계수 ρ에 대한 귀무가설과 대립가설 설정

(i) 귀무가설 $H_0 : \rho = 0$ 두 변수 간에는 선형관계가 존재하지 않는다.

(ii) 대립가설 $H_1 : \rho \neq 0$ 두 변수 간에는 선형관계가 존재한다.

⑦ _____ _____

a) 가설 검정에 t 통계량을 사용, 자유도가 n-2인 t 분포(t-distribuion)을 따름

$$t_{n-1} = \gamma \frac{\sqrt{n-2}}{\sqrt{1-\gamma^2}} \sim t(n-2)$$

⑧ _____ Significance test

a) t 검정(t-test)으로 상관계수의 통계적 유의성 검정

b) 검정통계량 t값이 자유도 n-2인 t분포 상에서 유의수준 ____로 하는 양측검정 임계치와 비교하여 검정통계량 t값이 양측 중 어느 한쪽의 임계치보다 크면 H_0기각(유의확률이 ____보다 작으면 귀무가설 ____)

c) H_0이 기각되면 자동으로 H_1이 채택되어 두 변수의 상관계수가 유의수준 0.05에서 통계적으로 유의하다고 판단, 두 변수 간에 상관관계가 ____.

4. 기타 다변량 데이터 탐색

① 다차원 척도법 Multidimentional Scaling

개체들 사이의 유사/비유사성을 측정하여 개체들을 2차원 또는 3차원 공간상에 점으로 표현, 데이터 축소에 활용, 개체들간의 거리 계산은 유클리드 거리 행렬 사용

② _____ ___, Principal Component Analysis

분산이 최대인 축 찾기(주성분) → 첫 번째 축과 직교하면서 분산이 최대인 축 찾기

③ _____ ___, Linear Discriminant Analysis

같은 집단 내의 원소들은 뭉치고 집단 거리는 멀어지는 축 찾기

④ 조건부 플롯 : 3개 변수 X, Y, Z의 관계 탐색 시 X와 Y의 관계를 Z에 조건화

⑤ _____ ___ _____

입력변수 X만큼 Y축을 만들고 동일한 행에 있는 값을 선으로 연결하여 시각화

서로 엇갈리는 방향으로 놓이면 음의 상관, 연결선들이 나란하면 양의 상관

1. 비정형 데이터 분석

① 데이터 마이닝 Data Mining

대용량의 데이터에서 의미 있는 정보를 찾아내는 프로세스, 통계, 머신 러닝, 인공지능 등 여러 기술들을 활용하여 숨겨진 패턴이나 관계, 추세 등을 발견하는 과정

a) 분류 Classification : 주어진 데이터를 미리 정의된 그룹 또는 클래스로 분류

b) 군집화 Clustering : 유사한 특성을 갖는 데이터를 그룹화

c) 연관 규칙 학습 Association Rule Learning : 데이터 항목 간의 관계 찾기 (예: 장바구니 분석)

d) 회귀 Regression : 변수들 사이의 관계를 예측

e) 시퀀스 패턴 Sequential Patterns : 일련의 값들 사이의 패턴 찾기

f) 예측 Forecasting : 대용량 데이터집합 내의 패턴을 기반으로 미래 예측

② 텍스트 마이닝 Text Mining

대량의 비정형 텍스트 데이터에서 다양한 텍스트 분석 기법을 활용하여, 텍스트 내의 패턴, 트렌드, 구조 등을 찾아내고, 그 정보를 구조화하는 과정

자연어 처리 Natural Language Processing, NLP 기술을 기반으로 마케팅, 금융, 의료, 연구 등에서 데이터 분석, 시장 연구, 고객 의견 분석 등의 목적으로 활용

a) 감정 분석 Sentiment Analysis : 텍스트에서 긍정적인지 부정적인지의 감정 또는 의견을 판별, 제품 리뷰나 온라인 댓글에서 고객의 반응을 분석

b) 주제 모델링 Topic Modeling : 대량의 텍스트 데이터에서 주요 주제나 토픽을 추출

c) 개체 인식 Named Entity Recognition, NER : 텍스트에서 특정 정보(예: 사람 이름, 기관 이름, 날짜, 위치 등)를 인식하고 분류

d) 문서 분류 Document Classification
: 주어진 텍스트를 사전 정의된 카테고리로 분류

e) 문서 요약 Document Summarization : 긴 텍스트를 짧은 요약본으로 변환

② 오피니언 마이닝 Opinion Mining

텍스트 마이닝의 한 분류로서, 특정 주제에 대한 사람들의 주관적 의견을 통계, 수치화해 객관적 정보로 바꾸는 빅데이터 분석 기술

감정, 뉘앙스, 태도 등을 판별하므로 감정 분석이라고도 함

③ 웹 마이닝 Web Mining

기기에 쌓이는 로그, 사용자 행동 및 작성 콘텐츠 등으로부터 패턴, 추세 등을 도출, 이러한 데이터를 분석하여 유용한 정보를 추출, 통찰 Insight 를 얻어냄

2. 비정형 데이터 분석

① _____

대용량의 데이터에서 의미 있는 정보를 찾아내는 프로세스, 통계, 머신 러닝, 인공지능 등 여러 기술들을 활용하여 숨겨진 패턴이나 관계, 추세 등을 발견하는 과정

a) 분류 Classification : 주어진 데이터를 미리 정의된 그룹 또는 클래스로 분류

b) _____ : 유사한 특성을 갖는 데이터를 그룹화

c) _____ : 데이터 항목 간의 관계 찾기 (예: 장바구니 분석)

d) 회귀 Regression : 변수들 사이의 관계를 예측

e) 시퀀스 패턴 Sequential Patterns : 일련의 값들 사이의 패턴 찾기

f) 예측 Forecasting : 대용량 데이터집합 내의 패턴을 기반으로 미래 예측

② _____

대량의 비정형 텍스트 데이터에서 다양한 텍스트 분석 기법을 활용하여, 텍스트 내의 패턴, 트렌드, 구조 등을 찾아내고, 그 정보를 구조화하는 과정

자연어 처리 Natural Language Processing, NLP 기술을 기반으로 마케팅, 금융, 의료, 연구 등에서 데이터 분석, 시장 연구, 고객 의견 분석 등의 목적으로 활용

a) _____ : 텍스트에서 긍정적인지 부정적인지의 감정 또는 의견을 판별, 제품 리뷰나 온라인 댓글에서 고객의 반응을 분석

b) 주제 모델링 Topic Modeling : 대량의 텍스트 데이터에서 주요 주제나 토픽을 추출

c) 개체 인식 Named Entity Recognition, NER : 텍스트에서 특정 정보(예: 사람 이름, 기관 이름, 날짜, 위치 등)를 인식하고 분류

d) 문서 분류 Document Classification
: 주어진 텍스트를 사전 정의된 카테고리로 분류

e) 문서 요약 Document Summarization : 긴 텍스트를 짧은 요약본으로 변환

④ _____

텍스트 마이닝의 한 분류로서, 특정 주제에 대한 사람들의 주관적 의견을 통계, 수치화해 객관적 정보로 바꾸는 빅데이터 분석 기술

감정, 뉘앙스, 태도 등을 판별하므로 감정 분석이라고도 함

⑤ _____

기기에 쌓이는 로그, 사용자 행동 및 작성 콘텐츠 등으로부터 패턴, 추세 등을 도출, 이러한 데이터를 분석하여 유용한 정보를 추출, 통찰 Insight 를 얻어냄

⑥ text to vector 변환

텍스트 데이터를 수치 데이터로 이해하고 처리할 수 있게 함.

벡터화 기법들을 통해, 텍스트 데이터는 고차원의 수치 벡터 공간에 표현되게 되며, 이를 기반으로 다양한 NLP 작업(분류, 군집화, 유사도 계산 등)을 수행

a) 원 핫 인코딩 One-Hot Encoding : 각 단어를 고유한 하나의 벡터로 표현하는 방법, 예를 들어, "사과", "바나나", "체리"라는 세 개의 단어가 있을 때, "사과"는 [1, 0, 0], "바나나"는 [0, 1, 0], "체리"는 [0, 0, 1]로 표현

b) TF-IDF Term Frequency-Inverse Document Frequency : 단어의 빈도와 역문서 빈도를 사용하여 단어의 중요도를 계산하고 벡터로 표현

c) Word2Vec : 주변 단어의 문맥을 기반으로 단어의 임베딩을 학습

(i) CBOW : 주변 단어들로 중심 단어를 예측

(ii) Skip-Gram : 중심 단어로 주변 단어들을 예측

d) FastText : Word2Vec을 기반으로 하되, 단어를 부분 문자열(subword) 단위로 나누어 학습, 희소 단어나 철자 오류에 강함

e) GloVe Global Vectors for Word Representation : 전체 텍스트의 통계 정보를 활용하여 단어 임베딩을 학습하는 방법

f) BERT, GPT 등의 Transformer 기반 모델 : 딥러닝 기반의 방법으로, 큰 텍스트 데이터를 활용하여 단어, 문장, 문단 등의 임베딩을 학습, 이러한 모델은 특히 전이 학습 transfer learning 에서 뛰어난 성능을 보임

⑦ 텍스트 전처리

a) 데이터 클렌징 Data Cleansing : 불필요한 문자, 기호, 숫자 제거, HTML 태그, URL, 이메일 주소 제거, 특정 패턴이나 문자열 제거

b) 토큰화 Tokenization : 텍스트를 단어나 문장 등의 작은 단위로 분리

c) 불용어 제거 Stopword Removal : '그리고', '하지만', '이', '그', '저'와 같이 의미를 가지지 않거나 분석에 도움이 되지 않는 단어를 제거

d) 형태소 분석 Morphological Analysis : 단어를 기본 형태로 변환하거나 품사를 판별, "running"을 "run"으로 변환하거나 "뛰는"을 "뛰다"로 변환

e) 어간 추출 Stemming : 단어의 어간을 추출하여 단어의 다양한 변형을 기본 형태로 변환 "running" -> "run", "flies" → "fli".

f) 표제어 추출 Lemmatization : 단어의 원형 복원, "am", "are", "is" → "be"

g) n-그램 추출 n-gram Extraction : 연속된 n개의 토큰(단어, 문자등)으로 구성된 단위를 추출, "I love you"에서 바이그램(bigram)은 I love, love you

h) 단어 임베딩 Word Embedding : 단어를 고차원 벡터로 변환,
Word2Vec, FastText, GloVe 등

i) 정규화 Normalization : 같은 의미의 단어나 표현을 통일, "유니버시티"와 "대학교"를 같은 의미로 취급

⑧ text to vector 변환

텍스트 데이터를 수치 데이터로 이해하고 처리할 수 있게 함.

벡터화 기법들을 통해, 텍스트 데이터는 고차원의 수치 벡터 공간에 표현되게 되며, 이를 기반으로 다양한 NLP 작업(분류, 군집화, 유사도 계산 등)을 수행

a) _____ : 각 단어를 고유한 하나의 벡터로 표현하는 방법, 예를 들어, "사과", "바나나", "체리"라는 세 개의 단어가 있을 때, "사과"는 [1, 0, 0], "바나나"는 [0, 1, 0], "체리"는 [0, 0, 1]로 표현

b) _____ Term Frequency-Inverse Document Frequency : 단어의 빈도와 역문서 빈도를 사용하여 단어의 중요도를 계산하고 벡터로 표현

c) _____ : 주변 단어의 문맥을 기반으로 단어의 임베딩을 학습

(i) CBOW : 주변 단어들로 중심 단어를 예측

(ii) Skip-Gram : 중심 단어로 주변 단어들을 예측

d) _____ : Word2Vec을 기반으로 하되, 단어를 부분 문자열(subword) 단위로 나누어 학습, 희소 단어나 철자 오류에 강함

e) GloVe Global Vectors for Word Representation : 전체 텍스트의 통계 정보를 활용하여 단어 임베딩을 학습하는 방법

f) BERT, GPT 등의 Transformer 기반 모델 : 딥러닝 기반의 방법으로, 큰 텍스트 데이터를 활용하여 단어, 문장, 문단 등의 임베딩을 학습, 이러한 모델은 특히 전이 학습 transfer learning 에서 뛰어난 성능을 보임

⑨ 텍스트 전처리

a) 데이터 클렌징 Data Cleansing : 불필요한 문자, 기호, 숫자 제거, HTML 태그, URL, 이메일 주소 제거, 특정 패턴이나 문자열 제거

b) _____ : 텍스트를 단어나 문장 등의 작은 단위로 분리

c) _____ : '그리고', '하지만', '이', '그', '저'와 같이 의미를 가지지 않거나 분석에 도움이 되지 않는 단어를 제거

d) 형태소 분석 Morphological Analysis : 단어를 기본 형태로 변환하거나 품사를 판별, "running"을 "run"으로 변환하거나 "뛰는"을 "뛰다"로 변환

e) _____ : 단어의 어간을 추출하여 단어의 다양한 변형을 기본 형태로 변환 "running" -> "run", "flies" → "fli".

f) 표제어 추출 Lemmatization : 단어의 원형 복원, "am", "are", "is" → "be"

g) n-그램 추출 n-gram Extraction : 연속된 n개의 토큰(단어, 문자등)으로 구성된 단위를 추출, "I love you"에서 바이그램(bigram)은 I love, love you

h) 단어 임베딩 Word Embedding : 단어를 고차원 벡터로 변환,
Word2Vec, FastText, GloVe 등

i) _____ : 같은 의미의 단어나 표현을 통일, "유니버시티"와 "대학교"를 같은 의미로 취급

빅데이터 분석기사-2과목 빅데이터 탐색 15

1. 기술통계

① 중심화 경향 Central Tendency : 데이터의 중심 위치 파악, 평균, 중앙값, 최빈값

② 분산도 경향 Degree of Dispersion : 데이터가 흩어진 정도에 대한 기술 및 요약

③ 자료의 분포 형태 Shape of Distribution, Skewness

자료의 분포가 대칭인지, 한쪽으로 치우쳐 있는지에 대한 기술 및 요약

2. 표본 추출

① 모집단 Population : 정보를 얻고자 하는 전체 집합

전수 조사 : 모집단 전체를 대상으로 조사, 인구 조사

② 표본 Sample : 모집단 속에서 일부를 추출하여 조사한 결과

표본 조사 : 표본을 대상으로 조사를 시행, 비용 절감, 신속, 심도있는 조사 가능

③ 표본추출 Sampling : 모집단으로부터 표본을 추출하는 과정

a) 확률 표본추출 : 모집단으로부터 동일한 확률로 표본의 원소를 추출

(i) 단순무작위 추출 Simple Random Sampling

통계조사에서 가장 기본이 되는 표본 추출법으로 무작위 추출, $\frac{n}{N}$확률

추출 모집단에 대해 사전지식이 많지 않은 경우 시행

(ii) 계통 추출법 Systematic Sampling

첫 번째 개체를 무작위로 선택한 후, 그 이후에는 일정한 간격으로(추출 간격을 설정)하여 개체를 선택,

(iii) 층화 추출법 Stratified Sampling

모집단을 여러 층으로 나눈 후 각 계층을 대표할 수 있는 표본 추출, 각 층 내에서는 단순 무작위 추출. 집단 내 동질적, 집단 간 이질적

(iv) 군집 추출 Cluster Sampling

모집단을 여러 군집으로 나눈 후 일부 군집만을 무작위로 선택, 선택된 군집 내의 모든 개체를 조사, 집단 내 이질적, 집단 간 차이가 동질적

한 나라의 여러 도시를 군집으로 본다면, 각 도시 내의 주민들은 다양한 직업, 연령, 성별, 교육 수준 등의 특성을 가짐(집단 내 이질적). 그러나 여러 도시를 비교했을 때, 각 도시의 주민 구성이 크게 다르지 않음(집단 간 동질적). 이러한 특성 덕분에 군집 추출 방법을 사용하면, 전체 모집단을 조사하지 않아도 전체에 대한 합리적인 추론을 할 수 있게 됨

빅데이터 분석기사-2과목 빅데이터 탐색 15

3. 기술통계

① 중심화 경향 Central Tendency : 데이터의 중심 위치 파악, 평균, 중앙값, 최빈값

② 분산도 경향 Degree of Dispersion : 데이터가 흩어진 정도에 대한 기술 및 요약

③ 자료의 분포 형태 Shape of Distribution, Skewness

자료의 분포가 대칭인지, 한쪽으로 치우쳐 있는지에 대한 기술 및 요약

4. 표본 추출

① _____ : 정보를 얻고자 하는 전체 집합

전수 조사 : 모집단 전체를 대상으로 조사, 인구 조사

② 표본 Sample : 모집단 속에서 일부를 추출하여 조사한 결과

표본 조사 : 표본을 대상으로 조사를 시행, 비용 절감, 신속, 심도있는 조사 가능

③ _____: 모집단으로부터 표본을 추출하는 과정

a) 확률 표본추출 : 모집단으로부터 동일한 확률로 표본의 원소를 추출

(i) _____

통계조사에서 가장 기본이 되는 표본 추출법으로 무작위 추출, $\frac{n}{N}$확률

추출 모집단에 대해 사전지식이 많지 않은 경우 시행

(ii) _____

첫 번째 개체를 무작위로 선택한 후, 그 이후에는 일정한 간격으로(추출 간격을 설정)하여 개체를 선택,

(iii) _____

모집단을 여러 층으로 나눈 후 각 계층을 대표할 수 있는 표본 추출, 각 층 내에서는 단순 무작위 추출. 집단 내 _____, 집단 간 _____

(iv) _____

모집단을 여러 군집으로 나눈 후 일부 군집만을 무작위로 선택, 선택된 군집 내의 모든 개체를 조사, 집단 내 _____, 집단 간 차이가 _____

한 나라의 여러 도시를 군집으로 본다면, 각 도시 내의 주민들은 다양한 직업, 연령, 성별, 교육 수준 등의 특성을 가짐(집단 내 이질적). 그러나 여러 도시를 비교했을 때, 각 도시의 주민 구성이 크게 다르지 않음(집단 간 동질적). 이러한 특성 덕분에 군집 추출 방법을 사용하면, 전체 모집단을 조사하지 않아도 전체에 대한 합리적인 추론을 할 수 있게 됨

b) 비확률 표본 추출법

모집단에서 표본을 선택할 때 각 개체가 선택될 확률을 미리 알 수 없는 방법, 주관적 요소나 특정 기준에 따라 표본을 선택하게 되므로, 모집단을 정확하게 규정지을 수 없는 경우 사용, 비용과 시간, 조사의 편리함 때문에 자주 활용

(i) 편의 표본추출 convenience Sampling

조사자 임의대로 원소 표집, 길거리에서 만난 사람들에게 설문조사

(i) 판단 표본추출 Judgmental Sampling, 유의 표본추출

연구자의 판단이나 특정 기준에 따라 표본을 선택, 특정 전문가 그룹만을 대상으로 설문조사

(ii) 연속 표본추출 Sequential Sampling

연속적이나 순차적인 조건을 만족할 때까지 표본을 선택

(iii) 할당 표본추출 Quota Sampling

모집단의 여러 하위 그룹의 비율을 고려하여 표본을 선택, 남녀의 비율을 동일하게 유지하면서 설문조사

(iv) 눈덩이 추출법 Snowball Sampling

참여 대상자로부터 주변 사람을 소개받아 표본을 늘려가는 방식

2. 자료의 측정과 척도

① 측정 Measurement : 표본추출을 통해 얻은 자료를 분석 목적에 맞게 데이터화

② 척도 Scale : 측정된 값을 기준이나 규칙에 따라 분류하거나 순위를 매기는 방법

a) 질적 자료 Qualitative data : 범주형 자료, 숫자로 표현할 수 없는 데이터
성별, 교육수준

(i) 명목 척도 Nominal Scale : 순서나 크기의 의미 없이 단순히 분류,
성별(남, 여), 혈액형(A, B, AB, O)

(ii) 순서 척도 Ordinal Scale : 순위나 서열이 있는 척도이나 간격이 일정하지 않음, 선호도(매우 좋다, 좋다, 보통이다, 나쁘다)

b) 양적 자료 Quantitative data : 수치형 자료, 숫자로 표현 가능한 자료

(i) 등간(구간) 척도 Interval Scale : 일정한 간격으로 순위가 매겨진 척도이며, 절대적인 영점이 없음. 덧셈과 뺄셈 가능, 섭씨 온도 등

(ii) 비율 척도 Ratio Scale : 일정한 간격과 절대적인 영점을 가진 척도,
사칙연산 가능, 키, 무게, 거리, 나이 등

c) 비확률 표본 추출법

모집단에서 표본을 선택할 때 각 개체가 선택될 확률을 미리 알 수 없는 방법, 주관적 요소나 특정 기준에 따라 표본을 선택하게 되므로, 모집단을 정확하게 규정지을 수 없는 경우 사용, 비용과 시간, 조사의 편리함 때문에 자주 활용

(i) _____

조사자 임의대로 원소 표집, 길거리에서 만난 사람들에게 설문조사

(iii) _____

연구자의 판단이나 특정 기준에 따라 표본을 선택, 특정 전문가 그룹만을 대상으로 설문조사

(iv) _____

연속적이나 순차적인 조건을 만족할 때까지 표본을 선택

(v) _____

모집단의 여러 하위 그룹의 비율을 고려하여 표본을 선택, 남녀의 비율을 동일하게 유지하면서 설문조사

(vi) _____

참여 대상자로부터 주변 사람을 소개받아 표본을 늘려가는 방식

3. 자료의 측정과 척도

① 측정 Measurement : 표본추출을 통해 얻은 자료를 분석 목적에 맞게 데이터화

② _____ : 측정된 값을 기준이나 규칙에 따라 분류하거나 순위를 매기는 방법

a) _____ : 범주형 자료, 숫자로 표현할 수 없는 데이터
성별, 교육수준

(i) _____ : 순서나 크기의 의미 없이 단순히 분류,
성별(남, 여), 혈액형(A, B, AB, O)

(ii) _____ : 순위나 서열이 있는 척도이나 간격이 일정하지 않음, 선호도(매우 좋다, 좋다, 보통이다, 나쁘다)

b) _____ : 수치형 자료, 숫자로 표현 가능한 자료

(i) _____ : 일정한 간격으로 순위가 매겨진 척도이며, 절대적인 영점이 없음. 덧셈과 뺄셈 가능, 섭씨 온도 등

(ii) _____ : 일정한 간격과 절대적인 영점을 가진 척도,
사칙연산 가능, 키, 무게, 거리, 나이 등

1. 경우의 수

① 확률시험 1회의 시행에 있어서 일어날 수 있는 사건의 종류

② 합의 법칙 : 두 사건 A 또는 B가 일어나는 경우의 수

$n(A)=k, n(B)=j$ 이면 $n(A\cup B)=n(A)+n(B)-n(A\cap B)$

$A\cap B=\varnothing$이면 $n(A\cup B)=n(A)+n(B)$

③ 곱의 법칙 : 두 사건 A, B가 동시에 일어나는 경우의 수를 고려할 때

$n(A)=k, n(B)=j$ 이면 $n(A\times B)=n(A)\times n(B)$

④ 순열 : 서로 다른 n개의 원소에서 r개를 중복없이 순서를 고려하여 선택하는 경우의 수

$nPr=\dfrac{n!}{(n-r)!}$ $(n\neq n\times(n-1)\times(n-2)\times\cdots\times 2\times 1)$

⑤ 조합 : 서로 다른 n개의 원소에서 r개를 중복없이 순서를 고려하지 않고 선택하는 경우의 수

$\binom{n}{r}=nCr=\dfrac{n!}{(n-r)!r!}$

2. 확률

① 수학적 확률 : 표본공간 S의 각 사건이 일어날 가능성이 동등할 때, 사건 A에 대하여

$P(A)=\dfrac{n(A)}{n(S)}$

② 통계적 확률 : 불확실한 상황(자연현상)에서 특정 결과가 발생할 가능성을 정량화

어떤 시행을 n번 반복하고, 사건 A가 일어난 횟수를 r_n이라 할 때,

n을 크게 함에 따라 $\dfrac{r_n}{n}$이 일정한 값 p 가까워지면, 이 때 p를 사건 A의 통계적 확률이라 함

$p=\dfrac{r_n}{n}$

③ 독립 사건 : 두 개의 사건 A와 B가 있을 때, 각각의 사건이 일어날 확률이 다른 사건이 일어날 확률에 영향을 미치지 않을 때

④ 배반 사건 : 2개의 사건 A, B가 동시에 일어날 수 없을 때, 즉 한쪽이 일어나면 다른 쪽이 일어나지 않을 때의 두 사건

⑤ 조건부 확률 : 사건 B가 일어났다는 조건하에서 다른 사건 A가 일어날 확률

$P(A|B)=\dfrac{P(A\cap B)}{P(B)}, P(B)>0$

⑥ 결합 확률 : 확률의 곱셈, 사건 A와 사건 B가 동시에 발생하는 확률

$P(A\cap B)=P(A|B)\times P(B)$

빅데이터 분석기사-2과목 빅데이터 탐색 17

3. 경우의 수

① 확률시험 1회의 시행에 있어서 일어날 수 있는 사건의 종류

② 합의 법칙 : 두 사건 A 또는 B가 일어나는 경우의 수

$n(A)=k, n(B)=j$ 이면 $n(A\cup B)=$ _____

$A\cap B=\varnothing$이면 $n(A\cup B)=n(A)+n(B)$

③ 곱의 법칙 : 두 사건 A, B가 동시에 일어나는 경우의 수를 고려할 때

$n(A)=k, n(B)=j$ 이면 $n(A\times B)=$ _____

④ 순열 : 서로 다른 n개의 원소에서 r개를 중복없이 순서를 고려하여 선택하는 경우의 수

$nPr=$ $(n\neq n\times(n-1)\times(n-2)\times\cdots\times 2\times 1)$

⑤ 조합 : 서로 다른 n개의 원소에서 r개를 중복없이 순서를 고려하지 않고 선택하는 경우의 수

$\binom{n}{r}=nCr=$

4. 확률

① 수학적 확률 : 표본공간 S의 각 사건이 일어날 가능성이 동등할 때, 사건 A에 대하여

$P(A)=$

② 통계적 확률 : 불확실한 상황(자연현상)에서 특정 결과가 발생할 가능성을 정량화

어떤 시행을 n번 반복하고, 사건 A가 일어난 횟수를 r_n이라 할 때,

n을 크게 함에 따라 $\dfrac{r_n}{n}$이 일정한 값 p 가까워지면, 이 때 p를 사건 A의 통계적 확률이라 함

$p=$

③ 독립 사건 : 두 개의 사건 A와 B가 있을 때, 각각의 사건이 일어날 확률이 다른 사건이 일어날 확률에 영향을 미치지 않을 때

④ 배반 사건 : 2개의 사건 A, B가 동시에 일어날 수 없을 때, 즉 한쪽이 일어나면 다른 쪽이 일어나지 않을 때의 두 사건

⑤ 조건부 확률 : 사건 B가 일어났다는 조건하에서 다른 사건 A가 일어날 확률

$P(A|B)=$ $, P(B)>0$

⑥ 결합 확률 : 확률의 곱셈, 사건 A와 사건 B가 동시에 발생하는 확률

$P(A\cap B)=$

⑦ 한 개의 주사위를 한 번 던져서 나온 눈의 수가 6의 약수일 때, 그 수가 소수일 확률?
표본공간 S={1, 2, 3, 4, 5, 6}, A={1, 2, 3, 6}, B={2, 3, 5}, $A\cap B$={2, 3}

$P(A)=\frac{n(A)}{n(S)}=\frac{4}{6}=\frac{2}{3}$, $P(A\cap B)=\frac{n(A\cap B)}{n(S)}=\frac{2}{6}=\frac{1}{3}$

$P(B|A)=\frac{P(A\cap B)}{P(A)}=\frac{\frac{1}{3}}{\frac{2}{3}}=\frac{1}{2}$ 답 : $\frac{1}{2}$

⑧ 숫자 1, 2, 2, 3, 3, 3이 하나씩 적혀 있는 6장의 카드가 들어 있는 주머니에서 임의로 2장의 카드를 동시에 꺼낸다. 꺼낸 2장의 카드에 적혀 있는 두 수의 합이 짝수일 때, 꺼낸 2장의 카드 중에 3이 적혀 있는 카드가 있을 확률은? $\frac{6}{7}$

a) 꺼낸 2장의 카드에 적혀 있는 두 수의 합이 짝수인 사건 A
b) 꺼낸 2장의 카드 중에 3이 적혀 있는 카드가 있는 사건 B
c) 꺼낸 2장의 카드의 합이 짝수일 때, 꺼낸 2장의 카드 중에 3이 적혀 있는 카드가 있을 확률 $P(B|A)$

d) 꺼낸 2장의 카드 합이 짝수일 경우
1,3이 적힌 카드를 1장씩 꺼내는 경우, 2가 적힌 카드 2장 꺼내는 경우,
3이 적힌 카드 2장 꺼내는 경우

$P(A)=\frac{{}_1C_1\times{}_3C_1+{}_2C_2+{}_3C_2}{{}_6C_2}=\frac{7}{15}$

e) 꺼낸 2장의 카드에 적혀 있는 두 수의 합이 짝수이면서 꺼낸 2장의 카드 중에 3이 적혀 있는 카드가 있는 경우는 1,3이 적힌 카드를 1장씩 꺼내는 경우와 3이 적힌 카드 2장 꺼내는 경우

$P(A\cap B)=\frac{{}_1C_1\times{}_3C_1+{}_3C_2}{{}_6C_2}=\frac{2}{5}$

f) 구하는 확률은

$P(B|A)=\frac{P(A\cap B)}{P(A)}=\frac{\frac{2}{5}}{\frac{7}{15}}=\frac{6}{7}$

⑨ 숫자 1, 2, 3이 하나씩 적혀 있는 빨간 공 3개와 숫자 1, 2, 3, 4가 하나씩 적혀 있는 파란 공 4개가 들어 있는 주머니에서 임의로 2개의 공을 동시에 꺼낸다. 꺼낸 두 공에 적혀 있는 두 수의 합이 4일 때 꺼낸 두 공의 색이 서로 같을 확률?
$\frac{2}{5}$

⑩ 한 개의 주사위를 한 번 던져서 나온 눈의 수가 6의 약수일 때, 그 수가 소수일 확률?

⑪ 숫자 1, 2, 2, 3, 3, 3이 하나씩 적혀 있는 6장의 카드가 들어 있는 주머니에서 임의로 2장의 카드를 동시에 꺼낸다. 꺼낸 2장의 카드에 적혀 있는 두 수의 합이 짝수일 때, 꺼낸 2장의 카드 중에 3이 적혀 있는 카드가 있을 확률은?

⑫ 숫자 1, 2, 3이 하나씩 적혀 있는 빨간 공 3개와 숫자 1, 2, 3, 4가 하나씩 적혀 있는 파란 공 4개가 들어 있는 주머니에서 임의로 2개의 공을 동시에 꺼낸다. 꺼낸 두 공에 적혀 있는 두 수의 합이 4일 때 꺼낸 두 공의 색이 서로 같을 확률?

빅데이터 분석기사-2과목 빅데이터 탐색 18

1. 조건부 확률 예시 문제

① 어느 학교에서 방과후 수업을 신청한 학생, 50명 학생을 대상으로 저녁 간식을 신청받았다. 임의로 선택한 한 명의 학생이 남학생일 때, 이 학생이 피자를 신청하였을 확률은? $\frac{3}{5}$

	피자	떡볶이	계
남학생	12	8	20
여학생	16	14	30
계	28	22	50

a) 남학생일 때 피자를 신청했을 확률이므로 조건부 확률입니다.

b) 최종적으로 알고자 하는 확률은 피자를 신청했을 확률이고, 여기에 남학생이라는 조건이 포함되므로 **P(피자|남학생)** 으로 식을 세우고 계산합니다.

c) $P(\text{피자}|\text{남학생}) = \frac{P(\text{남학생} \cap \text{피자})}{P(\text{남학생})} = \frac{n(\text{남학생} \cap \text{피자})}{n(\text{남학생})}$

d) 즉 총 남학생은 20명이고 이중 피자를 선택한 학생은 12명이므로 확률은 $\frac{12}{20} = \frac{3}{5}$ 입니다.

2. 베이지안 정리(베이즈 정리 Baye's Theorem)

두 확률 변수의 사전 확률과 사후 확률 사이의 관계를 나타내는 정리다. 베이즈 확률론 해석에 따르면 베이즈 정리는 사전확률로부터 사후확률을 구할 수 있다. 베이즈 정리는 불확실성 하에서 의사결정문제를 수학적으로 다룰 때 중요하게 이용된다.

① 총 확률의 법칙

임의의 사건 B의 확률을 k개의 조건부 확률을 이용해서 구하는 방법입니다.

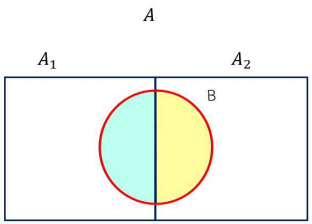

$P(B) = P(B \cap A) = P(B \cap A_1) + P(B \cap A_2) = P(B|A_1) \times P(A_1) + P(B|A_2) \times P(A_2)$

표본공간이 상호 배타적인 사건 $A_1, A_2, \cdots, A_k$로 분할될 때,

$$P(B) = \sum_{i=1}^{k} P(B|A_i) P(A_i)$$

② 베이지안 정리

$$P(A_1|B) = \frac{P(B \cap A_1)}{P(B)} = \frac{P(B|A_1) \times P(A_1)}{P(B)}$$

즉 $P(A_j|B) = \frac{P(B|A_j) \times P(A_j)}{\sum_{i=1}^{k} P(B|A_i) \times P(A_i)}$

③ 예시 문제(영진닷컴 2024 빅분기 필기 발췌)

직장 남성의 30%는 지나친 흡연으로 인한 기관지에 이상이 있다고 알려져 있다. 실제 기관지를 검사하였을 때, 검사결과가 90%가 이상이 있는 것으로 나타나고 기관지에 이상이 없는 경우에도 이상반응이 나타날 수 있는 확률이 10%이면, 임의의 직장 남성이 기관지 검사를 하였을 때 이상반응이 나타났지만 실제로 이상이 없을 확률은 얼마인가?

a) A_1은 기관지에 이상이 있을 사건, A_2는 이상이 없을 사건, 검사결과 이상반응이 나타날 사건을 B라고 한다면

$P(A_1) = 0.3 \quad P(A_2) = 0.7,\ P(B|A_1) = 0.9,\ P(B|A_2) = 0.1$

b) $P(B|A_1)$: 기관지에 이상이 있으면서 검사결과 이상 반응이 나타날 확률

c) $P(B|A_2)$: 기관지에 이상이 없는데 검사결과 이상 반응이 나타날 확률

d) 임의의 직장 남성이 기관지 검사를 하였을 때 이상을 보일 확률

$$P(B) = \sum_{i=1}^{2} P(B|A_i) P(A_i) = P(B|A_1) \times P(A_1) + P(B|A_2) \times P(A_2)$$

즉 $0.9 \times 0.3 + 0.1 \times 0.7 = 0.34$

e) 검사결과 이상이 있는 것으로 나타난 사람에게 실제로 기관지에 이상이 없는 사후확률은 아래와 같습니다.

$$P(A_2|B) = \frac{P(B|A_2) \times P(A_2)}{P(B)} = \frac{0.1 \times 0.7}{0.34} = \frac{7}{34}$$

빅데이터 분석기사-2과목 빅데이터 탐색 18

3. 조건부 확률 예시 문제

① 어느 학교에서 방과후 수업을 신청한 학생, 50명 학생을 대상으로 저녁 간식을 신청받았다. 임의로 선택한 한 명의 학생이 남학생일 때, 이 학생이 피자를 신청하였을 확률은? $\frac{3}{5}$

	피자	떡볶이	계
남학생	12	8	20
여학생	16	14	30
계	28	22	50

4. 베이지안 정리(베이즈 정리 Baye's Theorem)

두 확률 변수의 사전 확률과 사후 확률 사이의 관계를 나타내는 정리다. 베이즈 확률론 해석에 따르면 베이즈 정리는 사전확률로부터 사후확률을 구할 수 있다. 베이즈 정리는 불확실성 하에서 의사결정문제를 수학적으로 다룰 때 중요하게 이용된다.

① 총 확률의 법칙

임의의 사건 B의 확률을 k개의 조건부 확률을 이용해서 구하는 방법입니다.

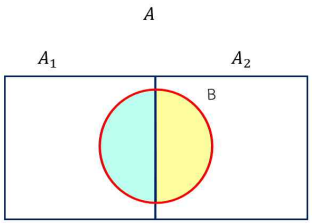

$P(B) = P(B \cap A) = P(B \cap A_1) + P(B \cap A_2) = P(B|A_1) \times P(A_1) + P(B|A_2) \times P(A_2)$

표본공간이 상호 배타적인 사건 $A_1, A_2, \cdots, A_k$로 분할될 때,

$P(B) =$

② 베이지안 정리

$$P(A_1|B) = \frac{P(B \cap A_1)}{P(B)} =$$

즉 $P(A_j|B) =$

③ 예시 문제(영진닷컴 2024 빅분기 필기 발췌)

직장 남성의 30%는 지나친 흡연으로 인한 기관지에 이상이 있다고 알려져 있다. 실제 기관지를 검사하였을 때, 검사결과가 90%가 이상이 있는 것으로 나타나고 기관지에 이상이 없는 경우에도 이상반응이 나타날 수 있는 확률이 10%이면, 임의의 직장 남성이 기관지 검사를 하였을 때 이상반응이 나타났지만 실제로 이상이 없을 확률은 얼마인가?